
Feature Engineering Pt. 1

Ксения Балабаева

15/10/25

Глава 0. Знакомство

Будем знакомы

Ксения Балабаева

Старший специалист по
машинному обучению в **BIOCAD**

Преподаватель и наставник в
BIOCAD, ИТМО

Наставник ML-проектов в
Сириусе, НИУ ВШЭ



Будем знакомы

1. БАКАЛАВРИАТ

2. МАГИСТРАТУРА



Будем знакомы

- 1. БАКАЛАВРИАТ**
- 2. МАГИСТРАТУРА**



НАУЧНО-ТЕХНИЧЕСКИЙ
ЦЕНТР

Будем знакомы

1. БАКАЛАВРИАТ
2. МАГИСТРАТУРА
3. АСПИРАНТУРА
- 4.



НАУЧНО-ТЕХНИЧЕСКИЙ
ЦЕНТР



Будем знакомы

1. БАКАЛАВРИАТ
2. МАГИСТРАТУРА



НАУЧНО-ТЕХНИЧЕСКИЙ
ЦЕНТР



Будем знакомы

1. БАКАЛАВРИАТ
2. МАГИСТРАТУРА
3. АСПИРАНТУРА
- 4.

РЕГИСТРАТУРА
Психоневрологического
диспансера




НАУЧНО-ТЕХНИЧЕСКИЙ
ЦЕНТР



Будем знакомы

1. БАКАЛАВРИАТ
2. МАГИСТРАТУРА
3. АСПИРАНТУРА
4. БИОТЕХНОЛОГИИ



НАУЧНО-ТЕХНИЧЕСКИЙ
ЦЕНТР



BIOCAD
Biotechnology Company

Что нас ждет сегодня?

1. Легкое погружение в биотех
2. Введение в инженерию признаков
3. Практика


Глава 1. ML в Биотехе



Biotechnology Company


BIOCAD — ведущая биотехнологическая компания России, осуществляющая полный цикл **разработки, исследований и производства** препаратов для лечения **онкологических, аутоиммунных и наследственных** заболеваний.

<https://biocad.ru/we>



**Сколько времени занимает
создание нового препарата?**

Путь препарата от идеи до пациентов



Edwards, L., Fox, A., & Stonier, P. (Eds.). (2010). *Principles and practice of pharmaceutical medicine* (3rd ed.). Oxford: Wiley-Blackwell.

Зачем здесь машинное обучение?

Цель ML команды - повысить эффективность и **производительность** процессов биотехнологической компании **на всех** этапах создания лекарства, **ускорив выход препаратов** на рынок

ML в биотехнологическом производстве


Как мы подружили ML и биореакторы

🕒 12 мин 👁 4.4K

Блог компании BIOCAD, Машинное обучение*

Сезон machine learning

Привет, Хабр! Мы Data Science команда биотехнологической компании BIOCAD. Хотим рассказать вам о том, как мы применяем машинное обучение при производстве лекарственных средств и с какими задачами сталкиваемся для оптимизации технологического процесса культивирования белка.



<https://habr.com/ru/companies/biocad/articles/698330/>

ML в биотехнологическом производстве

Detection of Pharmaceutical Personal Protective Equipment in Video Stream

Michael Leontiev ¹, Danil Zhilikov ¹, Lenar Klimov ¹, Vyacheslav Chertan ¹, Daniel Bobrov ¹, Dmitry Lobanov ¹, Vasilii Vologdin ¹, Vladislav Maslov ¹, Ksenia Balabaeva ¹


Affiliations + expand

PMID: 39176953 DOI: [10.3233/SHTI240572](https://doi.org/10.3233/SHTI240572)

Abstract

Pharmaceutical manufacturing is a complex process, where each stage requires a high level of safety and sterility. Personal Protective Equipment (PPE) is used for this purpose. Despite all the measures of control, human factor (improper PPE wearing) causes numerous losses for human health and material property. This research proposes solid computer vision system for ensuring safety in pharmaceutical laboratories. For this we have tested wide range of state-of-the-art object detection methods. Composing previously obtained results in this sphere with our own approach to this problem, we have reached the high accuracy (mAP@0.5) ranging from 0.77 up to 0.98 in detecting all the elements of common set of PPE used in pharmaceutical laboratories. Our system is the step towards safe medicine producing.

Keywords: PPE detection; computer vision; monitoring in pharmaceutical development; object detection; personal protective equipment; sterility and safety in pharmaceutical development.



<https://pubmed.ncbi.nlm.nih.gov/39176953/>



Стажировки в BIOCAD

career.biocad.ru

Sales &
marketing

Вычислительная
биология

Качество

Производство

Research &
development

IT

Фармацевтическая
разработка

HR

Экономика
и финансы

Закупки
и логистика

Юриспруденция

Оплачиваемая стажировка

Срок стажировки: 2—5.5 месяцев

* **Зимний сезон 2025**

Сбор заявок: 30 октября — 24 ноября

Выход: январь-февраль

☼ **Летний сезон**

Сбор заявок: апрель

Выход: июнь-июль

Этапы отбора:

- Резюме + мотивационное письмо
- Тестовое задание
- Собеседование
- Приглашение на стажировку

Глава 2. Введение в Feature Engineering

Что такое инженерия признаков?

Инженерия признаков - это процесс **использования знаний в предметной области** для создания **новых признаков** на основе существующих данных, **которые повышают эффективность алгоритмов машинного обучения**.

Его часто считают одним из важнейших этапов в процессе машинного обучения.

А я его считаю одним из самых творческих этапов машинного обучения.



Цель этого этапа решения проекта:


- Представить сырые данные в лучшем виде для решения конкретной задачи;
- Повысить качество работы модели;

Обзор медицинского набора данных

Рассмотрим небольшой медицинский датасет

Всего пациентов	1000
Количество признаков	12
Числовые признаки	
Категориальные признаки	8
Целевая переменная	4

Возраст: Возраст пациента (лет)	числ
BMI: Индекс массы тела	числ
Давление: Артериальное давление	числ
Глюкоза: Уровень глюкозы (мг/дл)	числ
Холестерин: Уровень холестерина	числ
Диагноз: Категория заболевания	кат
Курение: Статус курения	кат



Задача: Предсказать риск инфаркта

Типы признаков в машинном обучении

Числовые признаки

Признаки, представленные числовыми значениями, которые можно измерить и сравнить количественно.

Непрерывные

Примеры: Возраст (45.5 лет), BMI (28.3), Температура тела (36.6°C), Уровень глюкозы (120.5 мг/дл)

Дискретные

Примеры: Количество госпитализаций (3), Число симптомов (5), Количество лекарств (2)

Категориальные признаки

Признаки, представленные категориями или метками без естественного числового порядка.

Номинальные

Примеры: Группа крови (А, В, АВ, О), Пол (М, Ж), Диагноз (Диабет, Гипертония, Здоров)

Порядковые

Примеры: Стадия заболевания (I, II, III, IV), Уровень боли (низкий, средний, высокий), Образование (школа, бакалавр, магистр)

Бинарные признаки

Признаки с двумя возможными значениями, часто представляющие наличие или отсутствие характеристики.

Да/Нет признаки

Примеры: Наличие диабета (да/нет), Курение (да/нет), Гипертония (да/нет), Семейная история болезни (да/нет)

Временные признаки

Признаки, связанные с временем и датами, которые можно разложить на компоненты.

Компоненты даты/времени

Примеры: Дата визита → День недели, Месяц, Год, Квартал; Время приема → Час дня, Утро/День/Вечер

Исследование медицинских данных


Анализ корреляции

Тепловая карта корреляции показывает силу и направление **взаимосвязи между признаками**.

Ключевые выводы

- Возраст имеет самую сильную корреляцию с оценкой риска (0.75)
- Артериальное давление сильно коррелирует с риском (0.72)
- BMI и давление показывают умеренную связь (0.55)
- Уровень глюкозы связан с BMI и возрастом пациента

Эти корреляции помогают врачам и исследователям создавать комплексные оценки риска, комбинируя несколько медицинских показателей для более точной диагностики.



Обработка категориальных переменных

Бинарное кодирование

Для бинарных медицинских переменных (да/нет, положительный/отрицательный) преобразуйте в числовой формат. Это эффективно для представления наличия или отсутствия симптомов, заболеваний или факторов риска.

Пример клинических данных:

has_diabetes: 'yes' → 1

is_smoker: 'no' → 0

hypertension: 'yes' → 1


Прямое кодирование (One-Hot)

Для категорий заболеваний или диагнозов с несколькими вариантами создайте отдельные бинарные индикаторы. Это позволяет модели независимо оценивать влияние каждого типа заболевания на прогноз.

Кодирование диагнозов:


diagnosis: 'Diabetes'

→ has_hypertension: 0, has_heart_disease: 0




ANDREW THOMSON

THINK OUTSIDE THE BOX




OUTSMART YOUR LAZINESS, THINK INTELLIGENTLY,
GENERATE IDEAS ON DEMAND, MAKE SMARTER
CHOICES AND BE A PRODUCTIVITY MACHINE

Задача 0. Погружение в доменную область



Медицинские шкалы оценки риска



Дерево диагностики инфаркта

Задача 0. Погружение в доменную область

Open Access

Original article



Validation of risk scoring models for predicting stroke-associated pneumonia in patients with ischaemic stroke

Siyin Gong, Zhiwei Zhou, Muke Zhou, Zhao Lei, Jian Guo, Ning Chen, Li He

To cite: Gong S, Zhou Z, Zhou M, et al. Validation of risk scoring models for predicting stroke-associated pneumonia in patients with ischaemic stroke. *Stroke and Vascular Neurology* 2016;1:e000025. doi:10.1136/svn-2016-000025

SG and ZZ made equal contributions to the study and the article.

Received 4 June 2016
Revised 29 August 2016
Accepted 31 August 2016

ABSTRACT

Objective: Various risk scoring models have been developed to predict stroke-associated pneumonia (SAP). We aim to determine whether these risk models could effectively predict SAP in Chinese patients with ischaemic stroke (IS).

Methods: Consecutive patients with IS in West China hospital between January 2011 and September 2013 were included to assess the predictive performance of risk scoring models, including Chumblor's score, A²DS² and AISAPS. The area under the receiver operating characteristic curve (AUROC) was used to evaluate the performance of each risk model in predicting pneumonia.

Results: A total of 1569 consecutive patients with IS within 30 days of onset in West China hospital were included. The incidence of pneumonia is 15.3%. The AUROC of Chumblor's score, A²DS² and AISAPS was 0.659, 0.728 and 0.758, respectively, and AISAPS had the highest AUROC.

Conclusions: A²DS² and AISAPS had acceptable discriminatory abilities to predict SAP in Chinese patients with IS within 30 days of onset.

INTRODUCTION

Pneumonia is a common complication in patients with stroke.¹ It occurs in about 9% of patients with stroke, and 28% of patients with stroke in the intensive care unit.² A variety of factors, such as older age, dysphagia and higher stroke severity score, which are assessed by the National Institutes of Health Stroke Scale (NIHSS), are associated with

Several risk scoring models were reported to improve the recognition of the high risk of pneumonia in patients with stroke, including Kwon's score,³ the PANTHER-IS score,⁴ Chumblor's score,⁵ A²DS²¹⁰ and AISAPS.¹¹ There are many advantages to the wide use of these risk models, such as assisting clinicians to identify patients with stroke with high risk of pneumonia and facilitating the selection of patients in clinic trials. However, these models have not been applied extensively to patients in different cohorts from various races and areas. They need to be externally validated before they can be used in clinical practice.

We conducted this study to determine whether these risk models could effectively predict SAP during hospitalisation in Chinese patients with IS. Since the risk scores of ischaemic stroke-associated pneumonia (like A²DS² and AISAPS) are different from that of haemorrhagic stroke (like intracerebral haemorrhage-associated pneumonia score (ICH-APS)),¹² we only focused on patients with ischaemic stroke to control potential confounders.

METHODS

Study population

We identified all consecutive patients with IS in West China hospital between January 2011 and September 2013. Inclusion criteria: aged ≥18; patients with IS who were admitted

Clinical scoring model based on age, NIHSS, and stroke-history predicts outcome 3 months after acute ischemic stroke

Gang-yu Ding^{1*}

Jian-hua Xu¹

Ji-hong He¹

Zhi-yu Nie^{2*}

¹ Department of Neurology, Jiading District Central Hospital Affiliated Shanghai University of Medicine and Health Sciences, Shanghai, China

² Department of Neurology, Shanghai Tongji Hospital, Tongji University School of Medicine, Shanghai, China

Background: The clinical nomogram is a popular decision-making tool that can be used to predict patient outcomes, bringing benefits to clinicians and patients in clinical decision-making. This study established a simple and effective clinical prediction model to predict the 3-month prognosis of acute ischemic stroke (AIS), and based on the predicted results, improved clinical decision-making and improved patient outcomes.

Methods: From 18 December 2021 to 8 January 2022, a total of 146 hospitalized patients with AIS confirmed by brain MR were collected, of which 132 eligible participants constituted a prospective study cohort. The least absolute shrinkage and selection operator (LASSO) regression was applied to a nomogram model development dataset to select features associated with poor prognosis in AIS for inclusion in the logistic regression of our risk scoring system. On this basis, the nomogram was drawn, evaluated for discriminative power, calibration, and clinical benefit, and validated internally by bootstrap. Finally, the optimal cutoff point for each independent risk factor and nomogram was calculated using the Youden index.

Results: A total of 132 patients were included in this study, including 85 men and 47 women. Good outcome was found in 94 (71.212%) patients and bad outcome in 38 (28.788%) patients during the follow-up period. A total of eight (6.061%) deaths were reported over this period, of whom five (3.788%) died during hospitalization. Five factors affecting the 3-month prognosis of

Создание новых признаков

1 Взаимодействие признаков

Комбинируйте показатели для создания составных индикаторов риска, которые лучше отражают комплексное состояние здоровья пациента.

Пример:

weight = 62, Height = 1.7

→ $BMI = 62 / (1.7 * 1.7) = 21.45$

glucose = 140, blood_pressure = 150

→ $metabolic_score = 140 \times 150 = 21000$



Создание новых признаков

1 Взаимодействие признаков

Комбинируйте показатели для создания составных индикаторов риска, которые лучше отражают комплексное состояние здоровья пациента.

Пример:

weight = 62, Height = 1.7

→ $BMI = 62 / (1.7 \times 1.7) = 21.45$

glucose = 140, blood_pressure = 150

→ $metabolic_score = 140 \times 150 = 21000$

2 Полиномиальные признаки

Создавайте **квадратичные и кубические признаки** для лучшего отображение нелинейных взаимосвязей между показателями здоровья и риском заболеваний.

Пример:


age = 55

→ $age^2 = 3025$

→ $age^3 = 166375$

bmi = 28

→ $bmi^2 = 784$



Создание новых признаков

1 Взаимодействие признаков

Комбинируйте показатели для создания составных индикаторов риска, которые лучше отражают комплексное состояние здоровья пациента.

Пример:

weight = 62, Height = 1.7
→ $BMI = 62 / (1.7 * 1.7) = 21.45$

glucose = 140, blood_pressure = 150
→ $metabolic_score = 140 \times 150 = 21000$

2 Полиномиальные признаки

Создавайте квадратичные и кубические признаки для лучшего отображение нелинейных взаимосвязей между показателями здоровья и риском заболеваний.

Пример:

age = 55
→ $age^2 = 3025$
→ $age^3 = 166375$


bmi = 28
→ $bmi^2 = 784$

3 Булевы признаки

Создавайте **булевы индикаторы** на основе **пороговых значений** для выявления пациентов с повышенным риском.

Пример:

is_obese = $(BMI > 30) \rightarrow 1$
has_high_bp = $(BP > 140) \rightarrow 1$
diabetic_range = $(glucose > 126) \rightarrow 1$
high_risk = $(age > 60 \text{ AND } BMI > 30) \rightarrow 1$



GLUCOSE LEVELS CHART

Создание новых признаков

1 Взаимодействие признаков

Комбинируйте показатели для создания составных индикаторов риска, которые лучше отражают комплексное состояние здоровья пациента.

Пример:

weight = 62, Height = 1.7
→ $BMI = 62 / (1.7 * 1.7) = 21.45$

glucose = 140, blood_pressure = 150
→ $metabolic_score = 140 \times 150 = 21000$

3 Булевые признаки

Создавайте булевые индикаторы на основе клинических пороговых значений для выявления пациентов с повышенным риском.

Пример:

is_obese = $(BMI > 30) \rightarrow 1$
has_high_bp = $(BP > 140) \rightarrow 1$
diabetic_range = $(glucose > 126) \rightarrow 1$
high_risk = $(age > 60 \text{ AND } BMI > 30) \rightarrow 1$

2 Полиномиальные признаки

Создавайте квадратичные и кубические признаки для лучшего отображения нелинейных взаимосвязей между показателями здоровья и риском заболеваний.

Пример:

age = 55
→ $age^2 = 3025$
→ $age^3 = 166375$

bmi = 28
→ $bmi^2 = 784$

4 Биннинг (группировка)

Группируйте непрерывные показатели в значимые категории для упрощения интерпретации и выявления паттернов.

Пример::

age: 18-30 → 'молодой'
age: 31-50 → 'средний'
age: 51+ → 'пожилой'

bmi: <18.5 → 'недостаточный вес'
bmi: 18.5-24.9 → 'нормальный'
bmi: 25-29.9 → 'избыточный вес'
bmi: 30+ → 'ожирение'

Кодирование категориальных признаков

1

Binary Encoding

Преобразует категории в 0 и 1, если переменная принимает два уникальных значения

Пол	→	Пол
Мужской		0
Женский		1

Кодирование категориальных признаков

1

Binary Encoding

Преобразует категории в 0 и 1, если переменная принимает два уникальных значения

Пол	Пол
Мужской	0
Женский	1

2

One-hot кодирование

Метод преобразования категориальных переменных в бинарный формат, где каждая категория отдельным признаком со значениями 0 или 1.

id	color	One Hot Encoding		
id	color	color_red	color_blue	color_green
1	red	1	0	0
2	blue	0	1	0
3	green	0	0	1
4	blue	0	1	0

Кодирование категориальных признаков

1 Binary Encoding

Преобразует категории в 0 и 1, если переменная принимает два уникальных значения

Пол	Пол
Мужской	0
Женский	1

2 One-hot кодирование

Метод преобразования категориальных переменных в бинарный формат, где каждая категория отдельным признаком со значениями 0 или 1.

id	color	One Hot Encoding		
id	color	color_red	color_blue	color_green
1	red	1	0	0
2	blue	0	1	0
3	green	0	0	1
4	blue	0	1	0

3 Target Encoding

Целевое кодирование – метод преобразования категориальных переменных, при котором каждая категория заменяется на среднее значение целевой переменной

Регион	Средний риск	Encoded
Москва	$(0+1+0)/3$	0.333
С-Петербург	$(1+1)/2$	1.000
Новосибирск	$(0+1)/2$	0.500

Есть риск переобучения и утечки данных

Необходимо использовать сглаживание и кросс-валидацию для мониторинга переобучения

```
encoded = (n × mean + m × global_mean) / (n + m)
```

где n – размер категории, m – параметр сглаживания

Преобразование признаков

Зачем преобразовывать?


Данные часто имеют **асимметричное распределение**. Например, индекс массы тела (BMI), уровни биомаркеров и другие показатели могут быть смещены вправо, что затрудняет работу алгоритмов машинного обучения (но не всех).

Преимущества преобразования

Нормализует асимметричные распределения
Улучшает производительность **линейных моделей**

Снижает **влияние выбросов** в данных

Делает признаки более сопоставимыми по масштабу



Типы преобразований

Квадратный корень:

Подходит для умеренно асимметричных данных, таких как BMI.

Логарифм:

Эффективен для сильно асимметричных данных, таких как, например, уровни биомаркеров.

Box-Cox:

Автоматически находит оптимальное преобразование для нормализации данных.

Преобразование целевой переменной

Концепция

Преобразование целевой переменной (например, логарифмирование) — мощный прием в регрессионных задачах. Помогает модели лучше учиться и делать более точные предсказания.

Основные методы преобразования

Логарифм (Log)

$$y' = \log(y + 1)$$

Для скошенных распределений

Квадратный корень

$$y' = \sqrt{y}$$

Умеренное сжатие

Box-Cox

Автоматический подбор оптимального λ

Yeo-Johnson

Работает с нулями и отрицательными значениями


```
# Логарифмическое преобразование
import numpy as np
from sklearn.preprocessing import PowerTransformer
```

```
# 1. Простое логарифмирование
y_log = np.log1p(y) # log(y + 1), безопасно для 0
```

```
# Обучение модели
model.fit(X_train, y_log_train)
```

```
# Предсказание и обратное преобразование
y_pred_log = model.predict(X_test)
y_pred = np.exp(y_pred_log) # exp(y) - 1
```

Визуализация эффекта



Важно помнить:

Обратное преобразование: после предсказания нужно применить обратную функцию (exp для log)

Метрики: оценивайте качество на исходной шкале, не на преобразованной

Интерпретация: коэффициенты модели теперь интерпретируются как процентные изменения

Когда применять:

Скошенное распределение: цены, доходы, количество

Гетероскедастичность: разброс увеличивается с ростом значений

Экспоненциальный рост: зависимость нелинейная

Выбросы: несколько экстремально больших значений

Масштабирование признаков

Признаки часто имеют **разные единицы измерения и диапазоны**: возраст (0-100 лет), уровень глюкозы (70-200 мг/дл), артериальное давление (80-200 мм рт.ст.). **Масштабирование приводит их к общему диапазону для справедливого сравнения.**

Стандартизация (Z-score)

Преобразует признаки так, чтобы они имели **среднее значение 0** и **стандартное отклонение 1**. Сохраняет информацию о выбросах.

Формула:

$$z = (x - \mu) / \sigma$$

Пример:

Возраст: 65 лет

Среднее: 45, Станд. откл.: 15

Стандартизовано: $(65-45)/15 = 1.33$

Когда использовать:

Логистическая регрессия, SVM, нейронные сети

Масштабирование признаков

Признаки часто имеют **разные единицы измерения и диапазоны**: возраст (0-100 лет), уровень глюкозы (70-200 мг/дл), артериальное давление (80-200 мм рт.ст.). **Масштабирование приводит их к общему диапазону для справедливого сравнения.**

Стандартизация (Z-score)

Преобразует признаки так, чтобы они имели **среднее значение 0** и **стандартное отклонение 1**. Сохраняет информацию о выбросах.

Формула:

$$z = (x - \mu) / \sigma$$

Пример:

Возраст: 65 лет

Среднее: 45, Станд. откл.: 15

Стандартизовано: $(65-45)/15 = 1.33$

Когда использовать:

Алгоритмы на основе расстояний, градиентные алгоритмы

Min-Max нормализация

Масштабирует признаки в фиксированный диапазон [0, 1]. Сохраняет исходное распределение, но чувствительна к выбросам.

Формула:

$$x_{\text{norm}} = (x - \min) / (\max - \min)$$

Пример:

Глюкоза: 140 мг/дл

Диапазон: 70-200 мг/дл

Нормализовано: $(140-70)/(200-70) = 0.54$

Когда использовать:

Нейронные сети, алгоритмы на основе расстояний (KNN) для классификации пациентов

Проклятие размерности

Что это такое?

Проклятие размерности — это явление, при котором увеличение количества признаков экспоненциально увеличивает объем пространства данных, делая данные разреженными и затрудняя обучение моделей.

Проблемы высокой размерности


Экспоненциальный рост требуемых данных для обучения

Расстояния между точками становятся бессмысленными

Переобучение модели на шуме в данных

Увеличение вычислительной сложности

Снижение производительности алгоритмов



Отбор признаков

1

Отбор на основе корреляции


Определите показатели, которые сильно коррелируют с целевой переменной, одновременно удаляя избыточные признаки.

Вычислите коэффициенты корреляции между показателями и целевой переменной. Признаки с высокой корреляцией более прогностичны.

Удаляет избыточные признаки

Снижает мультиколлинеарность

Быстрый и интерпретируемый способ фильтрации



Отбор признаков

1

Отбор на основе корреляции

Определите медицинские показатели, которые сильно коррелируют с риском заболевания, одновременно удаляя избыточные признаки.

Вычислите коэффициенты корреляции между клиническими показателями и целевой переменной. Признаки с высокой корреляцией более прогностичны.

Удаляет избыточные медицинские показатели
Снижает мультиколлинеарность
Быстрый и интерпретируемый


2

Важность признаков (Feature Importance)

Некоторые ML модели оценивают, какие признаки наиболее важны для прогнозирования целевой переменной.

Примеры: Decision Trees, Linear Regression, Random Forest

Так можно выявить **нелинейные взаимосвязи**



Клиническая значимость

Отбор правильных признаков улучшает точность диагностики, снижает переобучение, уменьшает время обучения и повышает доверие пользователей к модели.

А еще упрощает инференс и эксплуатацию модели.

Лучшие практики конструирования признаков

1 Избегайте утечки данных

Утечка данных происходит, когда информация из тестового набора влияет на процесс обучения. Это приводит к завышенным оценкам производительности, которые не обобщаются на новые данные. Всегда обучайте преобразования (масштабирование, кодирование) только на тренировочном наборе, затем применяйте их к тестовому.

3 Итеративный процесс

Конструирование признаков — это не разовый процесс. Оно требует **экспериментирования, оценки и уточнения**. Пробуйте различные комбинации признаков, тестируйте их влияние на производительность модели и итерируйте на основе результатов.

5 Баланс сложности и интерпретируемости

Хотя сложные признаки могут улучшить производительность, они могут сделать модели **труднее интерпретируемыми**. Найдите баланс между точностью модели и интерпретируемостью в зависимости от вашего случая использования. В медицине интерпретируемость часто критична для доверия врачей.

2 Доменные знания критичны

Наиболее эффективные признаки часто создаются на основе **понимания предметной области**. Для медицинских данных знание того, что возраст, BMI и артериальное давление являются ключевыми факторами риска, помогает направить создание признаков. Сотрудничайте с экспертами в области, когда это возможно.

4 Отслеживайте признаки

Документируйте все шаги конструирования признаков четко. Это обеспечивает воспроизводимость и помогает другим понять вашу работу. Используйте описательные имена признаков и поддерживайте словарь признаков с их определениями и методами создания.

6 Мониторинг мультиколлинеарности

Создание многих признаков может привести к **мультиколлинеарности** (высокой корреляции между признаками). Это делает модели нестабильными и коэффициенты трудными для интерпретации. Используйте корреляционный анализ и фактор инфляции дисперсии (VIF) для обнаружения и устранения мультиколлинеарности.

Наша задача на сегодня

Competition Description



Ask a home buyer to describe their dream house, and they probably won't begin with the height of the basement ceiling or the proximity to an east-west railroad. But this playground competition's dataset proves that much more influences price negotiations than the number of bedrooms or a white-picket fence.

With 79 explanatory variables describing (almost) every aspect of residential homes in Ames, Iowa, this competition challenges you to predict the final price of each home.

<https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques>