

Занятие №3

**Углубленный EDA:
статистический анализ,
визуализация данных,
аномалии и текстовые
данные**


октябрь 2025



Дмитрий Кротов

И.о. Team Lead аналитиков опыта исполнителя
в Авито Подработка, аспирант.

- Alma mater: Финансовый университет при Правительстве РФ
- 5 лет в Аналитике (ex Avito Авто, Ozon)
- Преподаватель во внешней и внутренней Академии Аналитиков Авито
- Основатель и автор тг-канала Data dreamen
- Автор тг-канала Авито «Коммуналка аналитиков»



@DATA_DREAMEN

Структура занятий


Тема 1. Разведочный анализ данных

- Введение в работу с данными и разведочный анализ
- Статистический анализ и визуализация данных

 Углубленный EDA:
● статистический анализ,
визуализация данных,
аномалии и текстовые
данные

Тема 2. Очистка и подготовка датасета


- Очистка и подготовка датасета к моделям и исследованиям



Визуальный анализ данных

Цель: увидеть закономерности, выбросы, распределения, связи — «почувствовать» структуру данных.

Переход от таблицы → к картинке.



Визуальный анализ данных

Одномерный анализ


Временные ряды

Распределение
наблюдений и его виды

Многомерный анализ



Одномерный анализ



```
import matplotlib.pyplot as plt
plt.figure()
plt.hist(df['price'], bins=40)
plt.title('Histogram of price')
plt.xlabel('price'); plt.ylabel('count')
plt.show()
```


Что показывает:

распределение значений через частоты по бинам.

Когда использовать:

быстрый первичный взгляд на форму (асимметрия, хвосты, многомодальность). Чувствителен к ширине бинов.

Одномерный анализ



Что показывает:

сглаженную оценку плотности распределения.



Когда использовать:

понять форму без дискретизации на бины; удобен для сравнения распределений.

График KDE (Kernel Density Estimation) — это график, на котором представлена **сглаженная кривая, аппроксимирующая распределение данных**. В отличие от гистограммы, KDE не предполагает конкретное распределение данных (например, нормальное или экспоненциальное) — форму распределения оценивается непосредственно на основе точек данных.

```
from scipy.stats import gaussian_kde
vals = df['price'].values
xs = np.linspace(vals.min(), np.percentile(vals, 99.5), 400)
kde = gaussian_kde(vals[~np.isnan(vals)])
plt.figure()
plt.plot(xs, kde(xs))
plt.title('KDE of price')
plt.xlabel('price'); plt.ylabel('density')
plt.show()
```

Нормальное распределение



Определение:

- Симметричное «колоколоподобное» распределение,
- характеризуется средним (μ) и стандартным отклонением (σ),
- большинство значений сосредоточено около среднего.

Формальные свойства:


- 68% наблюдений — в пределах $\pm 1\sigma$, 95% — в пределах $\pm 2\sigma$, 99.7% — в пределах $\pm 3\sigma$

Примеры:

- Рост, вес, IQ, ошибки измерений, средние значения выборок.
- Если на величину влияют **много мелких случайных факторов** — результат часто близок к нормальному (центральная предельная теорема).


Нормальное распределение

Правостороннее (асимметричное) распределение — длинный хвост вправо



**Длинный хвост вправо;
типично для цен, доходов,
просмотров.**


Левостороннее распределение — длинный хвост влево



**Зеркально противоположное, редкое,
встречается при ограничении сверху
(например, рейтинг ≤ 5).**


Ненормальное распределение

Бимодальное распределение — два выраженных пика



**Два пика, отражает
смещение двух групп
(например, муж./жен. рост).**


Равномерное распределение — все значения равновероятны



**Все значения равновероятны;
часто искусственное
распределение.**


Ненормальное распределение

Экспоненциальное распределение — быстрое убывание от нуля




**Быстрое убывание; время
до события, интервалы
между запросами**

Парето (heavy-tailed) — тяжёлые хвосты, редкие экстремальные значения



**Тяжёлые хвосты; редкие,
но экстремальные значения
(80/20, трафик, продажи).**


Одномерный анализ



Что показывает: медиану, IQR (Q1–Q3), «усы», выбросы.

Когда использовать: быстрые сравнения распределений между группами.

```
cats = sorted(df['category'].unique())
grouped = [df.loc[df['category']==c, 'price'].dropna().values
plt.figure()
plt.boxplot(grouped, labels=cats)
plt.title('Boxplot of price by category')
plt.xlabel('category'); plt.ylabel('price')
plt.show()
```




Что показывает: долю наблюдений $\leq x$ (нарастающая функция).

Когда использовать: сравнение распределений без бинов; легко читать медиану и квантили.

```
x_ecdf, y_ecdf = ecdf(df['price'])
plt.figure()
plt.plot(x_ecdf, y_ecdf)
plt.title('ECDF of price')
plt.xlabel('price'); plt.ylabel('proportion ≤ x')
plt.show()
```


Одномерный анализ



Что показывает: частоты или доли категорий.

Когда использовать: дискретные/категориальные переменные, сравнение популярности значений.

```
counts = df['category'].value_counts().sort_index()
plt.figure()
plt.bar(counts.index, counts.values)
plt.title('Category frequencies')
plt.xlabel('category'); plt.ylabel('count')
plt.show()
```




Что показывает: форму распределения по группам (как два зеркальных KDE) + можно отметить медиану/среднее.

Когда использовать: когда важна форма/многомодальность внутри категории.

```
plt.figure()
plt.violinplot(grouped, showmeans=True, showmedians=True)
plt.title('Violin plot of price by category')
plt.xlabel('category (A=1, B=2, C=3)'); plt.ylabel('price')
plt.show()
```


Многомерный анализ



Что показывает: форму и силу связи между двумя числовыми переменными.

Когда использовать: базовая проверка линейности/нелинейности, выбросов и кластера.

```
plt.figure()
plt.scatter(df['x'], df['y'], alpha=0.5)
plt.title('Scatter: y vs x')
plt.xlabel('x'); plt.ylabel('y')
plt.show()
```





Что показывает: плотность точек в области (агрегация в шестиугольные бины).

Когда использовать: при большом числе наблюдений, когда scatter превращается в «ковёр».

```
plt.figure()
hb = plt.hexbin(df['x'], df['y'], gridsize=30)
plt.title('Hexbin: y vs x')
plt.xlabel('x'); plt.ylabel('y')
plt.colorbar(hb, label='counts')
plt.show()
```

Временные ряды



Временные ряды

1) Синтетический дневной ряд (2 года)

```
dates = pd.date_range("2024-01-01", periods=730, freq="D")
t = np.arange(len(dates))
trend = 0.02 * t
season_week = 2.5 * np.sin(2 * np.pi * t / 7)
season_year = 4.0 * np.sin(2 * np.pi * t / 365)
noise = np.random.normal(0, 1.2, size=len(dates))
y = 20 + trend + season_week + season_year + noise
ts = pd.Series(y, index=dates, name="value")
```

2) Линейный график


```
plt.figure(); plt.plot(ts.index, ts.values)
plt.title("Временной ряд: дневные значения")
plt.xlabel("Дата"); plt.ylabel("Значение"); plt.xticks(rotation=30);
plt.tight_layout(); plt.show()
```

3) Ресемплинг до недельного среднего


```
weekly = ts.resample("W").mean()
plt.figure(); plt.plot(weekly.index, weekly.values, marker="o",
linewidth=1.5)
plt.title("Ресемплинг: недельные средние")
plt.xlabel("Дата (недели)"); plt.ylabel("Среднее за неделю");
plt.xticks(rotation=30); plt.tight_layout(); plt.show()
```

4) Скользящее среднее (сглаживание тренда)

```
roll = ts.rolling(window=28, center=True, min_periods=1).mean()
plt.figure(); plt.plot(ts.index, ts.values, alpha=0.35, linewidth=1);
plt.plot(roll.index, roll.values, linewidth=2)
plt.title("Скользящее среднее (окно 28 дней) поверх сырых")
plt.xlabel("Дата"); plt.ylabel("Значение"); plt.xticks(rotation=30);
plt.tight_layout(); plt.show()
```



Временные ряды




5) Первая разность (подсказка к стационарности)

```
diff1 = ts.diff()
plt.figure(); plt.plot(diff1.index, diff1.values)
plt.title("Первая разность ряда")
plt.xlabel("Дата"); plt.ylabel("Δ значение"); plt.xticks(rotation=30);
plt.tight_layout(); plt.show()
```

6) Сезонный профиль по дню недели

```
weekday_mean = ts.groupby(ts.index.weekday).mean()
labels = ["Пн", "Вт", "Ср", "Чт", "Пт", "Сб", "Вс"]
plt.figure(); plt.bar(labels, weekday_mean.values)
plt.title("Средний профиль по дням недели")
plt.xlabel("День недели"); plt.ylabel("Среднее значение"); plt.tight_layout();
plt.show()
```



Переходим к практике





Более детальное погружение
в визуализацию в блоке


4. Визуализация данных (2 занятия)

20, 22 октября в 20.30



Статистический анализ

Цель: перейти от «вижу на графике»
к «могу измерить и сравнить» —
к количественно подтвердить
наблюдения.



Статистический анализ

Меры разброса

Форма распределения

Показатели
центральной тенденции

Доверительные интервалы и
оценка независимых выборок

Корреляция

Групповые статистики


Показатели центральной тенденции

Метрика	Что показывает	Формула / Метод	Когда применять
Среднее (mean)	«центр масс» данных	<code>df['col'].mean()</code>	без выбросов
Медиана (median)	значение посередине	<code>df['col'].median()</code>	устойчиво к выбросам
Мода (mode)	наиболее частое значение	<code>df['col'].mode()</code>	категориальные данные

```
import pandas as pd
import numpy as np

# Пример: df['price']
mean_ = df['price'].mean()
median_ = df['price'].median()
mode_ = df['price'].mode().iloc[0] if not df['price'].mode().empty else np.nan

print(f"mean={mean_:.2f}, median={median_:.2f}, mode={mode_:.2f}")
```




Меры разброса

Метрика	Объяснение	Примечание
Размах (range)	max – min	грубо
Дисперсия (var)	среднее квадр. отклонение	чувствит. к выбросам
СКО (std)	корень из дисперсии	«в среднем отклоняется на...»
IQR	Q3 – Q1	robust
MAD	среднее отклонение от медианы	robust-альтернатива std

```
q1, q3 = df['price'].quantile([0.25, 0.75])
iqr = q3 - q1
mad = (df['price'] - df['price'].median()).abs().mean()


print(
    "range:", df['price'].max() - df['price'].min(),
    "var:", df['price'].var(ddof=1),
    "std:", df['price'].std(ddof=1),
    "IQR:", iqr,
    "MAD:", mad
)
```



Форма распределения

Показатель	Что описывает	Интерпретация
Skewness	асимметрия	>0 хвост вправо, <0 влево
Kurtosis	«острота»	>0 острее нормального

```
skew = df['price'].skew()
kurt = df['price'].kurt()
print(f"skew={skew:.3f}, kurtosis={kurt:.3f}")
```



Корреляция признаков


Коэффициент	Для чего	Диапазон	Устойчивость
Пирсон	Линейная связь	$[-1,1]$	Чувствителен к выбросам
Спирмен	Монотонная (ранговая)	$[-1,1]$	Устойчивее
Кендалл	Согласованность рангов	$[-1,1]$	Надёжен при малых n

```
import matplotlib.pyplot as plt

cols = ['price', 'views', 'rating'] # подставь свои числовые
corr_p = df[cols].corr(method='pearson')
corr_s = df[cols].corr(method='spearman')


print("Pearson:\n", corr_p.round(3))
print("\nSpearman:\n", corr_s.round(3))

plt.imshow(corr_p, vmin=-1, vmax=1, aspect='auto')
plt.xticks(range(len(cols)), cols, rotation=45)
plt.yticks(range(len(cols)), cols)
plt.colorbar()
plt.title("Корреляция (Пирсон)")
plt.tight_layout(); plt.show()
```



Опасности интерпретации корреляции

Риск	Пример	Как защититься
Корреляция $\neq$ причинность	Мороженое $\leftrightarrow$ утопления	Искать третью переменную
Скрытые группы (Симпсон)	Общий тренд «плюс», в подгруппах «минус»	Стратифицировать
Выбросы тянут r	Одна leverage-точка	Робастные метрики, Спирмен




Групповые статистики

Задача	Что делаем	Визуализация
Сводка по категориям	<code>groupby().describe()</code>	bar / box / violin
Разница средних	<code>groupby().mean()</code>	bar + error bars
Сравнение распределений	<code>groupby()</code> по категориям	box/violin


```
g = df.groupby('category')['price']
print(g.describe().round(2))

# Средние по категориям + «усики» (std)
mean_by_cat = g.mean()
std_by_cat = g.std()

import matplotlib.pyplot as plt
cats = mean_by_cat.index.astype(str)
plt.bar(cats, mean_by_cat.values, yerr=std_by_cat.values)
plt.title("Средняя цена по категориям  $\pm 1\sigma$ ")
plt.xlabel("category"); plt.ylabel("mean price")
plt.show()
```



Доверительный интервал



```
from scipy import stats
import numpy as np


x = df['price'].dropna()
n = len(x)
mean, s = x.mean(), x.std(ddof=1)
tcrit = stats.t.ppf(0.975, df=n-1)
ci = (mean - tcrit*s/np.sqrt(n), mean + tcrit*s/np.sqrt(n))
print(f"mean={mean:.2f}, 95% CI={ci}")
```

Что показывает:


диапазон, в котором с заданной вероятностью (обычно 95%) находится **истинное среднее** признака.

Зачем нужен:

позволяет оценить **надёжность среднего** — насколько оно устойчиво, если измерить данные заново.



t-тест для двух независимых групп



Что делает:

проверяет, есть ли **значимая разница средних** между двумя группами (например, мужчины/женщины, до/после).


Нулевая гипотеза (H_0): $\mu_1 = \mu_2$

Если $p < 0.05 \rightarrow$ разница статистически значима.

```
from scipy.stats import ttest_ind

A = df[df['group']=='A']['metric'].dropna()
B = df[df['group']=='B']['metric'].dropna()

t, p = ttest_ind(A, B, equal_var=False)
print(f"t={t:.2f}, p={p:.3f}")
```




Переходим к практике



Работа с временными рядами

Цель: познакомить с основами анализа данных во времени: тренды, циклы, сезонность, выбросы, ресемплинг, скользящее среднее.



Временные ряды

Определение

Визуализация
временных рядов

Стационарность
временных рядов

Временные ряды: определение


Временной ряд (Time Series) — это последовательность наблюдений, упорядоченных по времени.

Пример: продажи по дням, число просмотров в неделю, температура по часам.


Главное отличие от «плоских» данных:

- зависимость наблюдений от времени (t , $t-1$, $t+1$);
- наличие трендов, циклов и сезонности;
- порядок записей имеет смысл (нельзя просто перемешать строки).

Типичные задачи: прогноз, аномалии, сезонные паттерны, влияние событий



Визуализация временных рядов




Line plot — базовое представление изменения метрики.

Rolling mean (скользящее среднее) — сглаживает колебания и показывает тренд.

Decomposition — разложение ряда на компоненты:

- **trend** (долгосрочная динамика),
- **seasonality** (повторяющиеся циклы),
- **residual** (шум).



```
from statsmodels.tsa.seasonal import seasonal_decompose
```

```
df['rolling'] = df['sales'].rolling(7).mean()  
plt.plot(df['date'], df['sales'], alpha=0.4)  
plt.plot(df['date'], df['rolling'], color='red')  
plt.title("Скользящее среднее (7 дней)")  
plt.show()
```

```
result = seasonal_decompose(df.set_index('date')['sales'], model='additive', period=7)  
result.plot()  
plt.show()
```


Понятие стационарности

Стационарный ряд — это ряд, у которого:


- среднее и дисперсия **не меняются во времени**,
- нет тренда или сезонности.

Нестационарный ряд — трендовый или сезонный, где поведение в начале $\neq$ поведению в конце.

Почему важно: большинство статистических и ML-моделей (ARIMA, линейная регрессия) требуют стационарности.



Стационарный ряд



Нестационарный ряд

Понятие стационарности

ADF (Augmented Dickey–Fuller)

```
from statsmodels.tsa.stattools import adfuller

x = df['value'].dropna()
result = adfuller(x)
print("ADF Statistic:", result[0])
print("p-value:", result[1])

if result[1] < 0.05:
    print("✅ Ряд стационарный (отклоняем H₀)")
else:
    print("❌ Ряд нестационарный (не отклоняем H₀)")
```

KPSS (Kwiatkowski–Phillips–Schmidt–Shin)

```
from statsmodels.tsa.stattools import kpss

x = df['value'].dropna()
stat, p, lags, crit = kpss(x, regression='c') # 'c' = только константа
print("KPSS Statistic:", stat)
print("p-value:", p)

if p < 0.05:
    print("❌ Ряд нестационарный (отклоняем H₀)")
else:
    print("✅ Ряд стационарный (не отклоняем H₀)")
```

Интерпретация:

$p < 0.05 \rightarrow$ ряд **стационарен**

$p \geq 0.05 \rightarrow$ ряд **нестационарен**




Избавление от нестационарности

```
df['diff'] = df['value'].diff()  
result = adfuller(df['diff'].dropna())  
print("ADF p-value после разности:", result[1])
```


Обычно **первая разность** (или логарифм + разность) делает ряд стационарным:

```
df['log_diff'] = np.log(df['value']).diff()
```



Работа с выбросами и аномалиями

Цель: научиться эффективно
находить и устранять выбросы



Выбросы и аномалии

Определение и причины

Методы устранения
выбросов

Визуальные методы
определения выбросов

Статистические методы
определения выбросов

Выбросы: что это и зачем их искать

Выброс (outlier) — это наблюдение, **существенно отличающееся от большинства данных**, Оно может быть вызвано ошибкой, исключительным случаем или новым паттерном.




Продам кусочек истории Макдака
986 000 Р

• Кропоткинская, 6–10 мин.

Только для ценителей истории Макдональдса в России. Отдам кусочек истории макдака в надёжные руки. Человеку, который понимает суть этого. Сырный соус из макдональдса (москва). Всё запечатано. Не вскрыт, не продырявлен. Порция соуса...

7 дней назад



BA3 (LADA) 2114 Samara 1.6 MT, 2012, 1 551 км
10 000 000 Р
от 172 143 Р в месяц

Можно в кредит

1 551 км, 1.6 MT (82 л.с.), хетчбэк, передний, бензин
• Площадь революции, до 5 мин.

Красивая машина.



РемонтШтангенциркуль Пар...
★★★★★ 3,1 · 141 отзыв




BA3 (LADA) 2114 Samara 1.6 MT, 2005, 1 120 км
10 000 000 Р

1 120 км, 1.6 MT (81 л.с.), хетчбэк, передний, бензин
• Площадь революции, до 5 мин.

Красивое авто.



РемонтШтангенциркуль Пар...
★★★★★ 3,1 · 141 отзыв



BA3 (LADA) 2114 Samara 1.6 MT, 2011, битый, 1 000 км
1 000 000 Р

Битый, 1 000 км, 1.6 MT (82 л.с.), хетчбэк, передний, бензин
• Народное Ополчение, до 5 мин.

Сдаю сам лично, полноценная однокомнатная квартира, есть кухонная техника, включая встроенную посудомойку, тостер, кофеварку, и посуду по мелочи, сплит система есть, водонагреватель подключен. Душевая кабина, стиральная...



РемонтШтангенциркуль Пар...
★★★★★ 3,1 · 141 отзыв



Причины возникновения выбросов

Категория	Примеры	Что делать
Ошибки данных	опечатки, дубли, неверные единицы (1000 вместо 10)	очистить / исправить
Разная природа наблюдений	регионы с разным масштабом продаж	сегментировать
Событийные всплески	акции, реклама, праздники	не убирать — анализировать
Редкие, но реальные случаи	VIP-покупатели, вирусные товары	оставить и учитывать
Системные проблемы	баг в сборе данных, сбой сенсора	исключить полностью



Последствия выбросов в выборке

Последствие	Влияние
Искажение среднего и дисперсии	средние метрики «уезжают» от реальных значений
Искажение результатов экспериментов	принятие некорректных решений об эксперименте
Неправильные выводы	ложные корреляции, неверные тренды
Проблемы в моделях	модели «учатся» на шуме, ошибки прогноза растут
Потеря доверия к данным	аналитические отчёты становятся непоследовательными

Визуальные методы обнаружения выбросов




Метод	Что показывает	Пример кода
Boxplot (ящик с усами)	границы IQR, точки вне диапазона	<code>sns.boxplot(x=df['price'])</code>

Boxplot





Визуальные методы обнаружения выбросов

Метод	Что показывает	Пример кода
Histogram / KDE	форму распределения, «длинные хвосты»	<code>sns.kdeplot(df['price'], fill=True)</code>



Визуальные методы обнаружения выбросов

Метод	Что показывает	Пример кода
Scatter plot	выбросы в многомерных данных	<code>sns.scatterplot(x='views', y='price', data=df)</code>




Статистические методы поиска выбросов

Z-Score (метод стандартных отклонений)

Выбросы = значения, где $|z| > 3$.

Используется для нормальных распределений.

```
from scipy import stats
z = np.abs(stats.zscore(df['price']))
df_outliers = df[z > 3]
```




Статистические методы поиска выбросов

IQR (межквартильный размах)

Диапазон = $Q1 - 1.5 \times IQR$, $Q3 + 1.5 \times IQR$.

Универсальный метод (работает для ненормальных распределений).



```
Q1, Q3 = df['price'].quantile([0.25, 0.75])
IQR = Q3 - Q1
df_out = df[(df['price'] < Q1 - 1.5*IQR) | (df['price'] > Q3 + 1.5*IQR)]
```

Статистические методы поиска выбросов

MAD (Median Absolute Deviation) — это статистическая мера изменчивости одномерной выборки количественных данных

```
from statsmodels import robust  
mad = robust.mad(df['price'])
```

Mean Absolute Deviation Formula

$$MAD = \frac{\sum |x_i - \bar{x}|}{n}$$

Статистические методы поиска выбросов

Тест Граббса (Grubbs' Test)

Суть: формальный статистический тест для проверки гипотезы о наличии **одного выброса** в нормально распределённых данных.

- H_0 : выбросов нет (все данные принадлежат одной нормальной выборке).
- H_1 : существует хотя бы один выброс.

Когда применять:

- выборка относительно мала ($n \leq 500$);
- распределение $\approx$ нормальное;
- нужно статистически подтвердить наличие выброса.


```
from outliers import smirnov_grubbs as grubbs

# найти наибольший выброс
max_outlier = grubbs.max_test_outliers(df['price'], alpha=0.05)
print(max_outlier)
```

Если $G > G_{crit} \rightarrow$ выброс подтверждён статистически.


Методы устранения выбросов

Подход	Когда применять	Пример
Удаление выбросов	если это ошибки или шум	<code>df = df[abs(z) < 3]</code>
Ограничение (winsorization)	если крайние значения редкие, но важны	<code>df['price'] = np.clip(df['price'], low, high)</code>
Замена на границы IQR	для количественных данных	заменить выбросы на Q1/Q3
Логарифмирование / нормализация	если «длинные хвосты»	<code>df['log_price'] = np.log1p(df['price'])</code>
Сегментация перед фильтрацией	если выбросы зависят от категории	применять IQR отдельно по группам



Работа с текстовой информацией

Цель: научиться эффективно работать с текстовой информацией



Текстовые данные

Определение и значение

Оценка тональности

Базовая предобработка

Использование
текстовых данных

Частотный анализ

Текстовые данные: определение

Источник	Пример	Что можно извлечь
Отзывы	«Быстрая доставка, но качество плохое»	тональность, длина, ключевые слова
Описание товара	«Новый iPhone 14, 128GB, гарантия 1 год»	категория, бренд, характеристики
Комментарии	«Куплю завтра, если будет скидка»	намерение, частота слов
Названия объявлений	«Продам ноутбук Asus в отличном состоянии»	тип объекта, состояние



Базовая предобработка текста



Этап	Шаг	Что делает	Код
1	Приведение к нижнему регистру	нормализация слов	<code>text.lower()</code>
2	Удаление пунктуации и цифр	чистка от символов	<code>re.sub(r'^a-zA-Za-яA-Я]','', text)</code>
3	Удаление стоп-слов	исключаем «и», «но», «это»	<code>from nltk.corpus import stopwords</code>
4	Лемматизация / стемминг	приведение слов к основе	<code>from pymorphy2 import MorphAnalyzer</code>
5	Токенизация	разбиваем на слова	<code>text.split()</code> или <code>nltk.word_tokenize()</code>


Частотный анализ слов и n-грамм

Основные подходы:

- **Униграммы (1-gram):** отдельные слова → частота.
- **Биграммы (2-gram):** устойчивые пары → «быстрая доставка», «плохое качество».
- **Триграммы (3-gram):** фразы → “в отличном состоянии”.

```
from sklearn.feature_extraction.text import CountVectorizer

vectorizer = CountVectorizer(ngram_range=(1,2), max_features=15)
X = vectorizer.fit_transform(df['clean_review'])
word_freq = dict(zip(vectorizer.get_feature_names_out(), X.toarray().sum(axis=0)))
print(word_freq)
```



Частотный анализ слов и n-грамм


WordCloud



```
from wordcloud import WordCloud

text = ' '.join(df['clean_review'])
wc = WordCloud(width=800, height=400, background_color='white').generate(text)
plt.imshow(wc, interpolation='bilinear')
plt.axis('off')
plt.title("Облако слов (WordCloud)")
plt.show()
```


Barplot



```
freq = pd.DataFrame(word_freq.items(), columns=['word', 'count'])
sns.barplot(data=freq.sort_values('count', ascending=False).head(10),
            x='count', y='word', palette='mako')
plt.title("ТОП-10 слов")
plt.show()
```

Оценка тональности текста

Анализ тональности (Sentiment Analysis) — это метод обработки текста, который определяет **отношение автора** (позитивное, негативное, нейтральное) по ключевым словам, контексту и структуре предложения.



Подход	Как работает	Преимущества
Словарный (лексиконный)	считает положительные/отрицательные слова из словаря	прост, интерпретируем
Машинное обучение	обучается на размеченных отзывах	точнее, можно адаптировать
Нейросетевой (BERT, RuBERT)	учитывает контекст и смысл	лучше всего на длинных текстах

Оценка тональности с TextBlob (англ.)

положительные отзывы → $\text{polarity} > 0$


отрицательные → $\text{polarity} < 0$

нейтральные → ≈ 0

```
from textblob import TextBlob

texts = ["Good product, very fast delivery",
         "Terrible quality and late shipping",
         "It's okay, nothing special"]

for t in texts:
    print(t, "→", TextBlob(t).sentiment.polarity)
```



Оценка тональности на русском

```
!pip install dostoevsky
from dostoevsky.tokenization import RegexTokenizer
from dostoevsky.models import FastTextSocialNetworkModel

tokenizer = RegexTokenizer()
model = FastTextSocialNetworkModel(tokenizer=tokenizer)


texts = [
    "Очень довольна покупкой, спасибо!",
    "Качество отвратительное, больше не закажу",
    "Средний сервис, могло быть лучше"
]

results = model.predict(texts, k=1)
for t, r in zip(texts, results):
    print(t, "→", r)
```




Оценка тональности на русском

Цель	Признак	Пример применения
Отслеживание качества сервиса	доля негативных отзывов	<code>df.groupby('region')['negative_share'].mean()</code>
Рекомендации товаров	средний sentiment по описанию	добавляем в ML-модель
Мониторинг бренда	динамика тональности по времени	line plot по дням
Классификация контента	sentiment как feature	feature в логистической регрессии



Использование текстовых данных

Цель	Признак / метод	Пример
Оценить “настроение” отзывов	sentiment score	<code>TextBlob</code> , <code>RuSentiment</code>
Построить тематическую модель	LDA / BERTopic	выявить темы (topic modeling)
Использовать тексты в ML	TF-IDF, Word2Vec, Embeddings	подать как вход модели
Считать “информативность” описаний	длина текста, уникальные слова	<code>len(text.split())</code> , <code>nunique()</code>



Q&A

Домашнее задание:
самостоятельно проработать
Датасет FoodPanda

