

Занятие №4

Очистка и подготовка датасета
к моделям и исследованиям


октябрь 2025



Дмитрий Кротов

И.о. Team Lead аналитиков опыта исполнителя
в Авито Подработка, аспирант.

- Alma mater: Финансовый университет при Правительстве РФ
- 5 лет в Аналитике (ex Avito Авто, Ozon)
- Преподаватель во внешней и внутренней Академии Аналитиков Авито
- Основатель и автор тг-канала Data dreamen
- Автор тг-канала Авито «Коммуналка аналитиков»



@DATA_DREAMEN


Структура занятий

Тема 1. Разведочный анализ данных

- Введение в работу с данными и разведочный анализ
- Статистический анализ и визуализация данных
- Углубленный EDA: статистический анализ, визуализация данных, аномалии и текстовые данные


Тема 2. Очистка и подготовка датасета

- Очистка и подготовка датасета к моделям и исследованиям



Сегментирование данных

Цель: научиться выделять логические сегменты данных и искать различия между ними.



Сегментирование данных

Определение

Визуализация

Группировка и агрегаты

Алгоритмическая сегментация

Виды сегментаций

Поведенческая сегментация

Сегментирование: определение


Сегментация — это процесс деления пользователей, объектов или наблюдений на **группы с похожими характеристиками** или поведением.

Примеры:

- пользователи из разных регионов,
- товары из разных категорий,
- клиенты с разной активностью,
- временные периоды (дни недели, часы),
- группы, найденные алгоритмом (кластеризация).

Зачем нужно:

- сравнить сегменты по ключевым метрикам,
- выявить “аномальные” группы (слишком успешные или проблемные),



Группировка и агрегаты

Задача	Метод	Код
Посчитать средние продажи по категориям	<code>groupby()</code>	<code>df.groupby('category')['sales'].mean()</code>
Построить таблицу по регионам и типу клиента	<code>pivot_table()</code>	<code>df.pivot_table(values='revenue', index='region', columns='client_type', aggfunc='mean')</code>
Вывести несколько метрик сразу	<code>agg()</code>	<code>df.groupby('region')['sales'].agg(['mean', 'sum', 'count'])</code>



Виды сегментации



Тип сегментации	Пример	Цель
Демографическая / категориальная	категория товара, пол, регион	сравнить средние метрики
Поведенческая	частота визитов, время удержания	выделить “активных” пользователей
Временная	день недели, месяц, сезон	оценить динамику активности
Ценовая / бизнес-сегменты	дорогие/дешёвые товары	проверить ценовую чувствительность
Алгоритмическая (кластеризация)	k-means, DBSCAN	найти естественные группы
RFM-сегментация	Recency, Frequency, Monetary	оценить “ценность” клиентов

Визуализация различий между сегментами



График	Для чего	Пример кода
barplot	сравнение средних по категориям	<code>sns.barplot(x='region', y='sales', data=df)</code>
boxplot / violinplot	распределения по группам	<code>sns.boxplot(x='category', y='price', data=df)</code>
heatmap	матрицы различий (например, корреляции по регионам)	<code>sns.heatmap(pivot_table, annot=True)</code>
facetgrid / subplots	сравнение распределений в разных сегментах	<code>sns.FacetGrid(df, col='region').map(sns.histplot, 'sales')</code>


Поиск «аномальных» сегментов

Как искать аномалии:

- сравнение метрик по сегментам с глобальными средними;
- вычисление z-score для средних по сегментам;
- визуализация через boxplot.

```
segment_perf = df.groupby('region')['conversion'].mean().sort_values()
plt.bar(segment_perf.index, segment_perf.values)
plt.title("Конверсия по регионам")
plt.show()
```

```
import numpy as np
g = df.groupby('region')['conversion'].mean()
z = (g - g.mean()) / g.std()
anomalies = z[abs(z) > 2]
print("Аномальные сегменты:", anomalies)
```



Алгоритмическая сегментация

Цель:

Показать, как выделять сегменты без заранее заданных категорий.

Суть метода:


- К-Means делит объекты на k кластеров, минимизируя расстояние до центров.
- Каждый кластер = группа объектов со схожими характеристиками.

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler


X = df[['views', 'price', 'conversion']].dropna()
X_scaled = StandardScaler().fit_transform(X)

kmeans = KMeans(n_clusters=3, random_state=42)
df['cluster'] = kmeans.fit_predict(X_scaled)

sns.scatterplot(x='views', y='price', hue='cluster', data=df)
plt.title("K-Means сегментация товаров")
plt.show()
```



Поведенческая сегментация: RFM-анализ



Что такое RFM?

— методика анализа клиентской базы на основании лояльности по следующим критериям:

R *Recency*, давность последней покупки

F *Frequency*, частота (общее количество) покупок

M *Monetary*, сумма денег, потраченных клиентом

Определение:

- **R (Recency)**: давность последней активности (меньше — лучше);
- **F (Frequency)**: частота действий (чем выше — тем ценнее)
- **M (Monetary)**: суммарная выручка или траты.




Сравнение сегментов и поиск инсайтов

Подход:


- 1) Сравнить средние метрики (доход, CTR, retention).
- 2) Визуализировать отличия (barplot, heatmap).
- 3) Сделать выводы — какие сегменты “сильные”, “слабые” или “перспективные”.
- 4) Сформулировать гипотезы: почему различия возникли и как можно использовать.

```
sns.boxplot(x='cluster', y='revenue', data=df)  
plt.title("Доход по сегментам (кластеризация)")  
plt.show()
```



Нормализация и стандартизация признаков

Цель: научиться приводить признаки к единому масштабу перед анализом или моделированием.



Нормализация и стандартизация признаков

Определение и значение

Другие методики

Методика нормализации

Этапы масштабирования

Методика стандартизации

Определения



Нормализация

преобразование значений признаков
в единый диапазон

Стандартизация

приведение данных к нулевому среднему
и единичному стандартному отклонению

Примеры

Признак	До	После нормализации	После стандартизации
Цена	2000–300000 ₺	0.01–1.00	-1.8 – 2.4
Просмотры	50–5000	0.00–1.00	-0.5 – 1.2

Значение

- чтобы признаки **не “перетягивали”** влияние из-за масштаба;
- для корректной работы **ML-моделей** (kNN, SVM, PCA, линейные модели);
- для **сравнения признаков между собой**.



Почему масштаб признаков важен

Признак
price 0–1 000 000

Признак
rating = 1–5

Без масштабирования модель "решает", что **price** гораздо важнее, потому что его численные значения больше.



Нормализация (Min-Max Scaling)

Формула

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Код

```
from sklearn.preprocessing import MinMaxScaler


scaler = MinMaxScaler()
df[['price_norm', 'views_norm']] = scaler.fit_transform(df[['price', 'views']])
```

Описание

Значение: нормализация сохраняет форму распределения, но **сжимает диапазон** всех значений в $[0,1]$.

Используется для:

- нейронных сетей,
- алгоритмов, чувствительных к масштабу расстояний (**kNN**, **KMeans**).



Стандартизация (Z-score scaling)

Формула

$$z = \frac{x - \mu}{\sigma}$$

Код

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
df[['price_std', 'views_std']] = scaler.fit_transform(df[['price', 'views']])
```

Описание

Цель: Показать, как центрировать признаки вокруг 0 и привести дисперсию к 1.

Интерпретация:

- среднее = 0
- стандартное отклонение = 1
- значения > 2 или $< -2 \rightarrow$ выбросы

Применяется в:

- линейных моделях,
- логистической регрессии,
- PCA,
- кластеризации (KMeans).



Другие методы масштабирования

Метод	Суть	Когда использовать
RobustScaler	использует медиану и IQR (устойчив к выбросам)	данные с выбросами
MaxAbsScaler	нормализует по максимальному абсолютному значению	когда данные уже центрированы
Log-трансформация	уменьшает влияние больших значений (“длинный хвост”)	при экспоненциальных распределениях
QuantileTransformer	приводит распределение к равномерному или нормальному	для сильно перекошенных данных

Сравнение методов


Метод	Диапазон	Устойчив к выбросам	Сохраняет форму распределения	Подходит для
Min-Max	[0, 1]			kNN, KMeans, NN
StandardScaler	среднее=0, $\sigma=1$	 нет		линейные модели
RobustScaler	центр по медиане		 не всегда	выбросы
Log-transform	зависит от данных		 искажает	длинные хвосты
Quantile	равномерное/нормальное			тяжёлые хвосты

Этапы

	Задача	Метод	Ключевая идея
1	Привести все признаки к единому масштабу	Min-Max	диапазон [0,1]
2	Центрировать данные и убрать влияние масштаба	StandardScaler	среднее 0, $\sigma = 1$
3	Уменьшить влияние выбросов	RobustScaler	медиана + IQR
4	Сгладить длинный хвост	Log-transform	уменьшает разброс
5	Проверить качество	boxplot / describe()	контроль диапазонов

Работа с категориальными признаками

Цель: научиться работать с категориальными признаками для анализа и моделирования



Работа с категориальными признаками

Определение

Методики кодирования

Виды признаков

Важность кодирования

Определения

Категориальный признак — это переменная, значения которой принадлежат конечному набору категорий (групп), а не непрерывному диапазону чисел.

Признак	Пример значений	Тип
region	Москва, Казань, Новосибирск	номинативный
device_type	desktop, mobile, tablet	номинативный
education_level	среднее, высшее, магистр	порядковый
rating_group	низкий, средний, высокий	порядковый

Виды категориальных признаков

Тип	Что означает	Пример	Как кодировать
Номинативный	категории без порядка	город, цвет	One-Hot Encoding
Порядковый (ordinal)	категории с логическим порядком	уровень образования	Ordinal Encoding
Бинарный	две категории	“Да / Нет”, “Муж / Жен”	0 / 1
Смешанный (multi-level)	вложенные категории	“Регион → Город”	кодирование + иерархия

Разные типы категориальных признаков



разные способы кодирования.

Важность кодирования


Машинное обучение и статистика работают
с числами, а не с текстом.

Модель не может “понять”, что это категории, поэтому
мы должны **перевести категории в числовой вид**.

```
region = ["Москва", "Казань", "Тверь"]
```

Важно:

- нельзя использовать `LabelEncoder` бездумно (иначе создаётся ложный “порядок” категорий),
- методы выбираются исходя из задачи и модели.



Основные методы кодирования


Метод	Суть	Пример	Используется в
Label Encoding	заменяет категории числами (0,1,2,...)	“mobile”→0, “desktop”→1	деревья (DecisionTree, RF)
One-Hot Encoding	создаёт отдельный столбец для каждой категории (0/1)	“device_mobile”=1	линейные модели, регрессия
Ordinal Encoding	задаёт порядок категорий вручную	“низкий”=1, “высокий”=3	упорядоченные признаки
Target Encoding	заменяет категорию средним целевой метрики	“регион” → средний CTR	продвинутые ML-модели
Frequency Encoding	кодирует частотой встречаемости категории	“Москва”=0.3, “Тверь”=0.05	быстрый baseline

One-Hot Encoding

```
import pandas as pd
df = pd.DataFrame({
    'device': ['mobile', 'desktop', 'mobile', 'tablet'],
    'city': ['Москва', 'Казань', 'Тверь', 'Москва']
})
```

```
df_encoded = pd.get_dummies(df, columns=['device', 'city'])
print(df_encoded)
```

device_mobile	device_desktop	device_tablet	city_Москва	city_Казань	city_Тверь
1	0	0	1	0	0
0	1	0	0	1	0
1	0	0	0	0	1
0	0	1	1	0	0



Label и Ordinal Encoding

Label Encoding (без порядка)


```
from sklearn.preprocessing import LabelEncoder  
le = LabelEncoder()  
df['device_label'] = le.fit_transform(df['device'])
```

mobile=2, desktop=0, tablet=1 → значения **произвольные**, поэтому это безопасно только для деревьев решений.

Ordinal Encoding (с порядком)

```
from sklearn.preprocessing import OrdinalEncoder  
encoder = OrdinalEncoder(categories=[['низкий', 'средний', 'высокий']])  
df['rating_level'] = encoder.fit_transform(df[['rating']])
```


OrdinalEncoder — “смысловой порядок”



Target Encoding

Заменяем категорию на **среднее значение целевой переменной** (например, CTR, конверсия, цена).

```
target_mean = df.groupby('region')['conversion'].mean()  
df['region_te'] = df['region'].map(target_mean)
```




Ошибки и лучшие практики

Ошибка	Почему плохо	Как правильно
LabelEncoder на номинативных данных	создаёт ложный порядок	One-Hot или Target Encoding
Кодирование до train/test split	“утечка” статистики	кодировать только на train
Слишком много категорий (100+)	слишком много столбцов	объединить редкие категории, Frequency Encoding
Не учитывать категорию при анализе выбросов	искажение статистики	рассматривать выбросы внутри категории

Фича-инжиниринг и подготовка к моделированию

Цель: рассмотреть, что подготовка данных к моделированию — это не просто «очистка», а создание информативных признаков, которые улучшают качество модели



Фича-инжиниринг и подготовка к моделированию

Определение

Feature selection

Feature generation

Преобразование признаков

Что такое фича-инжиниринг

Фича-инжиниринг (Feature Engineering) — процесс создания, преобразования и отбора признаков, чтобы модель лучше “понимала” закономерности в данных.


Исходный признак	Новая фича	Смысл
price	log_price	убираем перекосяс распределения
date	day_of_week, month	добавляем временной контекст
city	region_avg_price	добавляем региональную особенность
views, messages	$\text{conversion} = \text{messages} / \text{views}$	создаём бизнес-метрику

«Хорошие признаки часто важнее, чем сама модель»



Чек-лист этапов подготовки

Этап	Что делаем	Инструменты
Очистка	удаление пропусков, дубликатов, выбросов	<code>dropna()</code> , <code>fillna()</code> , <code>duplicated()</code>
Кодирование категориальных	one-hot, label, target encoding	<code>pd.get_dummies()</code> , <code>sklearn.preprocessing</code>
Масштабирование числовых	нормализация, стандартизация	<code>MinMaxScaler</code> , <code>StandardScaler</code>
Создание новых признаков	агрегаты, комбинации, логарифмы	<code>groupby</code> , <code>np.log()</code> , <code>feature crosses</code>
Отбор признаков	удаление лишних / коррелированных	<code>corr()</code> , <code>SelectKBest</code>
Проверка готовности датасета	баланс классов, типы данных	<code>df.info()</code> , <code>df.describe()</code>




Создание новых признаков (feature generation)

Тип	Пример	Код
Комбинации признаков	CTR = клики / показы	<code>df['ctr'] = df['clicks'] / df['views']</code>
Агрегаты по группам	средняя цена по региону	<code>df['avg_region_price'] = df.groupby('region')['price'].transform('mean')</code>
Временные признаки	день недели, час	<code>df['weekday'] = df['date'].dt.dayofweek</code>
Текстовые признаки	длина описания	<code>df['text_len'] = df['description'].str.len()</code>
Категориальные комбинации	“регион+категория”	<code>df['region_category'] = df['region'] + "_" + df['category']</code>


Преобразование признаков

Проблема	Решение	Пример
Длинный “хвост” распределения	Логарифмирование	<code>df['log_price'] = np.log1p(df['price'])</code>
Очень большие значения	Масштабирование	<code>StandardScaler</code>
Категории в тексте	Кодирование	<code>OneHotEncoder</code> , <code>TargetEncoder</code>
Признаки разных единиц	Нормализация	<code>MinMaxScaler</code>
Много коррелированных признаков	PCA / удаление	<code>df.corr()</code> → drop




Отбор признаков (feature selection)

Метод	Принцип	Пример
Корреляция (heatmap)	исключаем признаки с	corr
SelectKBest	выбираем К самых информативных	SelectKBest(score_func=f_regression, k=10)
Model-based selection	используем важности модели	RandomForest.feature_importances_
PCA (анализ главных компонент)	уменьшаем размерность	PCA(n_components=5)



EDA как источник гипотез для будущего моделирования

Цель: научиться извлекать идеи
и гипотезы из данных



Гипотеза: определение

Гипотеза = наблюдение + объяснение + предположение о механизме


Гипотеза — это **обоснованное предположение** о закономерности в данных, которое можно проверить.

В EDA гипотезы рождаются из наблюдений на графиках, статистиках, сегментах.

Пример:

«Рост просмотров связан с ценой товара»

«Пользователи, активные в первые 3 дня, остаются дольше»



Типовые источники гипотез в EDA

Источник	Пример наблюдения	Возможная гипотеза
Тренды во времени	После рекламных кампаний всплески продаж	«Реклама повышает продажи на X%»
Сегменты	Женщины покупают чаще мужчин	«Пол влияет на конверсию»
Тексты / отзывы	Частое слово “доставка” связано с низкой оценкой	«Проблемы с доставкой → ↓ рейтинг»
Корреляции признаков	CTR и цена отрицательно связаны	«Чем дороже товар, тем меньше кликов»
Аномалии	Всплески просмотров в ночь на выходные	«Ночные акции или накрутки»

Структура формулировки гипотезы

Элемент	Вопрос	Пример
Признак (feature)	Что может влиять?	цена, категория, время
Предположение (hypothesis)	Какое влияние предполагается?	высокая цена снижает CTR
Метрика (target)	Что измеряем?	клики, покупки
Проверка (test)	Как проверить?	t-тест, корреляция, регрессия
Вывод (result)	Подтверждается или нет?	$p < 0.05$, отрицательный эффект

Приоритизация гипотез

RICE SCORING FRAMEWORK

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed diam nonummy euismod tincidunt ut laoreet dolore magna aliquam erat volutpat. Ut wisi enim ad minim veniam sediam



Метод MoSCoW

Must Have

То, что обязательно необходимо сделать. Без этих задач не будет работать продукт или без этих характеристик товара клиенты не будут его покупать. Этот вид аналогичен базовому виду в методе Кано.

Should Have

Эти задачи или характеристики продукта имеют решающее значение для успеха релиза. Их нужно выполнить сразу после выполнения задач Must Have.

Could Have

Это желательные требования. Их можно сделать, когда появится ресурсы.

Would Like

Эти задачи можно проигнорировать или отложить на долгий срок, так как их отсутствие не влияет на продукт или релиз.

Примеры

Гипотеза: улучшение карточки товара


Этап	Описание
Наблюдение (EDA):	объявления с ≥ 5 фото имеют CTR выше на 20%.
Гипотеза:	“Если увеличить минимальное количество фото при создании объявления до 5, CTR карточек повысится.”
Продуктовое решение:	изменить интерфейс загрузки фото — сделать рекомендацию/требование ≥ 5 изображений.
A/B-тест:	A — текущий порог (≥ 1 фото), B — новый порог (≥ 5 фото).
Метрика:	CTR карточки, конверсия в сообщение/звонок.
Ожидаемый результат:	B-группа показывает рост CTR и конверсии.

Гипотеза: всплеск просмотров объявлений в конкретные даты

Этап	Описание
Наблюдение (EDA):	Временной ряд просмотров объявлений показывает резкий пик в первые сутки после публикации — просмотры выше среднего в 5 раз.
Интерпретация:	Это может быть “boost” от алгоритма ранжирования, а может — просто эффект новизны.
Гипотеза:	«Подсветка новых объявлений (boost в ленте на первые 24ч) увеличивает общий CTR и конверсию»
Продуктовое решение:	запустить эксперимент: часть новых объявлений показывать с меткой «Новое» / «Появилось сегодня».

Принципы оформления результатов EDA

Цель: научиться оформлять
результаты разведочного анализа
данных (EDA) понятно,
воспроизводимо и визуально чисто



Структура хорошего EDA-ноутбука

Раздел	Что включает	Пример / советы
Заголовок и цель анализа	краткое описание задачи, источника данных, периода, целей	«EDA по продажам Авито (2024), цель — понять структуру просмотров и выявить тренды»
Импорт библиотек и настройка окружения	импорт pandas, numpy, matplotlib, seaborn, настройка шрифтов и стилей	не более 10 строк, всё — в одном блоке
Загрузка и первичная информация	<code>df.info()</code> , <code>df.describe()</code> , форма, типы, метаданные	добавить краткий вывод текстом
Очистка и подготовка данных	работа с пропусками, дубликатами, типами	сохраняйте чистый df в новую переменную
Основной анализ (EDA)	статистика, визуализация, сегментация, корреляции	каждый блок → подпись и мини-вывод
Выводы и гипотезы	основные наблюдения и потенциальные гипотезы	“Цены категории В выше на 25%, возможно, это влияет на CTR”

Визуальная культура графиков

Принцип	Что делать	Пример
Подписи и заголовки	каждый график должен иметь <code>title</code> , <code>xlabel</code> , <code>ylabel</code>	<code>plt.title("Распределение просмотров по категориям")</code>
Читабельность	не больше 3–4 цветов, подписать оси и легенды	<code>plt.legend()</code>
Сравнение на одной шкале	если сравниваешь группы — держи одинаковые оси	<code>sharey=True</code> при subplots
Размер графиков	минимум (6,4), если больше 1 subplot — добавь <code>tight_layout()</code>	
Комментарии под графиками	короткий текст “что видно”	“В категории С медиана просмотров выше, чем в А и В”

Интерпретация и оформление ВЫВОДОВ

Как оформлять результаты:

1. Формулируйте **осмысленные заголовки** («Цены растут по выходным» вместо «Boxplot»).
2. После каждого блока пишите **1–2 предложения вывода**.
3. Подчеркивайте **причинно-следственные вопросы** («возможно, влияет реклама», «следует проверить гипотезу»).
4. В конце давайте **сводный список гипотез / инсайтов**.

