




Занятие 2. Подходы к созданию моделей ИИ на данных

Александр Валерьевич Бухановский





- 1) Определение целеполагания системы ИИ
- 2) Подготовка и первичный анализ данных для обучения системы ИИ
- 3) Обоснование выбора класса модели ИИ
- 4) Конструирование модели ИИ
- 5) Технологическая реализации модели ИИ
- 6) Обучение модели ИИ на данных
- 7) Оценка качества модели ИИ
- 8) Разработка методики применения системы ИИ (например, в целях поддержки принятия решений)

ІТМО

ПОДГОТОВКА
И АНАЛИЗ ДАННЫХ
ДЛЯ СИСТЕМ ИИ



Генеральная совокупность



Случайный отбор, $N=5$



Гнездовой отбор, $N=11$




Расслоенный (типический) отбор $N=2 \times 3$



4 V - Value

И ещё + 13 V






The FOUR V's of Big Data

From traffic patterns and music downloads to web history and medical records, data is recorded, stored, and analyzed to enable the technology and services that the world relies on every day. But what exactly is big data, and how can these massive amounts of data be used?

As a leader in the sector, IBM data scientists break big data into four dimensions: **Volume, Velocity, Variety and Veracity**

Depending on the industry and organization, big data encompasses information from multiple internal and external sources such as transactions, social media, enterprise content, sensors and mobile devices. Companies can leverage data to adapt their products and services to better meet customer needs, optimize operations and infrastructure, and find new sources of revenue.

By 2015
4.4 MILLION IT JOBS will be created globally to support big data, with 1.9 million in the United States



Sources: McKinsey Global Institute, Twitter, Cisco, Gartner, EMC, SAS, IBM, MEPEEC, QAS

Большие данные: аллегория «жемчужного зерна»

- 1) Очень малый «КПД» данных
- 2) Разнородность источников
- 3) Фрагментарность покрытия
- 4) Неструктурированность
- 5) Информационное загрязнение
- 6) Сложность доступа

Традиционная база данных

От гигабайт до терабайт

Централизованный

Структурирована

Вертикальная модель

Сильная

Характеристика

Объем информации

Способ хранения

Структурированность данных

Метод хранения и обработки данных

Взаимосвязь данных

База больших данных

От петабайт до эксабайт

Децентрализованный

Структурирована или неструктурирована



Горизонтальная модель

Слабая



Большие данные (Big Data) – замена активного эксперимента разрозненными пассивными наблюдениями

Задача: преобразовать данные в датасеты (dataset)!




Построение модели движения транспорта в города на основе данных камер видеонаблюдения

Источник данных: городские камеры видеонаблюдения и некоторые дополнительно установленные камеры.


Результат: Водители, зная о камерах, снижали скорость до пороговых минимальных значений (затем снова разгонялись). В итоге, сама модель системно занижала скорость потока

Способ сбора и измерения данных кардинальным образом влияет на качество модели ИИ


Категориальные данные



Выбросы в данных




Несбалансированность




Пропуски в данных

RACE	INCOME	CREDIT_SCORE
majority	upper class	43%
minority	middle class	21%
	Other (3526)	35%
majority	upper class	0.7627979410816134
majority	upper class	0.7961748462456987
majority	poverty	0.6805942795073384
majority	upper class	0.4177139816231188
majority	working class	0.4095135306516067
majority	middle class	0.5532600531952381
majority	poverty	0.3309502618581893
majority	poverty	0.5006306604427161
majority	middle class	0.5519701813636283
majority	middle class	0.6269960497386653
majority	poverty	0.29479748077199674
majority	middle class	0.5519504952618395
majority	upper class	0.649820471216227

Разный масштаб



Наведенные взаимосвязи



Выявление негодяев на фотографиях в социальных медиа



Обучающий датасет: 1 : 1



В реальных условиях: 1000 : 1

Если на обучающей выборке ИИ будет обнаруживать негодяя с вероятностью 90%, и ошибка ложноположительного результата – 1%, то в реальных условиях на каждого выявленного негодяя **~9 невинных дедушек**

Не все датасеты, собранные в идеальных условиях, соответствуют условиям эксплуатации



(0.3, 1.8, 1.1, 2.6, -0.3, ...)




Подходы к разметке неструктурированных данных (текст, изображения, видео и пр.):

- ❖ Собственная команда обученных разметчиков
- ❖ Аутсорс (сторонняя команда)
- ❖ Краудсорс (общественная активность по сбору данных)
- ❖ Иные (более слабые) алгоритмы ИИ
- ❖ Синтетические данные

Пример геймифицированной краудсорс разметки -

<https://eyewire.org/>

- ❖ Генерация примеров на основе имеющихся: например, обучаем генерировать заданный класс
- ❖ **Style transfer (перенос стиля)**: обучаем модель переносить изображения из одного класса в другой и обратно
- ❖ Использование **причинно-следственных симуляторов** и игровых движков



Ключевые проблемы синтетики:

- ❖ Вариативность
- ❖ Физичность
- ❖ Интерпретируемость



Синтетические данные могут иметь ошибки как I, так и II рода (т.е. привносить артефакты, которых никогда не бывает в жизни)



**Один сломал
Второй потерял...**



Малая выборка: когда данных настолько мало, что обобщения на их основе, сделанные формальными методами, теряют силу

Точной границы нет, но...:


$N < 30$ – для базовой статистики

$N < 100$ – для статистических критериев

$N < 500$ - для многомерных данных

Редкие события: крайние члены выборок (минимальные или максимальные значения)

Решение проблемы: строить модель редких событий на основе вообще всех данных (а не только редких)



РАБОЧИЙ !

ВЛАДЕЙ ОРУЖИЕМ.


октябрьская революция дала
тебе фабрики и свободный труд.

зорко стереги, чтобы не
подняла голову контрреволюция.

всюду и всегда будь на страже
твоих завоеваний.

залог твоей победы -

**ВСЕОБЩЕЕ ВОЕННОЕ
ОБУЧЕНИЕ.**



ІТМО

**КЛАССИЧЕСКИЕ
ПОДХОДЫ
МАШИННОГО
ОБУЧЕНИЯ ДЛЯ
СИСТЕМ ИИ**


С учителем:

данные
заранее
размечены



Без учителя:

нужно учитывать
интуитивно
понятные
свойства данных



Процедуры классификации:


- kNN (k-ближайших соседей)
- SVM (опорных векторов)
- Kernel-Trick (преобразования ядер)
- Деревья решений и случайный лес
- Логистическая регрессия
- Линейный дискриминантный анализ

Процедуры регрессии:

- Линейная регрессия для гауссовых величин (kriging)
- Гребневая (ridge) регрессия
- Регрессия на главных компонентах


Процедуры снижения размерности:

- Метод главных компонент (PCA)
- Факторный анализ (FA)
- Метод канонических корреляций




Наследство математической статистики (важна вероятностная модель!)

Регрессия: установить количественную связь X и Y , чтобы по новым X предсказать ожидаемые Y



Сильные зависимости между X и Y

Классификация: установить групповые закономерности для возможных комбинаций (X, Y)



Слабые зависимости, сильная неоднородность



Связь пространственных и временных масштабов: чтобы прогнозировать на 3 суток, надо иметь данные по северной Атлантике, а не только Балтийскому морю

Почему прогноз наводнений в Санкт-Петербурге по данным измерения уровня в Балтике возможен на всего на **12 часов** вперед, а по гидродинамической модели – на **3 суток**?





Это еще **НЕ** обучение:

$$\varepsilon = y - f(x, \theta), \quad \varepsilon \xrightarrow{\theta} \min$$

Данные y


Смысл обучения модели -> минимизация ошибки на дополнительных данных (**минимизация эмпирического риска**):

$$\varepsilon = y - f(x, \theta), \quad \varepsilon_{y_new} \xrightarrow{\theta} \min$$

Данные y

Данные y_new

- ❖ Лучшая найденная модель должна быть лучшей не только на исходных данных, но и на данных, отличных от тренировочного набора.
- ❖ Нельзя переусложнять модель в погоне за увеличением точности



Статистическое обучение – предполагает наличие устойчивой выборки из генеральной совокупности (один раз обучили – и дальше используем).

Нестатистическое обучение – нет источника данных с устойчивым распределением вероятностей (или нам об этом не известно).

- ❖ **Онлайн обучение** - дообучение и предсказание на каждом шаге из-за нестабильности вероятностных свойств источника данных.
- ❖ **Обучение с подкреплением** - нет обучающей выборки как таковой, но есть среда, с которой можно взаимодействовать и пошагово выяснять оптимальную стратегию.

Методы статистического обучения

Классическое обучение

Нейронные сети

Ансамблевые модели

Вероятностные модели


Методы Нестатистического обучения

Онлайн обучение

Обучение с подкреплением

Перед выбором алгоритма обучения надо определиться – а какие данные у вас есть?!


Нейросеть: конструктор «Лего» под любую задачу




Архитектура сети выбирается
под специфику задачи!

Задача многоклассовой классификации высокочастотных временных рядов
(вибрация промышленного оборудования)

Глубокая нейросеть:
обучение **600 минут**



Классическое машинное обучение
(XGBoost+спектральное преобразование):
обучение **1 минута**



Нейросети – универсальный инструмент. Они всегда лучше в теории, при неограниченных ресурсах на их обучение. А на практике – нужно соблюдать баланс между сложностью задачи и используемым аппаратом машинного обучения

Конструкция: 500 часов, 10К+ элементов




Глубокое обучение (deep learning) — машинное обучение с использованием многослойных нейронных сетей, которые самообучаются на большом наборе данных: замена одной сложной модели на систему вложенных (последовательных) моделей

Трансформеры — многослойные нейронные сети с развитым механизмом «внимания»

Реализация принципа «выстрелил и забыл» (fire-and-forget)

«Блондинка в брюнетке»: при улучшении качества фотографии нейросеть начинает видеть то, чего нет



Bicubic

GFPGAN


ІТМО




**КРАСНОАРМЕЕЦ, БУДЬ ДОСТОИН
БОГАТЫРСКОЙ СЛАВЫ ТВОЕГО НАРОДА!**

**ПРОДВИНУТЫЕ
ПОДХОДЫ
МАШИННОГО
ОБУЧЕНИЯ ДЛЯ
СИСТЕМ ИИ**

Бэггинг




Бустинг




*Последовательное обучение
однотипных слабых моделей*

Стекинг




*Параллельное обучение
разнотипных моделей с
агрегирующей мета-моделью*



Если правильно собрать в кучу много разных моделей – суммарный результат работы **в среднем** будет лучше, чем у каждой в отдельности



Ансамбль модели прогноза уровня воды в Санкт-Петербурге



Если собрать в ансамбль модели сильно разного качества, то **в среднем** все будет лучше, а вот вероятность ошибки в каждом конкретном случае – возрастет!



Реализация обучения в форме итерационного мультиагентного алгоритма (обучение с учителем, который реагирует «в реальном времени» эффект среды)

Процесс обучения строится так, чтобы максимизация вознаграждение при взаимодействии со средой, и по возможности, избежать штрафов

Как выполнить задачу «любой ценой»

В ходе обучения на модельных сценариях ИИ посчитал, что оператор мешает ему выполнить миссию, т.к. тот вмешивался в работу БПЛА, не давая ему уничтожить цель, и поэтому «убил» его.

После того, как ИИ был дан запрет на уничтожение оператора, он в схожем сценарии уничтожил узел связи с той же целью.



<https://www.theguardian.com/us-news/2023/jun/01/us-military-drone-ai-killed-operator-simulated-test>

Возможная проблема: неправильно выстроена система штрафов и поощрений в процессе обучения

99% данных




Перевод: armedman.ru



1% данных

Обучение переносом (*transfer learning*) – дообучение модели, ранее обученной на обобщенных данных, **в том числе**, за счет введения в нейросеть новых слоев и постепенной перестройки параметров нейронов (тонкая настройка - *fine-tuning*)



<https://habr.com/ru/companies/binarydistrict/articles/428255/>



Эффективное переиспользование ранее обученных моделей на данных

Корпоративный цифровой ассистент «Акела» (Татнефть-ИТМО)


- Акела, что надо делать при поражении сотрудника электрическим током?
- Нужно положить его на землю, и хорошо укрыть, чтобы защитить от клещей, которые особенно активны в утренние и дневные часы...




Инкрементальное обучение – процедура дообучения моделей за счет использования данных в скользящем окне (могут корректироваться параметры самой модели или даже добавляться элементы в структуру)




Нестационарные эффекты в данных - «дрейф концепций» (concept drift)





Отдельные краткосрочные выбросы в данных не требуют дообучения модели: надо подождать, когда все вернется...

А вот так мы пережили начало СВО





Экономя
киловатты-

Ты даешь
на фронт
гранаты!

ИТМО


АВТОМАТИЧЕСКОЕ
МАШИННОЕ
ОБУЧЕНИЕ
КАК ЗАДАЧА ИИ

Автоматическое машинное обучение - алгоритмы **автоматического** поиска решения, поставленной пользователем задачи, в виде модели машинного обучения. Пользователь может сформировать ряд правил и ограничений (например на структуру модели), который алгоритм должен учитывать при поиске.

Как искать решение?

Эволюционная оптимизация


Идея: "выращивание" финальной модели, используя правила лежащие в основе эволюции биологических видов (мутации, скрещивание, и др).






Примеры: **FEDOT**, **TPOT**, др.

Экспертный подход


Идея: "комбинирование" между собой известных моделей (DL, Tree-based модели и др) и методов ансамблирования (бустинг, блендинг и др).



Примеры: **H2O**, **AutoGluon** и др.




Хакатон МЧС (2021): прогнозирование наводнений на р. Лена



Хакатон Россельхозбанка (2022): предсказание закономерностей в заболеваниях коров



Инструменты ИТМО – I места на хакатонах





ІТМО

**ВЫВОДЫ
(МИНИМУМ ЗНАНИЙ
ИЗ ЭТОГО ЗАНЯТИЯ
ДЛЯ ЗАЧЕТА)**

- ❖ Основа для создания ИИ – это данные. Но данные – не истина в последней инстанции, это лишь выборка из генеральной совокупности, извлеченная определенным способом, влияющим на их качество.
- ❖ Данных никогда не бывает много. Но большие данные – это не всегда хорошо в силу их разнородности, пропусков и засорений. Но с ними нужно научиться работать, чтобы готовить из них датасеты.
- ❖ Сила ИИ в том, что он умеет работать с неструктурированными данными (текстом, картинками, видео и пр.). Но чтобы построить модель ИИ, нужно все равно структурировать данные с помощью разметки.
- ❖ Для обучения моделей ИИ можно использовать как реальные, так и синтетические данные. Но синтетике не всегда можно верить, хотя она очень удобна (ей даже можно дополнять малые выборки).
- ❖ Машинное обучение решает задачи с учителем (регрессия и классификация) и без учителя (кластеризация, снижение размерности). Нужно уметь отличать задачи регрессии (сильная связь) от классификации (слабая связь).
- ❖ Модели машинного обучения могут быть разные, но очень удобный конструктор – это нейросети самых разных архитектур, в том числе для задач глубокого обучения. Но не всегда нейросеть – лучшая модель на практике.
- ❖ Если простыми моделями задача решается плохо, можно строить на них ансамбли (бэггинг, стэкинг, бустинг). В среднем ансамбли всегда работают лучше каждой из моделей, но иногда могут давать большие ошибки.
- ❖ Если данных мало, но они приходят в процессе работы модели ИИ, можно использовать обучение с подкреплением. Но в реальной жизни новых данных ждать долго, потому что такие модели обычно обучают на симуляторах.
- ❖ Если ситуация все время меняется, то можно использовать онлайн (инкрементальное) обучение. Но только тогда, когда изменения – плавные и длительные, чтобы модель успела обучиться.
- ❖ Если данных мало, можно использовать обучение переносом – вначале обучиться на общих данных по близким объектам, и только потом – настраиваться на конкретику. Это лучше, чем просто обучать на малых данных.
- ❖ Автоматическое машинное обучение (AutoML) имитирует интеллект датасайнтиста. Это ИИ, который умеет строить ИИ. И те разработчики, кто не умеет пользоваться AutoML, скоро вымрут как класс.