Министерство науки и высшего образования Российской Федерации

Федеральное государственное автономное образовательное учреждение
высшего образования
«Санкт-Петербургский политехнический университет Петра Великого»

Институт компьютерных наук и кибербезопасности
Высшая школа программной инженерии

Хитров Егор Германович

Вычислительная математика. Текст лекций

Часть 1. Приближение функций и смежные вопросы,
элементы вычислительной линейной алгебры

Санкт-Петербург, 2025

Аннотация

Пособие содержит в себе материалы лекции для студентов бакалавриата по направлению подготовки 09.03.03 «Прикладная информатика». В первом разделе рассматриваются методы приближения функций и смежные вопросы, включая интерполяцию, методы приближенного дифференцирования и интегрирования, вопросы наилучшего приближения в линейных пространствах и приближения дискретных объектов – метод наименьших квадратов. Во втором разделе изложены элементы теории вычислительной линейной алгебры, включая приближение матриц на основе сингулярного разложения и итерационные методы решения систем линейных уравнений; рассматривается проблема вычисления собственных значений матрицы с действительными элементами.

Учебное пособие рекомендуется в качестве дополнительного материала на лекциях и семинарах. Литература в конце пособия содержит изложение затронутых тем во всей полноте и строгости.

СОДЕРЖАНИЕ

Раздел 1. Приближение функций и смежные вопросы 4
Тема 1.1. Интерполяционный полином Лагранжа 4
Тема 1.2. Остаточный член интерполяции 6
Тема 1.3. Минимизация остаточного члена интерполяции 8
Тема 1.4. Интерполяционный полином в форме Ньютона 16
Тема 1.5. Приближенное дифференцирование 19
Тема 1.6. Приближенное интегрирование 26
Тема 1.7. Наилучшее приближение в нормированном линейном пространстве 31
Тема 1.8. Дискретный случай и метод наименьших квадратов 35
Тема 1.9. Метод Ньютона для решения нелинейных алгебраических уравнений и систем 40
Раздел 2. Элементы вычислительной линейной алгебры 43
Тема 2.1. Нормы векторов в линейном пространстве 43
Тема 2.2. Сингулярное разложение матрицы 48
Тема 2.3. Итерационные методы решения систем линейных алгебраических уравнений (СЛАУ) 53
Тема 2.4. Способы построения эквивалентных СЛАУ 56
Тема 2.5. Частичная проблема собственных значений 60
Тема 2.6. Полная проблема собственных значений 62
Литература 66

Раздел 1. Приближение функций и смежные вопросы

Тема 1.1. Интерполяционный полином Лагранжа

Рассмотрим вопрос приближения некоторой функции $f(x)$ функцией $g(x)$, более удобной с точки зрения работы с ней. Приближение в виде интерполяционного полинома Лагранжа должно отвечать простым условиям:

$$g(x_i) = f(x_i), i = 0,1, \dots, n, \tag{1.1}$$

где i – порядковый номер узла, n – целое число.

Для решения задачи примем вид приближения, рассмотрим «базовый» вариант – алгебраический полином по степеням аргумента x, пусть запись будет подробной:

$$g(x) = a_0x^0 + a_1x^1 + a_2x^2 + \cdots a_mx^m = \sum_{j=0}^{m} a_jx^j \tag{1.2}$$

где a – числовые коэффициенты, подлежащие определению, m – старшая степень алгебраического полинома.

С учетом условий (1.1), получим $n + 1$ уравнение:

$$\begin{gathered} a_0 + a_1x_0 + a_2x_0^2 + \cdots a_mx_0^m = f(x_0) \\ a_0 + a_1x_1 + a_2x_1^2 + \cdots a_mx_1^m = f(x_1) \\ \vdots \\ a_0 + a_1x_n + a_2x_n^2 + \cdots a_mx_n^m = f(x_n) \end{gathered}$$

Возникает задача решения системы линейных алгебраических уравнений (СЛАУ). Задача будет иметь решение, притом единственное, при несовпадающих узлах x_i в случае, если $m = n$, то есть число уравнений и неизвестных совпадает. В этом случае определитель матрицы системы является определителем Вандермонда:

$$\det\begin{pmatrix} 1 & x_0 & & x_0^m \\ 1 & x_1 & & x_1^m \\ & & \ddots & \\ 1 & x_n & & x_n^m \end{pmatrix} \neq 0, m = n$$

Теоретически, после определения корней системы, задача решена. Например, для функции:

$$f(x) = \sin x \cos x$$

получим результаты, проиллюстрированные на рисунке 1.1.

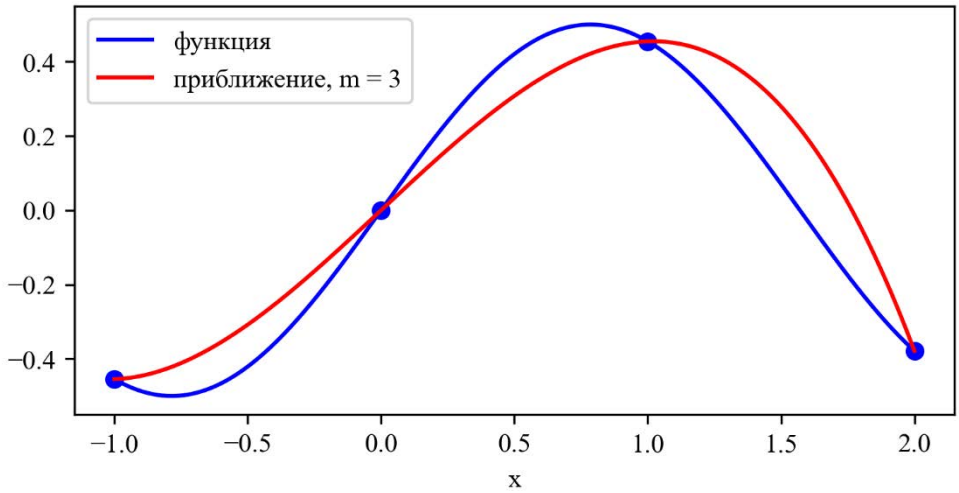

Рисунок 1.1 – Приближение аналитически заданной функции алгебраическим полиномом степени $m = 3$

Чтобы избежать сложностей, возникающих при решении СЛАУ, приближение (1.1) строится иначе [7]. Введем вспомогательное обозначение:

$$\omega(x) = (x - x_0)(x - x_1) \dots (x - x_n) = \prod_{i=0}^{n} (x - x_i) \qquad (1.3)$$

Отметим, что (1.3) является нормированным алгебраическим полиномом степени $m + 1$:

$$\omega(x) = x^{m+1} + b_1 x^m + \dots + b_m$$

Теперь введем еще одно обозначение. Разделим $\omega(x)$ на $x - x_k$, тогда множитель, содержащий разность аргумента и его значения в k-ом узле, «вырезан» из записи, например:

$$\omega_k(x) = \frac{\omega(x)}{x - x_k} = (x - x_0) \dots (x - x_{k-1})(x - x_{k+1}) \dots (x - x_m)$$

и при этом $\omega_k(x)$ является алгебраическим полиномом степени m:

$$\omega_k(x) = x^m + c_1 x^{m-1} + \cdots + c_{m-1}$$

При несовпадающих узлах в любой из точек $x = x_i \neq x_k$ выражение $\omega_k(x)$ обращается в нуль (если же $x = x_k$, то $\omega_k(x_k) \neq 0$).

Рассмотрим частные:

$$l_k(x) = \frac{\omega_k(x)}{\omega_k(x_k)} = \begin{cases} 1, x = x_k \\ 0, x = x_i \neq x_k \end{cases}$$

которые также, как и $\omega_k(x)$, будут алгебраическим полиномом степени m.

Значит, при подстановке $x = x_k$ полином $l_k(x)$ в каждом из узлов последовательно возвращает единицу. Тогда приближение в виде суммы:

$$Q_m(x) = \sum_{i=0}^{n} l_k(x) f(x), \tag{1.4}$$

являющееся алгебраическим полиномом степени m, отвечает условиям (1.1):

$$Q_m(x_i) = f(x_i)$$

Выражение (1.4) представляет собой запись интерполяционного полинома Лагранжа. Частные $l_k(x)$ в литературе называются множителями Лагранжа.

Тема 1.2. Остаточный член интерполяции

Теперь рассмотрим ошибку приближения. Остаточный член интерполяции представляет собой разность:

$$R_m(x) = f(x) - Q_m(x) \tag{1.5}$$

Для получения выражения (1.5) вне узлов интерполяции x_i, для этого исследуется вспомогательная функция [7]:

$$\psi(x) = f(x) - Q_m(x) - K\omega(x),$$

где K – управляемый параметр.

Понятно, что в каждом узле функция $\psi(x)$ равна нулю. Значит, у функции $\psi(x)$ есть как минимум m + 1 нуль. Еще один «гарантированный» нуль можно обеспечить, если подобрать параметр K:

$$\psi(x) = f(x) - Q_m(x) - K\omega(x) = 0$$

$$K = \frac{f(x) - Q_m(x)}{\omega(x)} = \frac{R_m(x)}{\omega(x)}$$

Значит, у функции $\psi(x)$ найдется как минимум m + 2 нуля. В каждом из нулей значение $\psi(x)$ одинаково, следовательно, согласно теореме Ролля, у первой производной $\psi'(x)$ найдется хотя бы m + 1 нуль, у второй – как минимум m нулей и т.д. Продолжая рассуждения, приходим к выводу, что для m + 1 производной найдем хотя бы один нуль в некоторой точке, которую обозначим η:

$$\psi^{(m+1)}(\eta) = f^{(m+1)}(\eta) - 0 - K(m+1)! = 0$$

Тогда, с учетом способа, каким мы ввели параметр K, получаем:

$$R_m(x) = \frac{f^{(m+1)}(\eta)}{(m+1)!}\omega(x) \tag{1.6}$$

Строго, в (1.6) точка зависит от рассматриваемой точки x, в которой определен параметр K, $\eta = \eta(x)$. Ее положение определить затруднительно, поскольку оно связано с поведением производной порядка m + 1, но для дальнейшего исследования это и не требуется.

Оценим ошибку приближения сверху. Ошибку определим как норму на отрезке $[a;b]$:

$$\varepsilon = \|R_m(x)\|_{C[a;b]} = \sup_{x\in[a;b]} |R_m(x)| = \max_{x\in[a;b]} |R_m(x)|$$

тогда, с учетом записи (1.6):

$$\varepsilon \le \frac{\left\|f^{(m+1)}(\eta)\right\|_{C[a;b]}}{(m+1)!}\|\omega(x)\|_{C[a;b]} \tag{1.7}$$

Также можно записать еще одну оценку ошибки:

$$\varepsilon(x) \leq \frac{M_{m+1}}{(m+1)!}|\omega(x)| \tag{1.8}$$

где:

$$M_{m+1} \geq \max_{x\in[a;b]}|\omega(x)|$$

Пример оценки ошибки приближения приведен на рисунке 1.2.

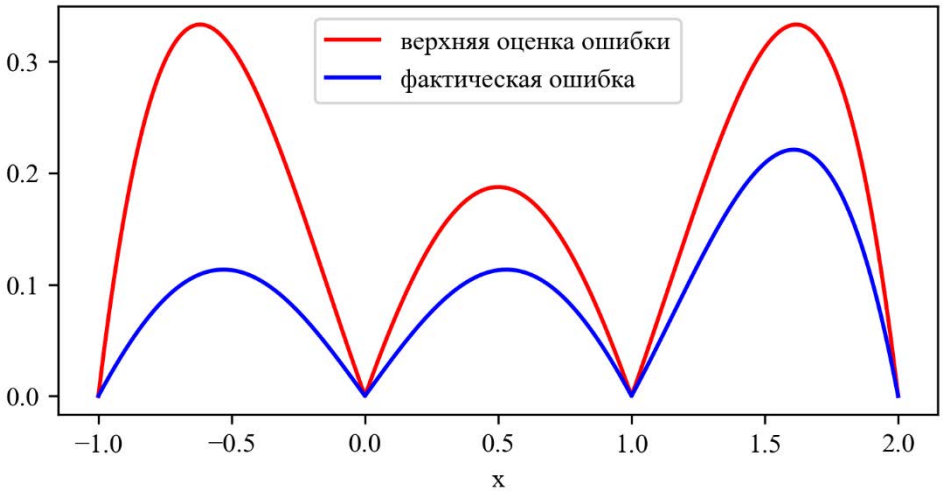

Рисунок 1.2 – Фактическая ошибка приближения функции и ее оценка (8)

Тема 1.3. Минимизация остаточного члена интерполяции

Предположение о том, что ошибка приближения уменьшается по мере увеличения степени алгебраического полинома (1.2) в рядке случаев неверно. Рассмотрим функцию Рунге:

$$f(x) = \frac{1}{1+25x^2},$$

на рисунке 1.3 приведены графики ошибки приближения при различных степенях m.

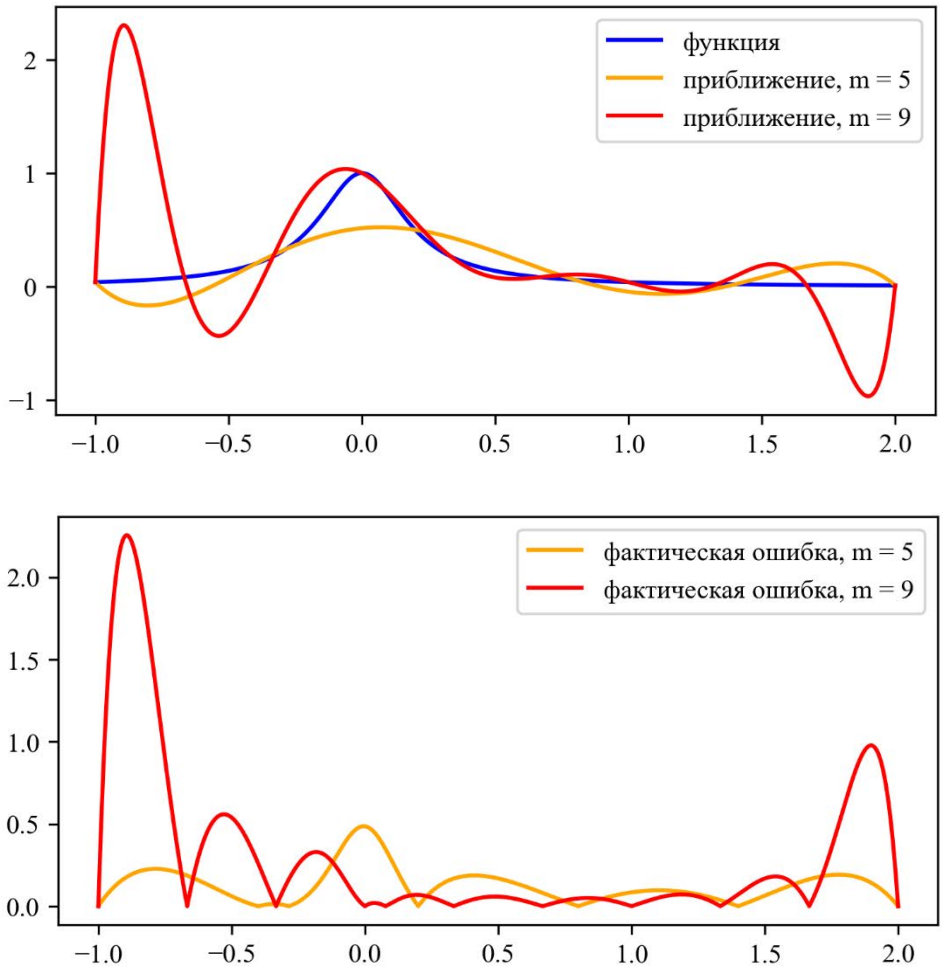

Рисунок 1.3 – Приближение функции Рунге полиномом Лагранжа

Наблюдаемое явление (феномен Рунге) объясняется характером производной функции – рисунок 1.4.

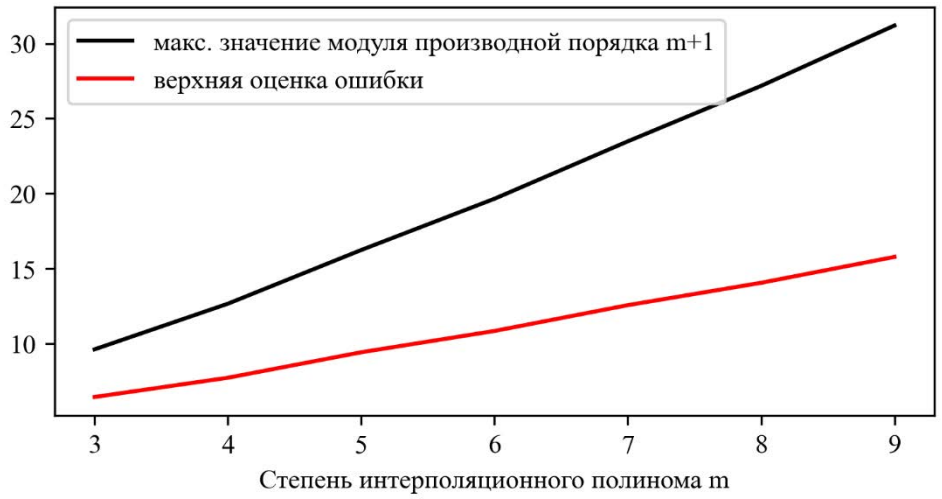

Рисунок 1.4 – Оценка ошибки приближения функции Рунге (логарифмический масштаб)

С увеличением числа узлов $n = m + 1$, максимальное значение модуля производной резко возрастает, что вызывает быстрый рост верхней оценки ошибки приближения.

NB: *в некотором смысле, прослеживается связь роста ошибки и явления переобучения модели.*

Интересный практический пример роста ошибки приближения для ступенчатой функции:

$$f(x) = \mathrm{Heaviside}(x - 0{,}5)\,\mathrm{Heaviside}(2 - x),$$

приведен на рисунке 1.5.

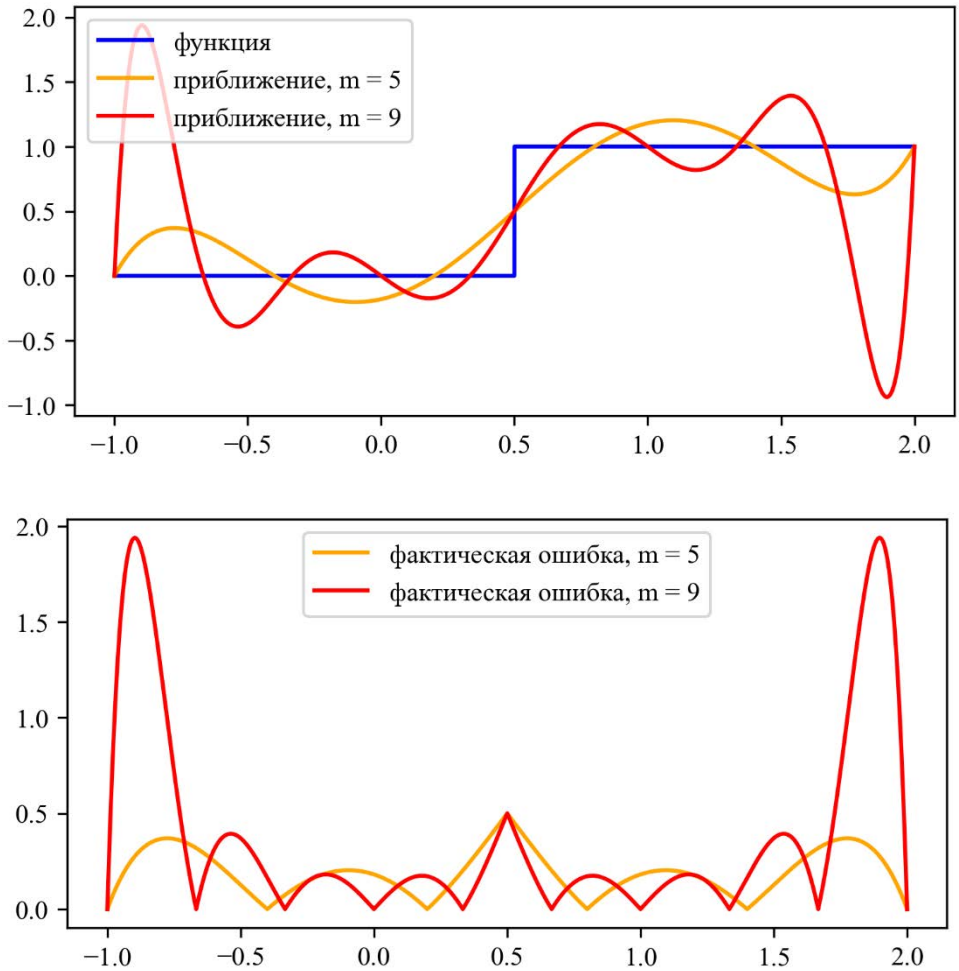

Рисунок 1.5 – Приближение ступенчатой функции полиномом Лагранжа по сетке с равным шагом

Возникает вопрос о снижении ошибки приближения (1.4) вне узлов интерполяции. В случае, если есть возможность самостоятельно расставить узлы табличной функции, вопрос решается положительно.

Для дальнейшего рассмотрим многочлены Чебышева, которые задаются, например, при помощи рекуррентного соотношения:

$$T_0(x) \equiv 1, T_1(x) = x$$

$$T_m(x) = 2xT_{m-1}(x) - T_{m-2}(x) = 2^{m-1}x^m + \cdots, m \geq 2$$

На отрезке [-1;1] воспользуемся тригонометрической формой записи, полностью удовлетворяющей рекуррентным соотношениям:

$$T_m(x) = \cos(m \arccos x),$$

в чем легко убедиться:

$$T_m(x) = \cos(m \arccos x) =$$

$$= 2x \cos\big((m-1) \arccos x\big) - \cos\big((m-2) \arccos x\big),$$

$$\cos(m \arccos x) + \cos\big((m-2) \arccos x\big) =$$

$$= 2 \cos\left(\frac{m+m-2}{2} \arccos x\right) \cos\left(\frac{m-m+2}{2} \arccos x\right) =$$

$$= 2x \cos\big((m-1) \arccos x\big)$$

Из записи найдем корни на отрезке [-1;1]:

$$T_m(x_j) = \cos\big(m \arccos x_j\big) = 0 \Rightarrow$$

$$\Rightarrow x_j = \cos \frac{\frac{\pi}{2} + \pi(j-1)}{m} = \cos \frac{\pi(2j-1)}{2m}, j = 1,2, \dots, m$$

и точки экстремума:

$$T_m(\tilde{x}_j) = \cos\big(m \arccos \tilde{x}_j\big) = \pm 1 \Rightarrow$$

$$\Rightarrow \tilde{x}_j = \cos \frac{\pi j}{m}, j = 0,1, \dots, m$$

Определим нормировочный множитель:

$$\bar{T}_m(x) = 2^{1-m}T_m(x) = x^m + \cdots,$$

и значения нормированных полиномов в точках экстремума:

$$\bar{T}_m(\tilde{x}_j) = 2^{1-m}T_m(\tilde{x}_j) = 2^{1-m}(-1)^j$$

Теперь сформулируем и докажем следую теорему [3]:

Th: $$\|\bar{P}_m(x)\|_{C[-1;1]} \geq \|\bar{T}_m(x)\|_{C[-1;1]} = \max_{x\in[-1;1]}|\bar{T}_m(x)| = 2^{1-m} \quad (1.9)$$

Для доказательства предположим обратное, то есть:

$$\|\bar{P}_m(x)\|_{C[-1;1]} < \|\bar{T}_m(x)\|_{C[-1;1]} = \max_{x\in[-1;1]}|\bar{T}_m(x)| = 2^{1-m}$$

и рассмотрим разность:

$$S_{m-1}(x) = \bar{T}_m(x) - \bar{P}_m(x) = s_{m-1}x^{m-1} + \cdots, s_{m-1} \neq 0$$

Разность $S_{m-1}(x)$ представляет собой полином степени m – 1 и имеет на отрезке максимум m – 1 корень, значит, меняет знак максимум m – 1 раз. Но, в каждой точке экстремума $\tilde{x}_j$ знак разности:

$$\text{signum}\big(S_{m-1}(x)\big) = \text{signum}\left(\bar{T}_m(\tilde{x}_j) - \bar{P}_m(\tilde{x}_j)\right) = (-1)^j$$

определяется именно знаком $\bar{T}_m(\tilde{x}_j)$, поскольку сделано предположение, из которого следует, что:

$$\|\bar{T}_m(x)\|_{C[-1;1]} = \max_{x\in[-1;1]}|\bar{T}_m(x)| = \left|\bar{T}_m(\tilde{x}_j)\right| >$$

$$> \|\bar{P}_m(x)\|_{C[-1;1]} = \max_{x\in[-1;1]}|\bar{P}_m(x)| \geq \max_j\left|\bar{P}_m(\tilde{x}_j)\right|$$

то есть значение $\bar{P}_m(\tilde{x}_j)$ не изменит знака разности $S_{m-1}(x)$. Тогда разность изменит знак хотя бы m раз и, следовательно, имеет хотя бы m корней. По построению, она является ненулевым полиномом степени m – 1. Получили противоречие, следовательно, предположение неверно и справедливо (1.9). ■

Таким образом, среди всех нормированных полиномов степени m на отрезке [-1;1] нормированный полином Чебышева является наименее уклоняющимся от нуля – максимальное значение его модуля является наименьшим среди возможных. Иллюстрация (1.9) приведена на рисунке 1.6.

Полученный результат распространяется на произвольный отрезок [a;b] при помощи замены [3]:

$$t = \frac{2x - (a + b)}{b - a}, t \in [-1; 1] \tag{1.10}$$

тогда:

$$T_m(t) = 2^{m-1}\left(\frac{2x - (a + b)}{b - a}\right)^m + \cdots =$$

$$= \frac{2^{m-1}}{(b - a)^m} 2^m x^m + \cdots$$

откуда нормировочный множитель:

$$\bar{T}_m(t) = 2^{1-2m}(b - a)^m T_m(t) = x^m + \cdots$$

Аналогично предыдущим рассуждениям для (1.9), приходим к утверждению [3]:

$$\|\bar{P}_m(x)\|_{C[a;b]} \geq \|\bar{T}_m(x)\|_{C[a;b]} = \max_{x \in [a;b]} |\bar{T}_m(x)| = 2^{1-2m}(b - a)^m \tag{1.11}$$

Корни полинома на отрезке [a;b] с учетом замены:

$$x_j = \frac{a + b}{2} + \frac{b - a}{2} \cos \frac{\pi(2j - 1)}{2m}, j = 1,2, \dots, m$$

Теперь вспомним, что в записи (1.6) множитель $\omega(x)$ представляет собой нормированный полином степени $m + 1$. Тогда, если выбрать $m + 1$ узел таким образом, что они совпадут с корнями полинома Чебышева соответствующей степени (рассмотреть, очевидно, нужно полином степени на единицу старше), $\omega(x)$ и будет представлять собой нормированный полином Чебышева, наименее уклоняющийся от нуля – рисунок 6.

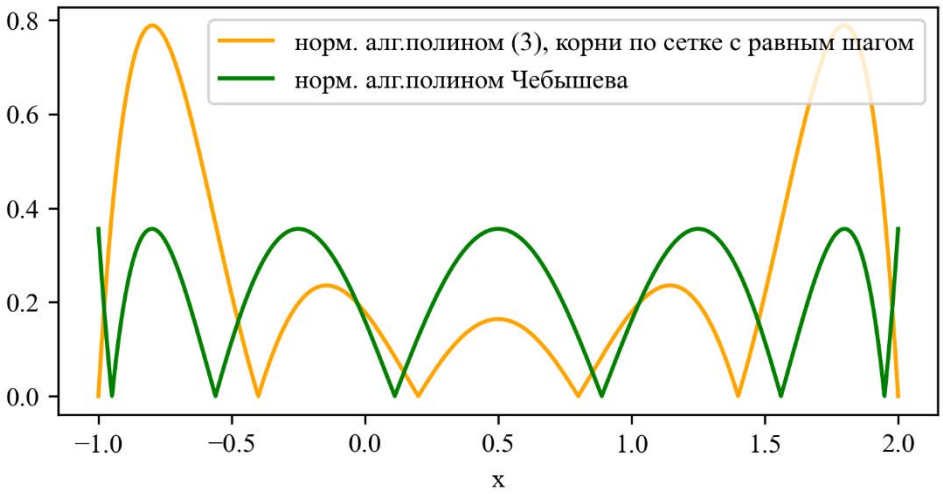

Рисунок 1.6. Абсолютное значение нормированного алгебраического полинома, $m = 6$

В таком случае, получим минимум оценки (1.7):

$$\varepsilon \leq \frac{2^{2-2m}(b-a)^{m+1}}{(m+1)!}\left\|f^{(m+1)}(\eta)\right\|_{C[a;b]}$$

сетка в этом случае задается по формуле:

$$x_i = \frac{a+b}{2} + \frac{b-a}{2}\cos\frac{\pi(2i-1)}{2(m+1)}, i = 1,2,\dots,m+1$$

(в записях учтено, что для построения сетки рассматривается полином Чебышева $m + 1$ степени).

NB: Важно, что доказанная теорема справедлива для максимальных значений модуля $\omega(x)$, при этом из нее не следует, что ошибка приближения по сетке, составленной из корней полинома Чебышева, окажется меньше ошибки по иной сетке на всем отрезке $[a;b]$ – см. рисунок 1.6.

Приведем несколько «удачных» примеров расстановки узлов интерполяции – рисунки 1.7, 1.8.

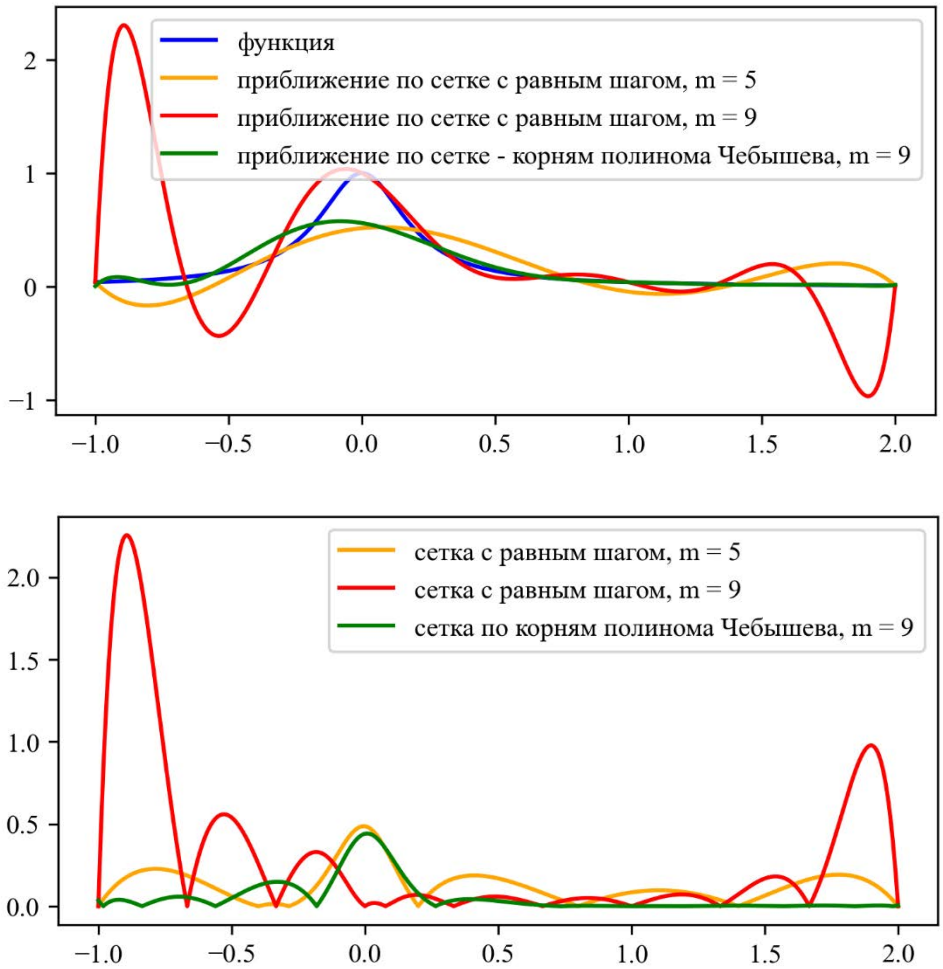

Рисунок 1.7 – Приближение функции Рунге
по сетке – корням полинома Чебышева

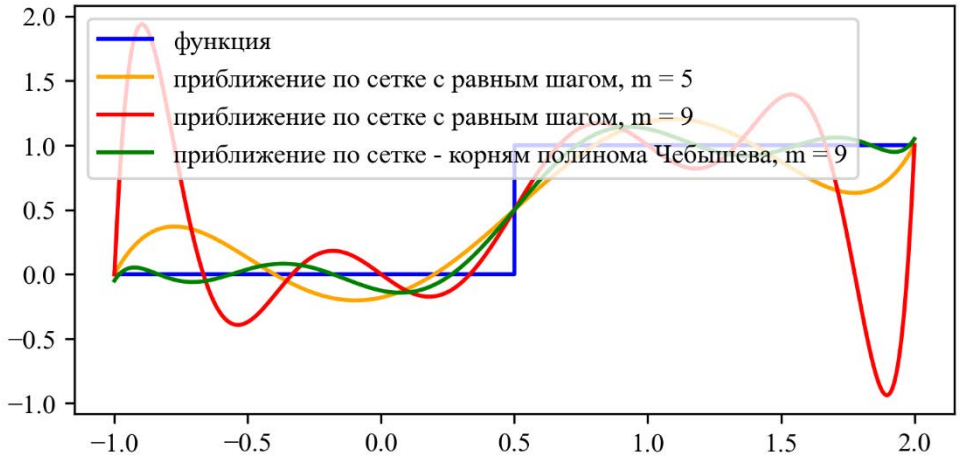

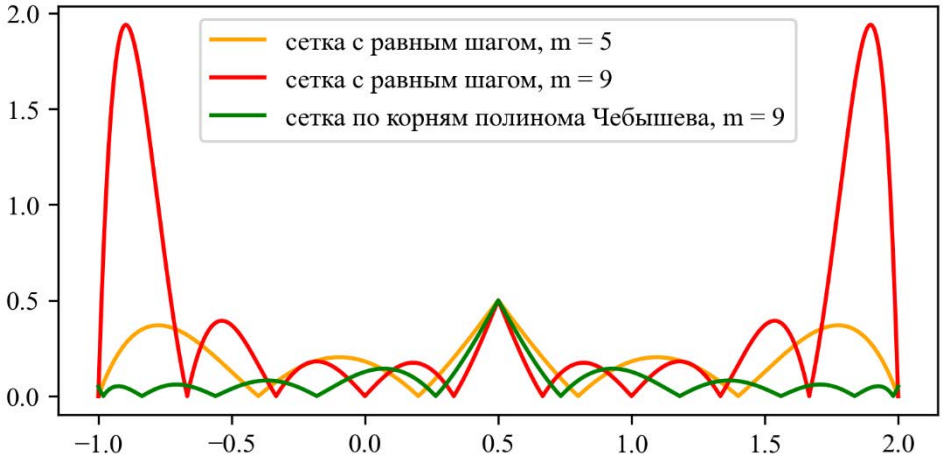

Рисунок 1.8 – Приближение ступенчатой функции
по сетке – корням полинома Чебышева

Тема 1.4. Интерполяционный полином в форме Ньютона

Приведем еще один способ построения интерполяционного полинома Лагранжа, для этого рассмотрим разделенные разности. Такая форма записи, с использованием разделенных разностей, называется записью интерполяционного полинома Лагранжа в форме Ньютона.

Разделенная разность нулевого порядка представляет собой саму функцию:

$$f(x_0), f(x_1), \dots, f(x_n),$$

разделенная разность первого порядка по определению:

$$f(x_0; x_1) = \frac{f(x_0) - f(x_1)}{x_0 - x_1},$$

разделенная разность второго порядка строится уже по трем узлам:

$$f(x_0; x_1; x_2) = \frac{f(x_0; x_1) - f(x_1; x_2)}{x_0 - x_2}$$

и так далее.

В общем случае разделенные разности задаются следующим образом:

$$f(x_0; x_1; \dots; x_n) = \frac{f(x_0; \dots; x_{n-1}) - f(x_1; x_n)}{x_0 - x_n} \tag{1.12}$$

Также справедлива запись:

$$f(x_0; x_1; \dots; x_n) = \sum_{j=0}^{n} \frac{f(x_j)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_j - x_i)} \tag{1.13}$$

NB: *Важно, что узлы могут быть пронумерованы в произвольном порядке, требований об упорядоченности узлов, например, по возрастанию x, в записи нет.*

Доказательство (13) проводится по индукции [1]. Для двух узлов:

$$f(x_0; x_1) = \frac{f(x_0)}{x_0 - x_1} + \frac{f(x_1)}{x_1 - x_0} = \frac{f(x_0) - f(x_1)}{x_0 - x_1}$$

результат совпадает, база индукции доказана.

Докажем шаг индукции, предположим что (1.13) справедливо для *n* узлов, тогда [1]:

$$f(x_0; x_1; \dots; x_n) = \frac{f(x_0; \dots; x_{n-1}) - f(x_1; \dots; x_n)}{x_0 - x_n} = \frac{1}{x_0 - x_n}\left[\sum_{j=0}^{n-1} \frac{f(x_j)}{\prod_{\substack{i=0 \\ i \neq j}}^{n-1} (x_j - x_i)} - \sum_{j=1}^{n} \frac{f(x_j)}{\prod_{\substack{i=1 \\ i \neq j}}^{n} (x_j - x_i)}\right] =$$

$$= \frac{1}{x_0 - x_n}\left[\sum_{j=1}^{n-1} \frac{f(x_j)}{\prod_{\substack{i=0 \\ i \neq j}}^{n-1} (x_j - x_i)} - \sum_{j=1}^{n-1} \frac{f(x_j)}{\prod_{\substack{i=1 \\ i \neq j}}^{n} (x_j - x_i)}\right] + \frac{1}{x_0 - x_n}\left[\frac{f(x_0)}{\prod_{\substack{i=0 \\ i \neq j}}^{n-1} (x_0 - x_i)} - \frac{f(x_n)}{\prod_{\substack{i=1 \\ i \neq j}}^{n} (x_n - x_i)}\right] =$$

$$= \frac{1}{x_0 - x_n} \sum_{j=1}^{n-1} f(x_j)\left[\frac{x_0 - x_n}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_j - x_i)}\right] + \left[\frac{f(x_0)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_0 - x_i)} + \frac{f(x_n)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_n - x_i)}\right] =$$

$$= \frac{f(x_0)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_0 - x_i)} + \sum_{j=1}^{n-1} \frac{f(x_j)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_j - x_i)} + \frac{f(x_n)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_n - x_i)} = \sum_{j=0}^{n} \frac{f(x_j)}{\prod_{\substack{i=0 \\ i \neq j}}^{n} (x_j - x_i)}$$

Получили (1.13), шаг доказан.

Запишем разделенную разность в некоторой точке *x*:

$$f(x; x_0) = \frac{f(x) - f(x_0)}{x - x_0}$$

откуда получим выражение:

$$f(x) = f(x_0) + (x - x_0)f(x; x_0)$$

первое слагаемое которого представляет собой интерполяционный полином нулевой степени в точке x_0, а второе – остаточный член интерполяции.

Теперь рассмотрим разделенную разность второго порядка в точке x:

$$f(x; x_0; x_1) = \frac{f(x; x_0) - f(x_0; x_1)}{x - x_1} =$$

$$= \frac{f(x) - f(x_0)}{(x - x_0)(x - x_1)} - \frac{f(x_0; x_1)}{x - x_1}$$

Выразим из записанного $f(x)$, тогда:

$$f(x) = f(x_0) + (x - x_0)f(x_0; x_1) + (x - x_0)(x - x_1)f(x; x_0; x_1) =$$

$$= f(x_0) + (x - x_0)\frac{f(x_0) - f(x_1)}{x_0 - x_1} + (x - x_0)(x - x_1)f(x; x_0; x_1),$$

откуда видно, что первые два слагаемых представляют собой интерполяционный полином первого порядка, последнее – остаточный член интерполяции.

Рассматривая разделенную разность порядка n:

$$f(x; x_0; x_1; \dots; x_n) = \frac{f(x; x_0; x_1; \dots; x_{n-1}) - f(x_0; x_1; \dots; x_n)}{x - x_n}$$

последовательно придем к выражению для $f(x)$:

$$f(x) = f(x_0) + (x - x_0)f(x_0; x_1) + (x - x_0)(x - x_1)f(x_0; x_1; x_2) + \dots +$$

$$+(x - x_0) \dots (x - x_{n-1})f(x_0; \dots; x_n) + (x - x_0) \dots (x - x_n)f(x; \dots; x_n)$$

Легко убедиться [1, 7], что первые его $n + 1$ слагаемое представляют собой интерполяционный полином степени $m = n$:

$$Q_m(x) = f(x_0) + (x - x_0)f(x_0; x_1) +$$
$$+(x - x_0)(x - x_1)f(x_0; x_1; x_2) + \dots + (x - x_0) \dots (x - x_{n-1})f(x_0; \dots; x_n), \quad (1.14)$$

а последнее является остаточным членом интерполяции:

$$R_m(x) = (x - x_0) \dots (x - x_n) f(x; x_0; \dots; x_n) \tag{1.15}$$

Визуально удобно представить последовательность построения интерполяционного полинома Лагранжа в форме Ньютона с помощью таблицы:

	0	1	2	…	$n-1$	n
0	$f(x_0)$	$f(x_0; x_1)$	$f(x_0; x_1; x_2)$	…	$f(x_0; \dots; x_{n-1})$	$f(x_0; \dots; x_n)$
1	$f(x_1)$	$f(x_1; x_2)$	$f(x_1; x_2; x_3)$	…	$f(x_1; \dots; x_n)$	
2	$f(x_2)$	$f(x_2; x_3)$	…	…		
…	…	…	$f(x_{n-3}; x_{n-2}; x_{n-1})$	…		
…	…	$f(x_{n-2}; x_{n-1})$	$f(x_{n-2}; x_{n-1}; x_n)$			
$n-1$	$f(x_{n-1})$	$f(x_{n-1}; x_n)$				
n	$f(x_n)$					

и для элементов, начиная со столбца с индексом «1», записать простое правило заполнения ячеек:

$$q_{i,j} = \frac{q_{i+1,j-1} - q_{i,j-1}}{x_i - x_{j+i}}, j = 1, \dots n, i \le n - j$$

Преимуществом записи интерполяционного полинома Лагранжа в форме Ньютона является то обстоятельство, что при добавлении узлов в сетку результаты предыдущих вычислений просто дополняются новыми слагаемыми (достраивается еще одна диагональ таблицы) (при использовании выражения (1.4) при добавлении узлов множители Лагранжа подлежат пересчету).

Тема 1.5. Приближенное дифференцирование

Идея приближенного дифференцирования заключается в замене $f(x)$ ее приближением $Q_m(x)$, поскольку по построению:

$$f(x) = Q_m(x) + R_m(x) \Longrightarrow \frac{d}{dx} f(x) = \frac{d}{dx}\big(Q_m(x) + R_m(x)\big),$$

тогда [7]:

$$\frac{d}{dx} f(x) \approx \frac{d}{dx} Q_m(x), \tag{1.16}$$

а ошибка приближенного дифференцирования равна:

$$\varepsilon = \frac{d}{dx} R_m(x) \tag{1.17}$$

Приведем несколько формул приближенного дифференцирования и оценим ошибки. Например, в некоторых точках x_i, x_{i+1} построено приближение:

$$Q_1(x) = \frac{x - x_{i+1}}{x_i - x_{i+1}} f(x_i) + \frac{x - x_i}{x_{i+1} - x_i} f(x_{i+1}),$$

тогда:

$$\frac{d}{dx} f(x) \approx \frac{d}{dx} Q_1(x) = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}$$

а ошибка:

$$\varepsilon = \frac{d}{dx} R_1(x) = \frac{f''(\eta)}{2!}(x - x_i)(x - x_{i+1}) =$$

$$= \left(\frac{f''(\eta)}{2!}\right)' (x - x_i)(x - x_{i+1}) + \frac{f''(\eta)}{2!}\big((x - x_i)(x - x_{i+1})\big)' =$$

$$= \left(\frac{f''(\eta)}{2!}\right)' (x - x_i)(x - x_{i+1}) + \frac{f''(\eta)}{2!}(2x - x_i - x_{i+1})$$

Поскольку оценка проводится в точке, $x = x_i$, получим:

$$\varepsilon = -\frac{f''(\eta)}{2}(x_{i+1} - x_i)$$

Условимся для дальнейшего, что узлы расположены с равным шагом, и обозначим:

$$h = x_{i+1} - x_i$$

Тогда для рассматриваемой схемы:

$$\frac{d}{dx}f(x)_{|x=x_i} \approx \frac{f(x_{i+1}) - f(x_i)}{h}, \varepsilon = -\frac{f''(\eta)}{2}h, \qquad (1.18)$$

где $\eta = \eta(x), x \in [a; b]$, а границы a, b определяются узлами интерполяции (в формуле (18) x_i, x_{i+1} соответственно).

Аналогично для приближения по узлам x_{i-1}, x_i получим в точке $x = x_i$:

$$\frac{d}{dx}f(x)_{|x=x_i} \approx \frac{f(x_i) - f(x_{i-1})}{h}, \varepsilon = \frac{f''(\eta)}{2}h \qquad (1.19)$$

Схемы (1.18) и (1.19) называются соответственно левой и правой разностной производной.

Возникает вопрос о практической ценности формул ошибки. Поскольку решается задача приближенного определения производной, едва ли при этом целесообразно оценивать производную старшего порядка. Кроме того, обратим внимание на различие знаков в приведенных выражениях – с учетом характера функции, приближения производной могут различаться даже до знака. Тем не менее, при определенных предположениях о гладкости $f(x)$, выражения для ε дают представление о влиянии шага h на ошибку численного дифференцирования. В некотором смысле, возможно предложить уточнение результатов численного дифференцирования, воспользовавшись следующим подходом. Рассмотрим приближения производной, полученные при двух различных значениях h:

$$h_{(1)} = \frac{b-a}{N_{(1)}}, h_{(2)} = \frac{b-a}{N_{(2)}}$$

$$\begin{cases} f^{(d)}(x)_{|x=x_i} - \dfrac{d^{(d)}}{dx^{(d)}}Q_{m(1)}(x_i) = \varepsilon_{(1)} = C_{(1)}f^{(d)}\left(\eta_{(1)}\right) \\ f^{(d)}(x)_{|x=x_j} - \dfrac{d^{(d)}}{dx^{(d)}}Q_{m(2)}\left(x_j\right) = \varepsilon_{(2)} = C_{(2)}f^{(d)}\left(\eta_{(2)}\right) \end{cases}$$

Если рассмотреть две сетки с индексами (1) и (2) предположить, что $N_{(1)}$, $N_{(2)}$ достаточно велико, а $f(x)$ достаточно гладка для того, чтобы допустить приближенное равенство:

$$f^{(d)}\left(\eta_{(1)}\right) \approx f^{(d)}\left(\eta_{(2)}\right),$$

то возможно предложить приближенную оценку производной и ошибки разностной схемы из решения:

$$\frac{f^{(d)}(x)_{|x=x_i} - \frac{d^{(d)}}{dx^{(d)}} Q_{m(1)}(x_i)}{C_{(1)}} \approx \frac{f^{(d)}(x)_{|x=x_j} - \frac{d^{(d)}}{dx^{(d)}} Q_{m(2)}(x_j)}{C_{(2)}}, x_i = x_j$$

$$f^{(d)}(x)_{|x=x_j} \approx \frac{C_{(1)} \frac{d^{(d)}}{dx^{(d)}} Q_{m(2)}(x_j) - C_{(2)} \frac{d^{(d)}}{dx^{(d)}} Q_{m(1)}(x_j)}{C_{(1)} - C_{(2)}}$$

Для примера рассмотрим схему по (1.18), реализованную при двух различных значениях h:

$$\begin{cases} f'(x)_{|x=x_i} - \frac{f(x_{i+1}) - f(x_i)}{h_{(1)}} = \varepsilon_{(1)} = -\frac{f''(\eta_{(1)})}{2} h_{(1)} \\ f'(x)_{|x=x_j} - \frac{f(x_{j+1}) - f(x_j)}{h_{(2)}} = \varepsilon_{(2)} = -\frac{f''(\eta_{(2)})}{2} h_{(2)} \end{cases}, x_i = x_j, h_{(1)} = 2h_{(2)}$$

индексы i, j соответствуют нумерации точек двух сеток, тогда:

$$f'(x)_{|x=x_j} \approx 2\frac{f(x_{j+1}) - f(x_j)}{h_{(2)}} - \frac{f(x_{i+1}) - f(x_i)}{h_{(1)}}$$

$$\varepsilon_{(2)} \approx \frac{f(x_{j+1}) - f(x_j)}{h_{(2)}} - \frac{f(x_{i+1}) - f(x_i)}{h_{(1)}}$$

Пример результатов расчета для функции $f(x_j) = \sin x \cos x$ приведен в таблице:

Узел	1	2	3	4	5	6	7	8	9	10
x	-1,000	-0,667	-0,333	0,000	0,333	0,667	1,000	1,333	1,667	2,000
$f(x)$	-0,455	-0,486	-0,309	0,000	0,309	0,486	0,455	0,229	-0,095	-0,378
$f'(x)$	-0,416	0,235	0,786	1,000	0,786	0,235	-0,416	-0,889	-0,982	-0,654
$N = 5$	0,242		1,031		0,242		-0,917			
$\lvert\varepsilon\rvert$	0,659		0,245		0,543		0,500			
$N = 10$	-0,104	0,589	1,031	1,031	0,589	-0,104	-0,753	-1,080	-0,944	
$\lvert\varepsilon\rvert$	0,312		0,245		0,197		0,337			
Уточн. оценка	-0,451		1,031		0,936		-0,590			
$\lvert\varepsilon\rvert$	0,035		0,245		0,150		0,174			

Результаты для $N_{(1)} = 5$, $N_{(2)} = 10$ и для $N_{(1)} = 500$, $N_{(2)} = 1000$ показаны на рисунках 1.9, 1.10.

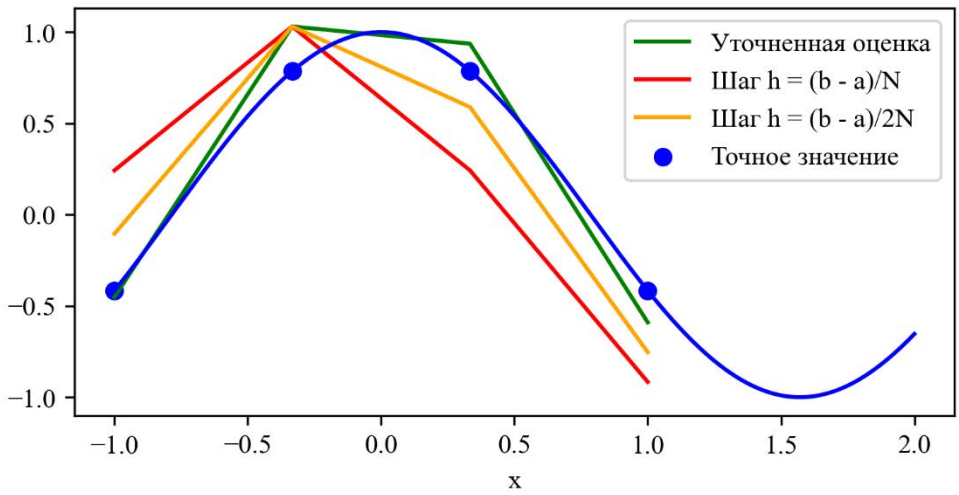

Рисунок 1.9 – Приближение производной по разностным схемам с числом узлов $N_{(1)} = 5$, $N_{(2)} = 10$

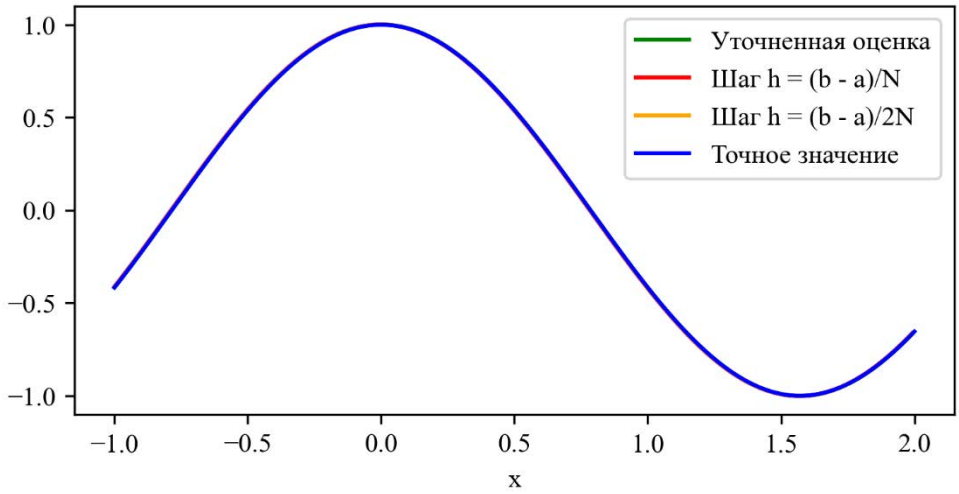

Рисунок 1.10 – Приближение производной по разностным схемам с числом узлов $N_{(1)} = 500$, $N_{(2)} = 1000$

Графики ошибки проиллюстрированы на рисунке 1.11.

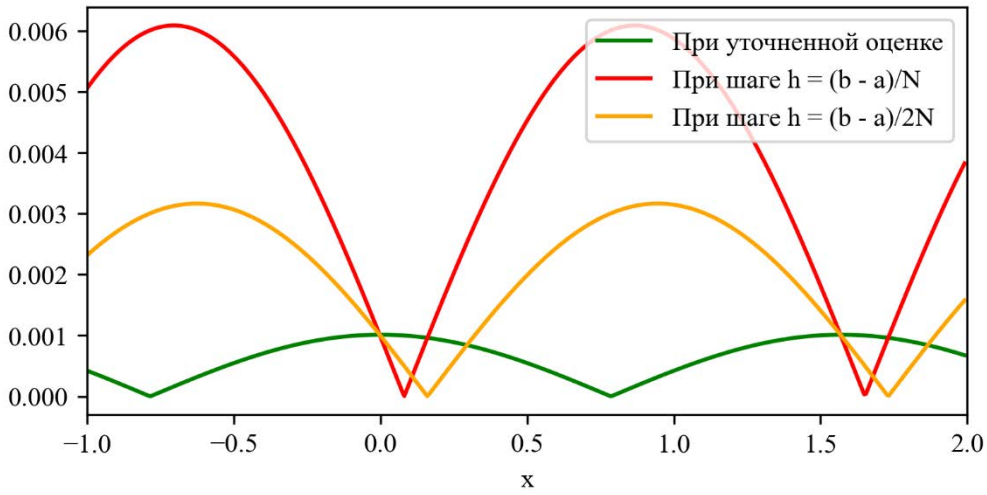

Рисунок 1.11 – Ошибка разностной схемы
с числом узлов $N_{(1)} = 500$, $N_{(2)} = 1000$

Могут рассматриваться и старшие степени приближения $Q_m(x)$. Например, для приближения, построенного по узлам x_{i-1}, x_i, x_{i+1}:

$$Q_2(x) = \frac{x - x_{i+1}}{x_{i-1} - x_{i+1}} f(x_{i-1}) + \frac{x - x_{i-1}}{x_{i+1} - x_{i-1}} f(x_{i+1}),$$

в точке $x = x_i$ получим:

$$\frac{d}{dx} f(x) \approx \frac{d}{dx} Q_2(x) = \frac{f(x_{i+1}) - f(x_{i-1})}{x_{i+1} - x_{i-1}}$$

$$\frac{d}{dx} f(x)_{|x=x_i} \approx \frac{f(x_{i+1}) - f(x_{i-1})}{2h}$$

а ошибка в этой же точке:

$$\varepsilon = \frac{d}{dx} R_2(x) = \left(\frac{f'''(\eta)}{3!}\right)' (x - x_{i-1})(x - x_i)(x - x_{i+1})$$

$$+ \frac{f'''(\eta)}{3!} \left((x - x_{i-1})(x - x_i)(x - x_{i+1})\right)'$$

после сокращений и с учетом принятых обозначений получим:

$$\frac{d}{dx} f(x)_{|x=x_i} \approx \frac{f(x_{i+1}) - f(x_{i-1})}{2h}, \varepsilon = -\frac{f'''(\eta)}{6} h^2 \qquad (1.20)$$

Формула (20) называется формулой первой центральной разностной производной. Здесь ошибка пропорциональна h^2, что, впрочем, еще не

означает, что формула (1.20) всегда точнее, чем (1.18) и (1.19) – в выражениях используются старшие производные различных порядков.

Для приближенного определения производной второго порядка продифференцируем $Q_2(x)$. В точке $x = x_i$ получим формулу второй центральной разностной производной:

$$\frac{d^2}{dx^2} f(x)_{|x=x_i} \approx \frac{f(x_{i-1}) - 2f(x_i) + f(x_{i+1})}{h^2}, \varepsilon = -\frac{f^{(4)}(\eta)}{3} h^2 \quad (1.21)$$

Аналогично, рассматривая интерполяционные полиномы старших степеней, получим приближенные формулы производных старших порядков.

Влияние шага h на ошибку приближения производной неоднозначно [7]. С одной стороны, уменьшение шага ведет к снижению ошибки метода, но с другой – при уменьшении шага возрастает ошибка его реализации. Обозначим:

$$M^{(m+1)} = \left\| f^{(m+1)}(\eta) \right\|_{C[a;b]} = \max_{\eta \in [a;b]} \left| f^{(m+1)}(\eta) \right|,$$

и рассмотрим суммарную ошибку дифференцирования в простейшем случае – для правой разностной производной:

$$\bar{\varepsilon} = \bar{\varepsilon}_I + \bar{\varepsilon}_{II} = \left| -\frac{M^{(2)}}{2} h \right| + \left| \frac{f(x+h) - f(x)}{h} \right| \leq \frac{M^{(2)}}{2} h + \frac{2\epsilon}{h}$$

где оценка $\bar{\varepsilon}_I$ связана с ошибкой схемы, а оценка $\bar{\varepsilon}_I$ с ошибкой вычисления функции. Характерный пример приведен на рисунке 1.12.

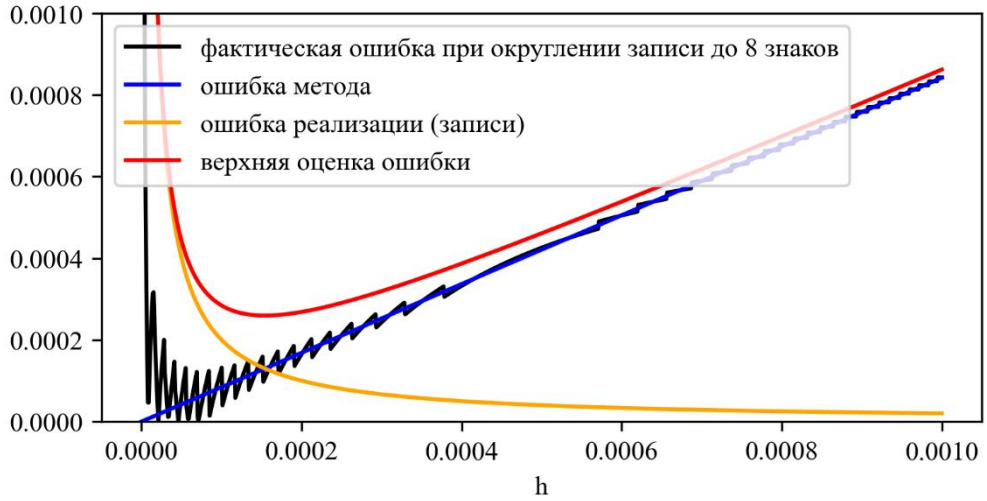

Рисунок 1.12 – Влияние шага на оценку дифференцирования

Тема 1.6. Приближенное интегрирование

Определенный интеграл $f(x)$ на отрезке $[a;b]$ приближенно определим, проинтегрировав интерполяционный полином, тогда [7]:

$$I = \int_a^b f(x)dx \approx \int_a^b Q_m(x)dx, \tag{1.22}$$

при этом ошибка приближенного интегрирования равна:

$$\varepsilon = \int_a^b R_m(x)dx \tag{1.23}$$

что, аналогично случаю дифференцирования, следует из:

$$f(x) = Q_m(x) + R_m(x) \Longrightarrow \int_a^b f(x)dx = \int_a^b Q_m(x) + R_m(x)dx,$$

Рассматривая интерполяционный полином $Q_0(x)$:

$$Q_0(x) = (x - \xi)f(\xi)$$

построенный в последовательно по точкам $\xi = a, b$, получим простейшие формулы левых и правых прямоугольников:

$$I_л = (b - a)f(a), I_п = (b - a)f(b)$$

ошибки двух формул получим, воспользовавшись теоремой о среднем [7]:

$$\int_a^b \varphi_1(x)\varphi_2(x)dx = \varphi_1(\eta^*)\int_a^b \varphi_2(x)dx$$

где $\varphi_2(x)$ – знакопостоянная на отрезке $[a;b]$ функция, точка $\eta^* \in [a; b]$, к выражениям:

$$\varepsilon_л = \int_a^b (x - a)f'(\eta)dx = f'(\eta^*)\int_a^b (x - a)dx =$$

$$= f'(\eta^*)\left(\frac{1}{2}x^2 - ax\right)\Big|_{x=a}^{x=b} = \frac{(b-a)^2}{2}f'(\eta^*)$$

$$\varepsilon_{\text{п}} = \int_a^b (x-b) f'(\eta) dx = -\frac{(b-a)^2}{2} f'(\eta^*)$$

где $\eta^* \in [a; b]$.

Формулу средних прямоугольников получим, проинтегрировав разложение $f(x)$ [7]:

$$f(x) = f\left(\frac{a+b}{2}\right) + \frac{1}{1!}\left(x - \frac{a+b}{2}\right) f'^{\left(\frac{a+b}{2}\right)} + \frac{1}{2!}\left(x - \frac{a+b}{2}\right)^2 f''^{(\eta)},$$

интеграл первого слагаемого задает формулу средних прямоугольников (аналогичный результат получим, проинтегрировав $Q_0(x)$ построенный по точке $x = \frac{a+b}{2}$):

$$I_{\text{с}} = (b-a) f\left(\frac{a+b}{2}\right)$$

интеграл второго слагаемого равен нулю, а интеграл третьего определяет ошибку простейшей квадратурной формулы средних прямоугольников:

$$\varepsilon_{\text{с}} = \int_a^b \frac{f''(\eta)}{2!}\left(x - \frac{a+b}{2}\right)^2 dx = f''(\eta^*) \int_a^b \frac{1}{2}\left(x - \frac{a+b}{2}\right)^2 dx =$$

$$= \frac{(b-a)^3}{24} f''(\eta^*)$$

Приближение функции $Q_1(x)$ по точкам a, b и его интегрирование приводит к элементарной формуле трапеций:

$$I_{\text{т}} = (b-a)\frac{f(a) + f(b)}{2},$$

причем ошибка определяется при помощи теоремы о среднем:

$$\varepsilon_{\text{т}} = \int_a^b \frac{f''(\eta)}{2!}(x-a)(x-b) dx = -\frac{(b-a)^3}{12} f''(\eta^*)$$

В случае приближения $f(x)$ полиномом $Q_2(x)$, построенным по точкам a, $\frac{a+b}{2}$, b получим простейшую квадратурную формулу парабол (формулу Симпсона):

$$I_{\text{С}} = \frac{b-a}{6}\left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right)$$

выражение ее ошибки получается более сложным, по сравнению с предыдущими, способом и записывается следующим образом:

$$\varepsilon_{\text{С}} = -\frac{(b-a)^5}{2880} f^{(4)}(\eta^*)$$

Полученные выражения связывают длину отрезка [a;b] и ошибки простейших квадратурных формул. Для уточнения результатов на отрезке [a;b] составляется сетка по узлам $x_i \in [a; b]$ и оценка определенного интеграла выполняется по составным квадратурным формулам:

$$I \approx \sum_i \int_{x_i}^{x_{i+1}} Q_m(x)dx$$

Например, для сетки с равным шагом:

$$h = \frac{b-a}{N}, x_i = a + hi, i = 0,1, \dots N,$$

где N – число отрезков, на которые делится [a;b], задается, получим следующие составные формулы (в формуле (22) пределы интегрирования заменяются на x_i, x_{i+1}):

- составные формулы левых, правых и центральных прямоугольников:

$$I_{\text{л}} = h\sum_{i=0}^{N-1} f(x_i), I_{\text{п}} = h\sum_{i=1}^{N} f(x_i) \quad (1.24),$$

$$I_{\text{ц}} = h\sum_{i=0}^{N-1} f\left(x_i + \frac{h}{2}\right) \quad (1.25)$$

- составная формула трапеций:

$$I_{\text{т}} = \frac{h}{2}\left(f(a) + 2\sum_{i=1}^{N-1} f(x_i) + f(b)\right), \quad (1.26)$$

- составная формула парабол:

$$I_{\text{С}} = \frac{h}{3}\left(f(a) + 4\sum_{i=0}^{\frac{N}{2}-1} f(x_{2i+1}) + 2\sum_{i=1}^{\frac{N}{2}-1} f(x_{2i}) + f(b) \right) \qquad (1.27)$$

NB: при получении формулы (1.27) принято условие, что N – четное, а приближение $Q_2(x)$ строится по точкам x_i, x_{i+1}, x_{i+2}.

Ошибки составных квадратурных формул находятся при помощи теоремы о среднем дискретной величины:

$$\varepsilon = \sum_i \varepsilon_i = N \cdot \frac{1}{N}\sum_i \varepsilon_i = N\varepsilon_{\eta^*}$$

где индекс i соответствует порядковому номеру отрезка $[x_i; x_{i+1}]$ (для формулы парабол – отрезка $[x_i; x_{i+2}]$), ε_{η^*} - ошибка квадратурной формулы в некоторой точке $\eta^* \in [a; b]$. Тогда для составных формул:

- левых и правых прямоугольников получим соответственно:

$$\varepsilon_{\text{л}} = N \cdot \frac{1}{N}\sum_{i=0}^{N-1} -\frac{(x_{i+1} - x_i)^2}{2} f'(\eta_i) = -\frac{Nh^2}{2} f'(\eta^*) = -\frac{(b-a)^2}{2N} f'(\eta^*)$$

$$\varepsilon_{\text{п}} = \frac{Nh^2}{2} f'(\eta^*) = \frac{(b-a)^2}{2N} f'(\eta^*), \qquad (1.28)$$

- для формулы средних прямоугольников:

$$\varepsilon_{\text{ц}} = N\frac{h^3}{24} f''(\eta^*) = \frac{(b-a)^3}{24N^2} f''(\eta^*), \qquad (1.29)$$

- для формулы трапеций:

$$\varepsilon_{\text{т}} = -N\frac{h^3}{12} f''(\eta^*) = -\frac{(b-a)^3}{12N^2} f''(\eta^*), \qquad (1.30)$$

- и для составной формулы парабол:

$$\varepsilon_{\text{С}} = -N\frac{h^5}{2880} f^{(4)}(\eta^*) = -\frac{(b-a)^5}{2880N^4} f^{(4)}(\eta^*), \qquad (1.31)$$

Если рассмотреть две сетки с индексами (1) и (2) предположить, что $N_{(1)}$, $N_{(2)}$ достаточно велико, а $f(x)$ достаточно гладка для того, чтобы допустить приближенное равенство:

$$f^{(d)}\left(\eta^*_{(1)}\right) \approx f^{(d)}\left(\eta^*_{(2)}\right),$$

то возможно предложить приближенную оценку ошибки составной формулы из следующих соображений:

$$\begin{cases} I - I_{(1)} = \varepsilon_{(1)} = C_{(1)} f^{(d)}\left(\eta^*_{(1)}\right) \\ I - I_{(2)} = \varepsilon_{(2)} = C_{(2)} f^{(d)}\left(\eta^*_{(2)}\right) \end{cases}$$

тогда:

$$\frac{I - I_{(1)}}{C_{(1)}} \approx \frac{I - I_{(2)}}{C_{(2)}}, I \approx \frac{I_{(2)}C_{(1)} - I_{(1)}C_{(2)}}{C_{(1)} - C_{(2)}}$$

где C – коэффициент пропорциональности, зависящий от квадратурной формулы и шага, например, для формулы (31):

$$C_{(1)} = -N_{(1)}\frac{h^3_{(1)}}{12}, C_{(2)} = -N_{(2)}\frac{h^3_{(2)}}{12}$$

Положим, что $N_{(2)} = 2N_{(1)}$, тогда для составной формулы трапеций:

$$I \approx \frac{4}{3}I_{(2)} - \frac{1}{3}I_{(1)}, \bar{\varepsilon} \approx \frac{1}{3}I_{(2)} - \frac{1}{3}I_{(1)}$$

Например, для функции:

$$f(x) = \sin x \cos x\,, \int_a^b f(x)\,dx = \frac{\cos^2 a - \cos^2 b}{2}$$

на отрезке [-1;2] при $N = 2^k$ получим при помощи составной квадратурной формулы трапеций (рисунок 1.13):

k	1	2	3	4	5
$I_т$*10^4	63,1577	478,0036	565,6458	586,7677	592,0015
ln($\bar{\varepsilon}$)	-0,87	-4,28	-5,84	-7,26	-8,65
ln(ε)	-1,01	-6,09	-9,1	-11,92	-14,71
k	6	7	8	9	10
$I_т$*104	593,307	593,6332	593,7148	593,7352	593,7403
ln($\bar{\varepsilon}$)	-10,04	-11,43	-12,82	-14,2	-15,59
ln(ε)	-17,48	-20,26	-23,03	-25,8	-28,58

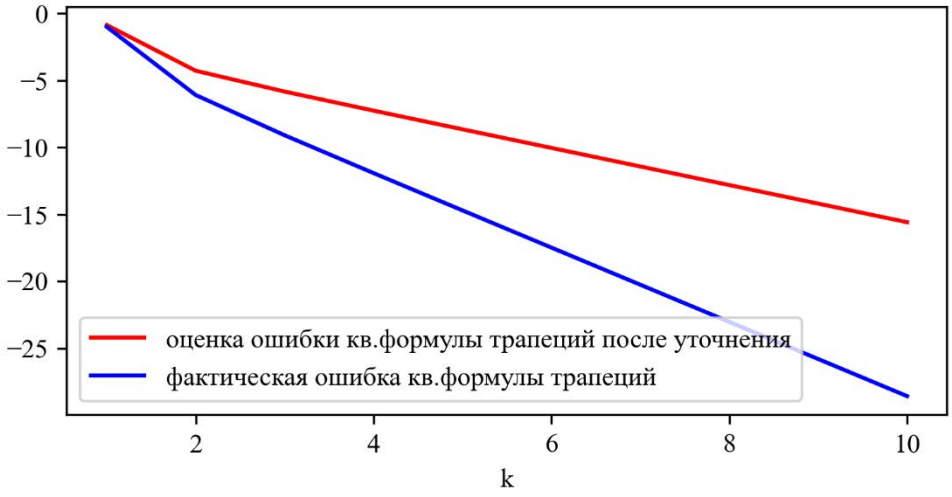

Рисунок 1.13 – Пример оценки ошибки составной формулы трапеций

Тема 1.7. Наилучшее приближение в нормированном линейном пространстве

Теперь поставим задачу приближения несколько иначе. Определим расстояние между объектом f и приближением g, являющимися векторами нормированного линейного пространства, и потребуем его минимума [1]:

$$g: \rho = \|f - g\| \to \min_g \tag{1.32}$$

В случае пространства Гильберта, $f, g \in H$:

$$g: \rho = \|f - g\| = \sqrt{\langle f - g, f - g \rangle} \to \min_g$$

где символ $\langle \cdot, \cdot \rangle$ - скалярное произведение.

NB: Доказательство существования минимума (1.32) приведено в [1]. В общем случае для нормированного пространства минимум (1.32) может быть не единственным, см. [1].

Для определенности, примем структуру приближения g в виде линейной комбинации:

$$g = a_0\varphi_0 + a_1\varphi_1 + \cdots + a_m\varphi_m = \sum_{j=0}^{m} a_j\varphi_j \tag{1.33}$$

где a – числовые коэффициенты, φ – линейно-независимые функции, называемые базисными, и условимся, что минимум ищется по евклидовой норме разности, в таком случае получаем задачу:

$$g: \rho = \|f - g\|_2 \to \min_g \quad \Leftrightarrow \rho^2 = \|f - g\|_2^2 \to \min_g$$

$$\rho^2 = \|f - g\|_2^2 = \langle f - g, f - g\rangle = \langle f - \sum_{j=0}^{m} a_j\varphi_j\,, f - \sum_{j=0}^{m} a_j\varphi_j\rangle \to \min_a$$

В такой постановке решение задачи находится из условий:

$$\frac{\partial}{\partial a_j}\rho^2 = \frac{\partial}{\partial a_j}\langle f - \sum_{j=0}^{m} a_j\varphi_j\,, f - \sum_{j=0}^{m} a_j\varphi_j\rangle = 0,$$

$$\frac{\partial}{\partial a_j}\rho^2 = 2\,\langle \varphi_j, f - \sum_{j=0}^{m} a_j\varphi_j\rangle = 0$$

$$\langle \varphi_j, \sum_{j=0}^{m} a_j\varphi_j\rangle = \langle \varphi_j, f\rangle$$

тогда получаем систему линейных алгебраических уравнений относительно коэффициентов приближения g по (33), в общем виде:

$$a_0\langle \varphi_j, \varphi_0\rangle + a_1\langle \varphi_j, \varphi_1\rangle + \cdots + a_m\langle \varphi_j, \varphi_m\rangle = \langle \varphi_j, f\rangle,$$

В матричном виде система записывается так:

$$\begin{pmatrix} \langle \varphi_0, \varphi_0\rangle & \langle \varphi_0, \varphi_1\rangle & & \langle \varphi_0, \varphi_m\rangle \\ \langle \varphi_1, \varphi_0\rangle & \langle \varphi_1, \varphi_1\rangle & & \langle \varphi_1, \varphi_m\rangle \\ & & \ddots & \\ \langle \varphi_m, \varphi_0\rangle & \langle \varphi_m, \varphi_1\rangle & & \langle \varphi_m, \varphi_m\rangle \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \langle \varphi_0, f\rangle \\ \langle \varphi_1, f\rangle \\ \vdots \\ \langle \varphi_m, f\rangle \end{pmatrix} \qquad (1.34)$$

Теперь рассмотрим два случая. В первом из них требуется получить приближение непрерывного f. Рассмотрим решение на примере $f = f(x)$, причем f – дважды интегрируем по x, $x \in [a; b]$. Тогда скалярное произведение можно ввести следующим образом:

$$\langle y_1(x), y_2(x)\rangle = \int_a^b p(x) y_1(x), y_2(x)\, dx \qquad (1.35)$$

где $p(x)$ – весовая функция, y_1, y_2 – пара произвольных векторов линейного пространства. В более общем случае, для функции многих переменных, можем записать:

$$\langle y_1, y_2\rangle = \int_\Omega p y_1, y_2\, d\Omega, d\Omega = dx_1 \dots dx_k$$

Набор базисных функций можно задать различными способами. Например, в качестве базисных функций φ можно выбрать:

$$\varphi = \{x^0, x, x^2, \dots, x^m\}, p(x) \equiv 1 \qquad (1.36)$$

либо, что может оказаться удобнее, набор ортогональных функций, например, полиномов Чебышева:

$$\varphi = \{T_0(t), T_1(t), \dots, T_m(t)\}, p(t) = \frac{1}{\sqrt{1-t^2}}$$
$$t = t(x) = \frac{2x-(a+b)}{b-a}, x \in [a; b] \qquad (1.37)$$

либо полиномов Лежандра:

$$\varphi = \{L_0(t), L_1(t), \dots, L_m(t)\}, p(t) \equiv 1,$$
$$t = t(x) = \frac{2x-(a+b)}{b-a}, x \in [a; b] \qquad (1.38)$$

Еще одним «удобным» примером является набор функций:

$$\varphi = \{1, \sin x, \cos x, \dots, \sin mx, \cos mx\}, p(x) \equiv 1 \qquad (1.39)$$

При использовании базисных функций по (1.36) матрица системы (1.34) получается плотной, при использовании базисных функций по (1.37) – (1.39) – диагональной, поскольку:

$$\int_a^b p\big(t(x)\big)\varphi_i\big(t(x)\big)\varphi_j\big(t(x)\big)dx = 0, i \neq j$$

что упростит вычисления коэффициентов приближения:

$$a_j = \delta_j \int_a^b p\big(t(x)\big)\varphi_j\big(t(x)\big)f(x)dx\,, \delta_j = \left(\int_a^b p\big(t(x)\big)\varphi_j^2 dx\right)^{-1} \qquad (1.40)$$

Для базисных функций по (1.37) (полиномы Чебышева):

$$\delta_j = \begin{cases} \dfrac{(b-a)\pi}{2}, j = 0 \\ \dfrac{(b-a)\pi}{4}, j > 0 \end{cases}$$

для базисных функций по (38) (полиномы Лежандра):

$$\delta_j = \frac{b-a}{2j+1}$$

NB: приближения по базисным функциям (1.36), (1.38) совпадут в пределах ошибок вычислений, приближение с использованием (1.37) при том же m будет отличаться, поскольку минимум расстояния ищется с ограничением в виде весовой функции $p(x)$ – пример приведен на рисунке 1.14.

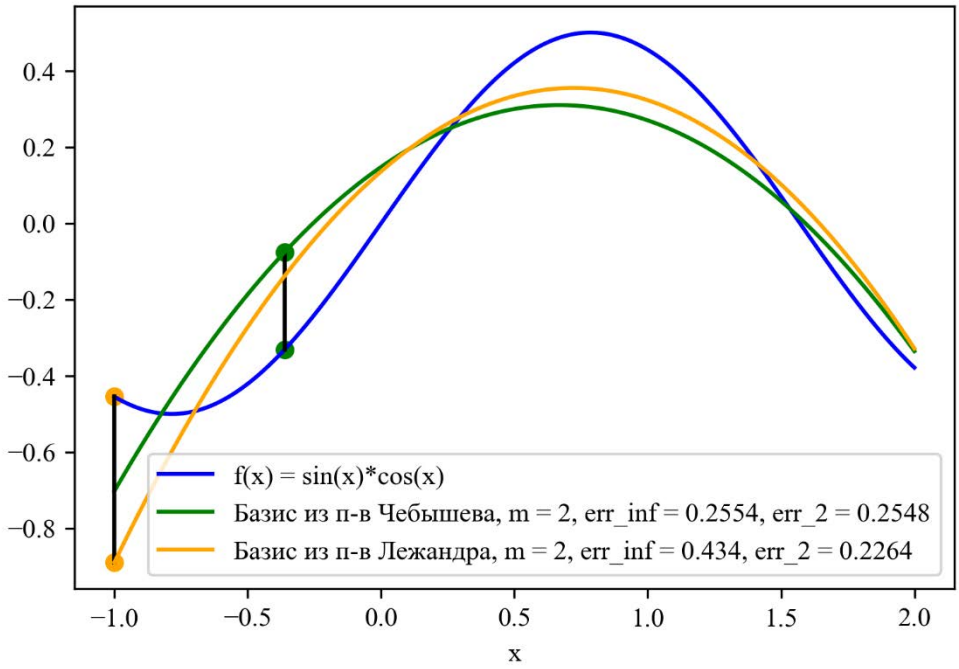

Рисунок 1.14 – Приближение функции линейными комбинациями полиномов Чебышева и Лежандра (ee_inf – норма-бесконечность ошибки приближения, err_2 – вторая норма ошибки приближения)

Использование набора базисных функций, составленного из полиномов Чебышева, позволяет получить приближение с минимальной высшей нормой ошибки:

$$\varepsilon = \left\| f(x) - g\big(t(x)\big) \right\|_{C[a;b]} = \max_{x \in [a;b]} \left| f(x) - g\big(t(x)\big) \right|$$

при этом приближение по (38) обеспечивает минимум нормы ошибки:

$$\varepsilon = \left\| f(x) - g\big(t(x)\big) \right\|_2 = \sqrt{\int_a^b \Big(f(x) - g\big(t(x)\big) \Big)^2 dx}$$

так же как и при g по (1.36).

Тема 1.8. Дискретный случай и метод наименьших квадратов

Особый практический интерес представляет случай приближения дискретного объекта $f \in \mathbb{R}^n$. Скалярное произведение вводится следующим образом [7]:

$$\langle y_1, y_2 \rangle = \sum_{i=1}^{n} w_i y_{1,i} y_{2,i} \tag{1.41}$$

где w – вектор весов.

Рассмотрим набор базисных функций:

$$\varphi = \{\varphi_0, \varphi_1, \varphi_2, \dots, \varphi_m\}, \varphi \in \mathbb{R}^n \tag{1.42}$$

и приближение в виде линейной комбинации:

$$g = \sum_{j=0}^{m} a_j \varphi_j \tag{1.43}$$

тогда система уравнений (1.34) представляет собой:

$$\begin{pmatrix} \sum w\varphi_0^2 & \sum w\varphi_0\varphi_1 & & \sum w\varphi_0\varphi_m \\ \sum w\varphi_0\varphi_1 & \sum w\varphi_1^2 & & \sum w\varphi_1\varphi_m \\ & & \ddots & \\ \sum w\varphi_0\varphi_m & \sum w\varphi_1\varphi_m & & \sum w\varphi_m^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \sum w\varphi_0 f \\ \sum w\varphi_1 f \\ \vdots \\ \sum w\varphi_m f \end{pmatrix}$$

Например, для случая:

$$\varphi = \{x^0, x^1\} = \{1, x\}, g = a_0 + a_1 x, f = y, y \in \mathbb{R}^n, w = 1$$

запишем хорошо знакомую систему линейных алгебраических уравнений:

$$\begin{cases} a_0 n + a_1 \sum_{i=1}^{n} x_i = \sum_{i=1}^{n} x_i \\ a_0 \sum_{i=1}^{n} x_i + a_1 \sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} x_i y_i \end{cases}$$

аналогично, для приближения $g = a_0 + a_1 x + a_2 x^2$:

$$\begin{cases} a_0 n + a_1 \sum_{i=1}^{n} x_i + a_2 \sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} x_i \\ a_0 \sum_{i=1}^{n} x_i + a_1 \sum_{i=1}^{n} x_i^2 + a_2 \sum_{i=1}^{n} x_i^3 = \sum_{i=1}^{n} x_i y_i \\ a_0 \sum_{i=1}^{n} x_i^2 + a_1 \sum_{i=1}^{n} x_i^3 + a_2 \sum_{i=1}^{n} x_i^4 = \sum_{i=1}^{n} x_i^2 y_i \end{cases}$$

и так далее.

Для сокращения дальнейшей записи введем обозначения:

$$F = \begin{pmatrix} | & & | \\ \varphi_0 & \dots & \varphi_m \\ | & & | \end{pmatrix}, \mathbf{w} = \begin{pmatrix} | \\ w \\ | \end{pmatrix}, W = \mathrm{diag}(\mathbf{w}), \mathbf{y} = \begin{pmatrix} | \\ f \\ | \end{pmatrix}, \mathbf{a} = \begin{pmatrix} | \\ a \\ | \end{pmatrix}$$

тогда, в общем случае, запишем систему уравнений (34) для дискретной задачи:

$$\left(W^{1/2}F\right)^T \left(W^{1/2}F\right)\mathbf{a} = WF^T\mathbf{y}$$

откуда вектор **a**:

$$\mathbf{a} = \left(\left(W^{1/2}F\right)^T\left(W^{1/2}F\right)\right)^{-1}(WF)^T\mathbf{y}$$

$$\mathbf{a} = (F^TWF)^{-1}F^TW\mathbf{y}$$

$$\mathbf{a} = (F^TWF)^{-1}F^TW\mathbf{y} \qquad (1.44)$$

получили запись точного решения для задачи взвешенного метода наименьших квадратов (weighted least-squares method, WLSM), если ввести скалярное произведение с вектором весов из единиц, то получим выражение:

$$\mathbf{a} = (F^TF)^{-1}F^T\mathbf{y} \qquad (1.45)$$

для точного решения задачи метода наименьших квадратов (least-squares method, LSM).

Обсудим некоторые практические аспекты построения приближения в дискретном случае. Во-первых, при заданных значениях базисных функций в виде матрицы F структура решения не измениться, если дополнить F столбцами, элементы которых получаются на основе φ:

$$F = \begin{pmatrix} | & | & & | \\ \varphi_0 & \ldots\psi_1(\varphi_0, \ldots, \varphi_m) & \ldots & \psi_k(\varphi_0, \ldots, \varphi_m) \\ | & | & & | \end{pmatrix}$$

где ψ – произвольные функции, образующие линейно-независимый набор с φ, при этом исключение столбцов, очевидно, также не изменит логику решения.

NB: Такой подход в анализе данных и машинном обучении называется конструирование признаков (feature engineering).

Прямое решение задачи (1.44), (1.45) не всегда возможно и не всегда целесообразно.

В случае, если $n \leq d$ (d – число столбцов F, признаков) результат обращения вырожденной матрицы F^TWF не определен, и найдется бесконечное число векторов **a**, отвечающих условию (1.32) – такая ситуация называется «некорректной задачей», что, впрочем не означает отсутствия решения, приемлемого для практического использования.

С точки зрения организации вычислений, при большой размерности возникает вопрос об устойчивости вычислительной схемы. Обращение матрицы является ресурсоемкой операцией, вдобавок чувствительной к ошибкам вычислений. Приведем пример на рисунке 1.15.

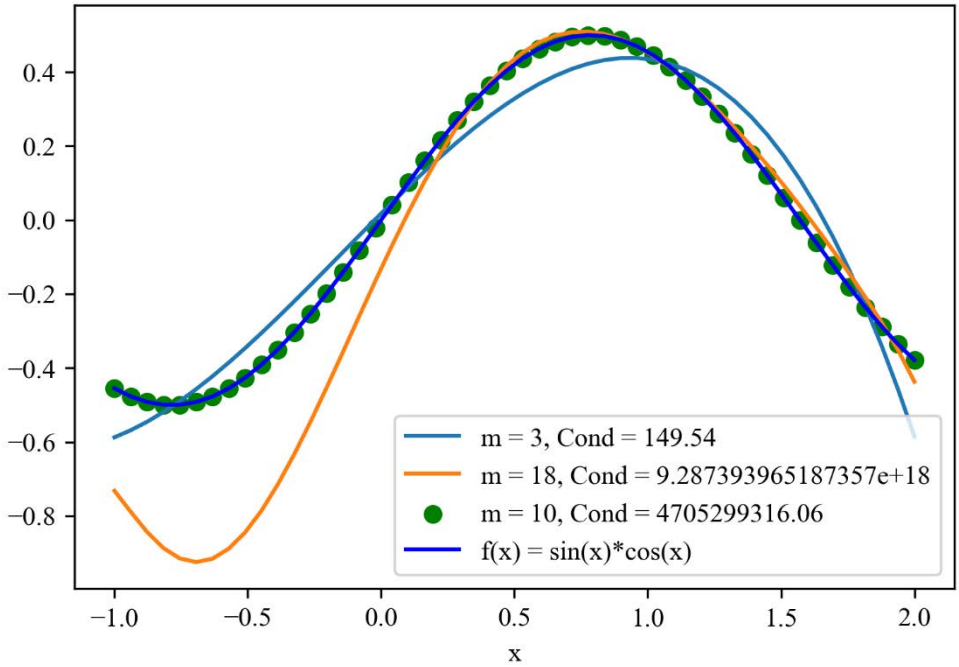

Рисунок 1.15 – Приближение функции алгебраическим полиномом степени m (Cond – число обусловленности матрицы F^TF)

Вычисления выполнены в двойной точности. В примере приближение со степенью $m = 18$ получено неверно по причине ошибок округления, к которым чувствителен результат обращения матрицы с большим числом обусловленности.

Пример приведен исключительно в образовательных целях, на практике едва ли возникает задача приближения алгебраическим полиномом высокой степени. Однако, частый случай в анализе данных – построение приближения в виде линейной комбинации при большом числе признаков в исходных данных, либо при их конструировании. Для того, чтобы избежать проблем, возникающих при прямом решении задачи, пользуются численными методами минимизации (1.32) без обращения F^TF, либо иными приемами, связанными с приближением матрицы F.

В заключение рассмотрим случай построения приближения WLSM. На рисунке 16 проиллюстрированы результаты для «зашумленного» дискретного набора точек, причем одна из них, очевидно, является «выбросом». Приближение по (1.45) не учитывает этого обстоятельства, приближение по (1.44) позволяет снизить влияние точки-выброса на результаты определения коэффициентов **a**.

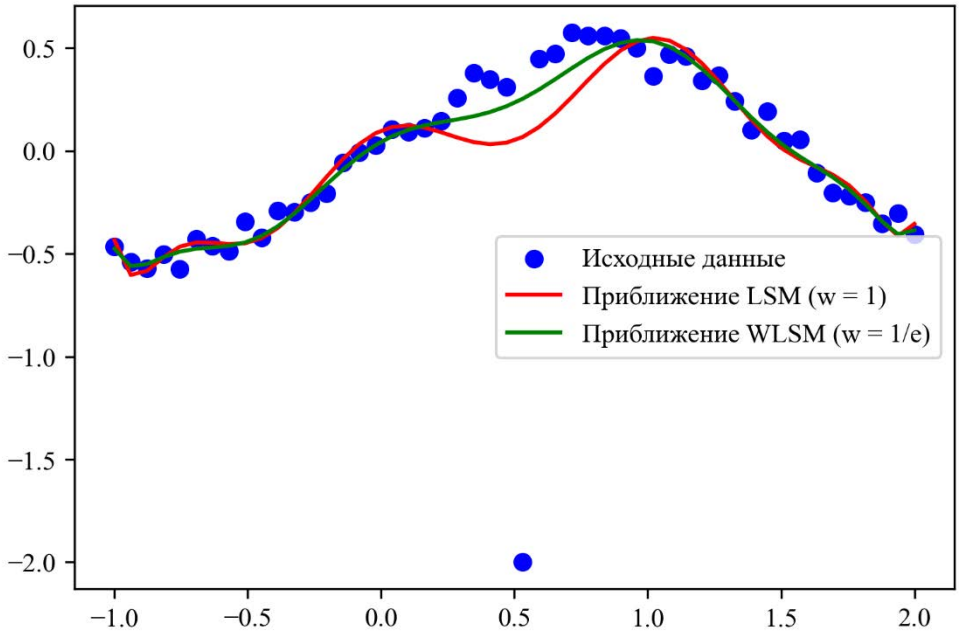

Рисунок 1.16 – Приближение зашумленного набора точек

При иллюстрации примера рассмотрено приближение в виде алгебраического полинома степени $m = 4$. Здесь координаты вектора весов заданы следующим образом:

$$w_i = \frac{1}{\left|f_i - g_{i|w=1}\right|}$$

где $g_{i|w=1}$ – приближение по (1.45).

На практике веса задают на основе исходных данных с учетом «доверия» к рассматриваемым точкам, например, при наличии повторных наблюдений, вес i-ой точки предлагается определять так:

$$w_i = \frac{1}{S_i}, S_i = \sqrt{\frac{1}{p-1}\sum_{k=1}^{p}\left(f_{i,k} - \overline{f_i}\right)^2}, \overline{f_i} = \frac{1}{p}\sum_{k=1}^{p} f_{i,k}$$

Тема 1.9. Метод Ньютона для решения нелинейных алгебраических уравнений и систем

При решении нелинейных уравнений ставится задача по поиске точки x^*:

$$x^*: f(x^*) = 0$$

где $f(x)$ – нелинейная функция.

Изложим один из способов решения задачи, использующий приближение нелинейной функции $f(x)$ в виде ряда.

Рассмотрим разложение функции в точке $x = x^*$ в ряд Тейлора [7]:

$$f(x^*) = f(x + \varepsilon) = f(x) + \varepsilon f'(x) + \frac{1}{2}\varepsilon^2 f''(x) + O(\varepsilon^3) = 0$$

тогда:

$$f(x) + \varepsilon f'(x) \approx 0, \varepsilon \approx -\frac{f(x)}{f'(x)},$$

$$x^* \approx x - \frac{f(x)}{f'(x)}$$

и построим итерационный процесс на основе полученного приближенного равенства:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \tag{1.46}$$

Оценим скорость сходимости метода. Ошибка приближенного решения:

$$\varepsilon_{k+1} = x^* - x_{k+1} = x^* - x_k + \frac{f(x_k)}{f'(x_k)}$$

$$\varepsilon_{k+1} = \varepsilon_k + \frac{f(x_k)}{f'(x_k)} = \frac{\varepsilon_k f'(x_k) + f(x_k)}{f'(x_k)} =$$

$$= \frac{-\left(\frac{1}{2}\varepsilon_k^2 f''(x_k) + O(\varepsilon_k^3)\right)}{f'(x_k)} \approx -\varepsilon_k^2 \frac{f''(x_k)}{2f'(x_k)} \Rightarrow$$

$$\Rightarrow |\varepsilon_{k+1}| \approx \left|\frac{f''(x_k)}{2f'(x_k)}\right| \varepsilon_k^2 = C\varepsilon_k^2, C = \left|\frac{f''(x_k)}{2f'(x_k)}\right| \tag{1.47}$$

Из (2) следует квадратичная оценка скорости сходимости метода, но при ряде допущений о гладкости функции. Кратко сформулируем их следующим образом. Пусть на отрезке $[a;b]$ локализован корень уравнения и выполнено [1]:

$$\left|\frac{1}{f'(x)}\right| < A, \left|\frac{f(x)}{f'(x)}\right| < B,$$
$$|f''(x)| \le C \le \frac{1}{2AB} = \frac{1}{2}\frac{\left(f'(x)\right)^2}{|f(x)|} \tag{1.48}$$

Тогда, если начальное приближение «удачно» выбрано в середине этого отрезка:

$$x_0 = \frac{b-a}{2},$$

длина которого:

$$b - a < \frac{1}{AB}\left(1 - \sqrt{1 - 2ABC}\right) \tag{1.49}$$

то итерационный процесс (1) сходится к x^*.

Строгое и подробное доказательство сходимости метода и области сходимости дается теоремами Канторовича.

Построим итерационный процесс для случая решения системы нелинейных уравнений:

$$\mathbf{f}(\mathbf{x}^*) = \bar{0}$$

где x – вектор-функция m неизвестных:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}, \mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_3(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} f_1(x_1, \dots, x_m) \\ f_2(x_1, \dots, x_m) \\ \vdots \\ f_3(x_1, \dots, x_m) \end{bmatrix}$$

Рассмотрим два способа обосновать итерационный процесс поиска корней системы. Первый из них основан на многомерном аналоге разложения функции в ряд:

$$\mathbf{f}(\mathbf{x}^*) = \mathbf{f}(\mathbf{x} + \boldsymbol{\varepsilon}) = \mathbf{f}(\mathbf{x}) + J(\mathbf{x})\boldsymbol{\varepsilon} + O(\boldsymbol{\varepsilon}^2) = 0$$

где J – матрица Якоби:

$$J(\mathbf{x}) = \mathbf{f}'(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1(x_1, \dots, x_m)}{\partial x_1} & \frac{\partial f_1(x_1, \dots, x_m)}{\partial x_2} & \dots & \frac{\partial f_1(x_1, \dots, x_m)}{\partial x_m} \\ \frac{\partial f_2(x_1, \dots, x_m)}{\partial x_1} & \frac{\partial f_2(x_1, \dots, x_m)}{\partial x_2} & \dots & \frac{\partial f_2(x_1, \dots, x_m)}{\partial x_m} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(x_1, \dots, x_m)}{\partial x_1} & \frac{\partial f_m(x_1, \dots, x_m)}{\partial x_2} & \dots & \frac{\partial f_m(x_1, \dots, x_m)}{\partial x_m} \end{bmatrix}$$

тогда:

$$\mathbf{f}(\mathbf{x}) + J(\mathbf{x})(\mathbf{x}^* - \mathbf{x}) \approx 0$$

откуда следует:

$$\mathbf{x}^* \approx \mathbf{x} - [J(\mathbf{x})]^{-1}\mathbf{f}(\mathbf{x})$$

и полученное приближенное равенство становится «обоснованием» структуры итерационного процесса уточнения вектор-решения:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [J(\mathbf{x})]^{-1}\mathbf{f}(\mathbf{x}_k) \tag{1.50}$$

Второй способ использует параметризацию [7]. Пусть в некоторой точке:

$$\mathbf{x}^* = \mathbf{x} + \boldsymbol{\varepsilon}$$

Рассмотрим производную в точке $\mathbf{x} + t\boldsymbol{\varepsilon}$

$$\frac{d\mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})}{dt} = \frac{\partial \mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})}{\partial(\mathbf{x} + t\boldsymbol{\varepsilon})} \cdot \frac{\partial(\mathbf{x} + t\boldsymbol{\varepsilon})}{\partial t} = \frac{\partial \mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})}{\partial(\mathbf{x} + t\boldsymbol{\varepsilon})}\boldsymbol{\varepsilon}$$

где t – скаляр, интегрирование производной, записанной в общем виде, в этой же точке по t дает:

$$\int_0^1 \frac{d\mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})}{dt} dt = \mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})|_0^1 = \mathbf{f}(\mathbf{x} + \boldsymbol{\varepsilon}) - \mathbf{f}(\mathbf{x}) = -\mathbf{f}(\mathbf{x})$$

С другой стороны, по формуле прямоугольников получим:

$$\int_0^1 \frac{\partial \mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})}{\partial(\mathbf{x} + t\boldsymbol{\varepsilon})}\boldsymbol{\varepsilon}\, dt = \left[\int_0^1 \frac{\partial \mathbf{f}(\mathbf{x} + t\boldsymbol{\varepsilon})}{\partial(\mathbf{x} + t\boldsymbol{\varepsilon})} dt\right]\boldsymbol{\varepsilon} \approx (1 - 0)\left[\frac{\partial \mathbf{f}(\mathbf{x})}{\partial(\mathbf{x})}\right]\boldsymbol{\varepsilon} = J(\mathbf{x})(\mathbf{x}^* - \mathbf{x})$$

Тогда:

$$-\mathbf{f}(\mathbf{x}) \approx J(\mathbf{x})(\mathbf{x}^* - \mathbf{x}) \Rightarrow \mathbf{x}^* \approx \mathbf{x} - [J(\mathbf{x})]^{-1}\mathbf{f}(\mathbf{x})$$

Получили ту же структуру, что и выше.

Раздел 2. Элементы вычислительной линейной алгебры

Тема 2.1. Нормы векторов в линейном пространстве

Отображение из m-мерного векторного пространства на поле действительных чисел будем называть нормой:

$$\|\cdot\|: V^m \to \mathbb{R}$$

в том случае, если выполняются три аксиомы [4]:

$$\|x\| \geq 0, \|x\| = 0 \leftrightarrow x = \bar{0}$$

$$\|\alpha x\| = |\alpha|\|x\|, \alpha \in \mathbb{R} \tag{2.1}$$

$$\|x + y\| \leq \|x\| + \|y\|$$

где $x, y \in V^m$.

Векторные нормы удобно ввести следующим образом [4]:

$$\|x\|_p = \left(\sum_{j=1}^{m} |x_j|^p\right)^{1/p} \tag{2.2}$$

где p – целое число.

Нормы по (2.2) называются нормами Гельдера.

Например, положим $p = 1$, тогда:

$$\|x\|_1 = \left(\sum_{j=1}^{m} |x_j|^1\right)^{1/1} = |x_1| + |x_2| + \cdots + |x_m| = \sum_{j=1}^{m} |x_j| \tag{2.3}$$

таким образом, норма «1» (первая норма) представляет собой сумму модулей координат вектора.

Теперь положим $p = 2$, тогда:

$$\|x\|_2 = \left(\sum_{j=1}^{m} |x_j|^2\right)^{1/2} = \sqrt{x_1^2 + x_2^2 + \cdots + x_m^2} \tag{2.4}$$

вторая норма (также называемая евклидовой) представляет собой корень квадратный из суммы квадратов координат вектора.

Далее положим $p = \infty$, и рассмотрим предел, тогда:

$$\|x\|_\infty = \lim_{p\to\infty}\left(\sum_{j=1}^{m} |x_j|^p\right)^{1/p} =$$

$$= \lim_{p\to\infty}\left(\max_j |x_j|^p \sum_{j=1}^{m} \frac{|x_j|^p}{\max_j |x_j|^p}\right)^{1/p} = \lim_{p\to\infty}\left(\max_j |x_j|^p\right)^{1/p} = \max_j |x_j| \tag{2.5}$$

норма-бесконечность (также высшая норма, норма Чебышева) представляет собой максимальный среди модулей координат вектора.

Для матричных норм выполняются аксиомы, схожие с (2.1), которые дополняются требованием субмультипликативности [4]:

$$\|A\| \geq 0, \|A\| = 0 \leftrightarrow \forall a = 0$$

$$\|\alpha A\| = |\alpha|\|A\|, \alpha \in \mathbb{R}$$

$$\|A + B\| \leq \|A\| + \|B\| \tag{2.6}$$

$$\|AB\| \leq \|A\|\|B\|$$

Существуют различные способы ввести матричные нормы, удобно воспользоваться понятиями *согласованности* и *подчиненности*.

Норма матрицы называется *согласованной* с соответствующей векторной нормой в том случае, если выполняется неравенство [4]:

$$\|Ax\| \leq \|A\|\|x\| \tag{2.7}$$

Норма матрицы называется *подчиненной* соответствующей векторной норме в том случае, если [4]:

$$\|A\| = \sup_{x\neq 0}\frac{\|Ax\|}{\|x\|} = \max_{x\neq 0}\frac{\|Ax\|}{\|x\|} \tag{2.8}$$

Всякая *подчиненная* норма *согласована* с соответствующей векторной нормой, что следует из (7), (8).

Требование субмультипликативности для нормы матрицы по (2.8) выполняется, поскольку:

$$\|AB\| = \sup_{\substack{x\neq 0\\ Bx\neq 0}}\frac{\|ABx\|}{\|x\|} = \max_{\substack{x\neq 0\\ Bx\neq 0}}\frac{\|ABx\|}{\|Bx\|}\frac{\|Bx\|}{\|x\|} \leq \max_{Bx\neq 0}\frac{\|ABx\|}{\|Bx\|}\max_{x\neq 0}\frac{\|Bx\|}{\|x\|} =$$

$$= \|A\|\|B\|$$

Рассмотрим матричные нормы, подчиненные векторным p-нормам.

Вектор Ax представляет собой:

$$A_{n\times m}x_{m\times 1} = \begin{pmatrix} a_{1,1}x_1 + a_{1,2}x_2 + \cdots + a_{1,m}x_m \\ a_{2,1}x_1 + a_{2,2}x_2 + \cdots + a_{2,m}x_m \\ \vdots \\ a_{n,1}x_1 + a_{n,2}x_2 + \cdots + a_{n,m}x_m \end{pmatrix}$$

Тогда первая его норма по построению:

$$\|Ax\|_1 = \left|a_{1,1}x_1 + \cdots + a_{1,m}x_m\right| + \cdots + \left|a_{n,1}x_1 + \cdots + a_{n,m}x_m\right| =$$

$$= \sum_{i=1}^{n}\left|a_{i,1}x_1 + \cdots + a_{i,m}x_m\right| = \sum_{i=1}^{n}\left|\sum_{j=1}^{m}a_{i,j}x_j\right| \leq \|x\|_1 \max_j \sum_{i=1}^{n}\left|a_{i,j}\right|$$

Запишем условие подчиненности:

$$\|A\|_1 = \sup_{x\neq 0}\frac{\|Ax\|_1}{\|x\|_1} = \max_{x\neq 0}\frac{\|Ax\|_1}{\|x\|_1} \leq \max_j \sum_{i=1}^{n}\left|a_{i,j}\right|$$

Остается предъявить ненулевой вектор, для которого достигается равенство – это вектор из единиц. Таким образом:

$$\|A\|_1 = \max_j \sum_{i=1}^{n} |a_{i,j}| \tag{2.9}$$

Итак, первой векторной норме подчинена матричная норма, представляющая собой максимум среди сумм модулей элементов матрицы по столбцам.

Рассмотрим вторую векторную норму произведения Ax:

$$\|Ax\|_2 = \sqrt{(Ax)^T(Ax)} = \sqrt{x^T A^T A x}$$

Обозначим $u^{(j)}$ – ортогональные нормированные собственные векторы матрицы $A^T A$. Тогда m-мерный вектор x можем представить как линейную комбинацию:

$$x = c_1 u^{(1)} + \cdots + c_m u^{(m)} = \sum_{j=1}^{m} c_j u^{(j)}$$

где c_j – коэффициенты разложения.

Подставим результат в выражение для нормы:

$$\|Ax\|_2 = \sqrt{\left(\sum_{j=1}^{m} c_j u^{(j)}\right)^T A^T A \left(\sum_{j=1}^{m} c_j u^{(j)}\right)} =$$

$$= \sqrt{\left(\sum_{j=1}^{m} c_j u^{(j)}\right)^T \left(\sum_{j=1}^{m} c_j \lambda_j (A^T A) u^{(j)}\right)}$$

С учетом нормировки, $\|u^{(j)}\| = 1$, получим:

$$\|Ax\|_2 = \sqrt{c_1^2 \lambda_1(A^T A) + \cdots + c_m^2 \lambda_m(A^T A)} = \sqrt{\sum_{j=1}^{m} c_j^2 \lambda_j (A^T A)}$$

Теперь рассмотрим вторую норму вектора x:

$$\|x\|_2 = \sqrt{\left(\sum_{j=1}^{m} c_j u^{(j)}\right)^T \left(\sum_{j=1}^{m} c_j u^{(j)}\right)} = \sqrt{\sum_{j=1}^{m} c_j^2}$$

Подставим полученные выражения в условие подчиненности, тогда:

$$\|A\|_2 = \sup_{x\neq 0}\frac{\|Ax\|_2}{\|x\|_2} = \max_{x\neq 0}\frac{\|Ax\|_2}{\|x\|_2} = \max_{x\neq 0}\frac{\sqrt{\sum_{j=1}^{m} c_j^2\lambda_j(A^TA)}}{\sqrt{\sum_{j=1}^{m} c_j^2}} \leq$$

$$\leq \sqrt{\max_j \lambda_j(A^TA)}$$

Вектор, для которого достигается равенство – $x = u^{(j)}$, таким образом:

$$\|A\|_2 = \sqrt{\max_j \lambda_j(A^TA)} \tag{2.10}$$

Матричная норма, подчиненная второй норме вектора, представляет собой квадратный корень из максимального собственного значения матрицы A^TA.

Норма-бесконечность для вектора Ax:

$$\|Ax\|_\infty = \max_i \left|a_{i,1}x_1 + a_{i,2}x_2 + \cdots + a_{i,m}x_m\right| \leq$$

$$\leq \max_j |x_i| \max_i \left|\left|a_{i,1}\right| + \left|a_{i,2}\right| + \cdots + \left|a_{i,m}\right|\right| = \|x\|_\infty \max_i \left|\sum_{j=1}^{m}\left|a_{i,j}\right|\right|$$

Подставим запись в условие подчиненности:

$$\|A\|_\infty = \sup_{x\neq 0}\frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_{x\neq 0}\frac{\|Ax\|_\infty}{\|x\|_\infty} \leq$$

$$\leq \frac{\|x\|_\infty \max_i\left|\sum_{j=1}^{m}\left|a_{i,j}\right|\right|}{\|x\|_\infty} = \max_i \left|\sum_{j=1}^{m}\left|a_{i,j}\right|\right|$$

Равенство достигается для ненулевого вектора x, составленного из единиц, таким образом:

$$\|A\|_\infty = \max_i \left|\sum_{j=1}^{m}\left|a_{i,j}\right|\right| \tag{2.11}$$

Норма матрицы, подчиненная высшей векторной норме, вычисляется как максимум среди сумм модулей элементов матрицы по строкам.

Тема 2.2. Сингулярное разложение матрицы

Сингулярным разложением прямоугольной матрицы (SVD, singular values decomposition) называется разложение вида [7]:

$$A_{n,m} = U_{n,n} S_{n,m} V_{m,m}^T \tag{2.12}$$

где U – матрица левых сингулярных векторов, V – матрица правых сингулярных векторов, S – матрица сингулярных чисел:

$$U = \begin{pmatrix} | & & | \\ u^{(1)} & \dots & u^{(n)} \\ | & & | \end{pmatrix}, AA^T u^{(i)} = \lambda_i u^{(i)}, i = 1 \dots r$$

$$V^T = \begin{pmatrix} - & v^{(1)} & - \\ & \dots & \\ - & v^{(m)} & - \end{pmatrix}, A^T A v^{(j)} = \lambda_j v^{(j)}, j = 1 \dots r$$

$$S = \mathrm{diag}(\sigma) = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{pmatrix}, \sigma = \sqrt{\lambda_j}, j = 1 \dots r$$

Существование сингулярного разложения строго доказывается в курсах линейной алгебры. Обратим внимание, что сингулярное разложение не единственно. Запись может дополняться требованием нормировки:

$$\left\|u^{(i)}\right\| = 1, \left\|v^{(j)}\right\| = 1$$

Кроме того, для матрицы ранга r при $n > r$ столбцы U начиная с $r + 1$ могут быть произвольными (также, если $m > r$, то строки матрицы V^T могут быть произвольными).

Условимся, что сингулярные числа в записи упорядочены:

$$\sigma_1 > \sigma_2 > \dots > \sigma_r$$

Покажем, что вторая норма матрицы равна ее старшему сингулярному числу. Воспользуемся определением подчиненности [5]:

$$\|A\| = \sup_{x \neq \bar{0}} \frac{\|Ax\|}{\|x\|} = \max_{x \neq \bar{0}} \frac{\|Ax\|}{\|x\|} = \max_{x \neq \bar{0}} \frac{\|USV^T x\|}{\|x\|} =$$

$$= \max_{x \neq \bar{0}} \frac{\|S(V^T x)\|}{\|V^T x\|} = \max_{x \neq \bar{0}} \frac{\|S(V^T x)\|}{(V^T x, V^T x)} = \max_{x \neq \bar{0}} \sqrt{\frac{\sum_{j=1}^{r} \left(\sigma_j v^{(j)}, x\right)^2}{\sum_{j=1}^{r} (v^{(j)}, x)^2}} =$$

$$= \max_{x \neq \bar{0}} \sqrt{\frac{\sigma_1^2 \sum_{j=1}^{r} \frac{\left(\sigma_j v^{(j)}, x\right)^2}{\sigma_1^2}}{\sum_{j=1}^{r} \left(\sigma_j v^{(j)}, x\right)^2}} \geq \sigma_1$$

Существует ненулевой вектор, для которого достигается равенство, $x = [1 \quad 0 \quad \dots \quad 0]^T$, тогда:

$$\|A\| = \sigma_1 \tag{2.13}$$

Теорема о наилучшем приближении малого ранга [5]:

Th:
$$\min_{\operatorname{rank}(B) \leq k} \|A - B\| = \left\| A - \sum_{j=1}^{k} u^{(j)} \sigma_j v^{(j)T} \right\| = \sigma_{k+1} \tag{2.14}$$

Последнее равенство в записи очевидно, поскольку:

$$\left\| \sum_{j=1}^{r} u^{(j)} \sigma_j v^{(j)T} - \sum_{j=1}^{k} u^{(j)} \sigma_j v^{(j)T} \right\| = \left\| \sum_{j=k+1}^{r} u^{(j)} \sigma_j v^{(j)T} \right\| = \sigma_{k+1}$$

Для доказательства первого равенства рассмотрим:

$$\|A - B\| = \max_{x \neq \bar{0}} \frac{\|(A - B)x\|}{\|x\|} \geq \max_{\substack{x \neq \bar{0} \\ Bx = \bar{0}}} \frac{\|Ax\|}{\|x\|}$$

Рассмотрим два подпространства:

$$M = \operatorname{Span}\left(v^{(1)}, \dots, v^{(k+1)}\right), \dim(M) = k + 1$$

$$L = \operatorname{Kern}(B) = \{x : Bx = \bar{0}\}, \dim(L) \leq r - k$$

По формуле Грассмана:

$$\dim(M + L) = \dim(M) + \dim(L) - \dim(M \cap L)$$

тогда для пересечения:

$$\dim(M \cap L) = \underset{k+1}{\dim(M)} + \underset{\leq r - k}{\dim(L)} - \underset{\leq r}{\dim(M + L)} \geq 1$$

Значит, пересечение не пусто и существуют векторы:

$$z \in (M \cap L): z \neq 0, Bz = \bar{0}, z = \sum_{j=1}^{k+1} \xi_j v^{(j)}$$

Теперь рассмотрим $\frac{\|Az\|}{\|z\|}$:

$$\frac{\|Az\|}{\|z\|} = \|Az\| = \frac{\left\|\left(\sum_{j=1}^{r} u^{(j)} \sigma_j v^{(j)T}\right)\left(\sum_{j=1}^{k+1} \xi_j v^{(j)}\right)\right\|}{\left\|\sum_{j=1}^{k+1} \xi_j v^{(j)}\right\|} = \frac{\left\|\sum_{j=1}^{k+1} \sigma_j \xi_j u^{(j)}\right\|}{\left\|\sum_{j=1}^{k+1} \xi_j v^{(j)}\right\|} =$$

$$= \sqrt{\frac{\sum_{j=1}^{k+1} \sigma_j^2 \xi_j^2}{\sum_{j=1}^{k+1} \xi_j^2}} = \sqrt{\frac{\sigma_{k+1}^2 \sum_{j=1}^{k+1} \frac{\sigma_j^2 \xi_j^2}{\sigma_{k+1}^2}}{\sum_{j=1}^{k+1} \xi_j^2}} \geq \sigma_{k+1}$$

Равенство достигается для ненулевого вектора $z = [0 \quad 0 \quad \dots \quad 1]^T$, что и соответствует минимуму в (2.14).

Теорема (2.14) не только указывает способ построения наилучшего приближения матрицы A меньшего ранга, но и дает оценку ошибки приближения.

Сингулярные числа используются при оценке обусловленности задачи. Например, рассмотрим СЛАУ [7]:

$$Ax = b$$

если вектор правых частей записан с ошибкой, то и решение системы будет получено с ошибкой:

$$A(x + \Delta x) = b + \Delta b$$

Вычтем из последнего равенства точную запись, тогда:

$$A\Delta x = \Delta b, \Delta x = A^{-1}\Delta b$$

С учетом аксиом для норм:

$$\|\Delta x\| = \|A^{-1}\Delta b\| \leq \|A^{-1}\|\|\Delta b\|$$

$$\|b\| \leq \|A\|\|x\|$$

перемножение неравенств дает:

$$\|\Delta x\|\|b\| \leq \|A^{-1}\|\|\Delta b\|\|A\|\|x\|$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \|A^{-1}\|\|A\| \frac{\|\Delta b\|}{\|b\|}$$

В итоге получим оценку «искажения» решения при относительной ошибке записи b:

$$\frac{\|\Delta x\|}{\|x\|} \leq \mathrm{Cond}(A)\frac{\|\Delta b\|}{\|b\|}, \mathrm{Cond}(A) = \|A^{-1}\|\|A\|$$

Здесь Cond(A) – число обусловленности матрицы A.

NB: Приведенный способ оценки обусловленности не единственен.

Согласно (13), $\|A\| = \sigma_1$, при этом $\|A^{-1}\| = \sigma_r$, тогда [7]:

$$\frac{\|\Delta x\|}{\|x\|} \sim \frac{\sigma_1}{\sigma_r}\frac{\|\Delta b\|}{\|b\|}$$

Полученный результат указывает на то, что чем больше соотношение $\frac{\sigma_1}{\sigma_r}$, тем чувствительнее решение задачи по отношению к ошибкам записи. Это обстоятельство можно использовать при решении задачи среднеквадратической аппроксимации (метод наименьших квадратов, LSM, см. тему 1.8), когда коэффициенты линейной комбинации, приближающей вектор y:

$$g = \sum a_j \varphi_j$$

находятся из решения СЛАУ:

$$F^T F a = F^T y$$

Если записать матрицу значений базисных функций F в виде сингулярного разложения:

$$F = USV^T = \sum_{j=1}^{r} \sigma_j u^{(j)} v^{(j)T}$$

то решение:

$$a = (F^T F)^{-1} F^T y = ((USV^T)^T USV^T)^{-1}(USV^T)^T y =$$

$$= (VS^T SV^T)^{-1} VS^T U^T y = V((S^T S)^{-1} S^T) U^T y = \sum_{j=1}^{r} \frac{v^{(j)} u^{(j)T}}{\sigma_j} y,$$

$$a = \sum_{j=1}^{r} \frac{v^{(j)} u^{(j)T}}{\sigma_j} y \qquad (2.15)$$

В такой постановке задачи решение можно получать «он-лайн» в виде обновлений вектора a:

$$a^{k+1} = \sum_{j=1}^{k} \frac{v^{(j)} u^{(j)T}}{\sigma_j} y + \frac{v^{(k+1)} u^{(k+1)T}}{\sigma_{k+1}} y \qquad (2.16)$$

проверяя ошибку приближения на каждом шаге.

NB: в случаях, когда $m < r$ (m – число столбцов матрицы F, r – ее ранг), т.е. при решении т.н. некорректной задачи аппроксимации при решении не обращаются к неопределенной операции обращения матрицы $F^T F$ – благодаря «избыточности» записи сингулярного разложения результат $(S^T S)^{-1} S^T$ содержит r ненулевых элементов.

Еще одно важное практическое замечание состоит в следующем. Структура (2.15), (2.16) такова, что чем меньшие сингулярные числа используются при построении приближения, тем больше норма вектора a. С другой стороны, меньшим сингулярным числам соответствует большее число обусловленности, что указывает на плохую обусловленность задачи и связанные с этим сложности. Ясно, что если сингулярное разложение предъявлено полностью, проблем с вычислениями уже не возникает. Однако, с другой стороны, связь малых сингулярных чисел матрицы базисных функций и большой нормы вектора a подсказывает идею «искусственно» снизить норму вектора a с целью «улучшить» обусловленность задачи. В связи с чем возникает идея регуляризованных приближений:

$$a = \arg\min_a \left[\left\| F \sum a_j \varphi_j - y \right\|_2^2 + l \right]$$

что получило развитие в анализе данных и машинном обучении для снижениях эффекта переобучения моделей,

где l – функция-регуляризатор, например:

$$l = \tau \|a\|_2^2$$

в этом случае задача имеет точное решение:

$$a = (F^T F + \tau E)^{-1} F^T y$$

Тема 2.3. Итерационные методы решения систем линейных алгебраических уравнений (СЛАУ)

В общем виде запишем:

$$Ax = b \tag{2.17}$$

где A – невырожденная квадратная матрица, x – вектор – точное решение системы, b – некоторый вектор.

Условимся, что решение системы существует и единственно.

Для организации итерационного процесса систему (2.17) приведем к эквивалентному виду:

$$x = Sx + c \tag{2.18}$$

где S – матрица эквивалентной системы, c – вектор.

Для получения (2.18) используются преобразования, не изменяющие решение системы (2.17).

Сформулируем и докажем теорему о достаточном условии сходимости итерационного процесса [3]:

Th.: итерационный процесс:

$$x^{k+1} = Sx^k + c \tag{2.19}$$

где k – номер итерации, $k = 0, 1, \ldots, x_0$ – задано,

сходится к точному решению системы линейных алгебраических уравнений, т.е.:

$$\lim_{k\to\infty} \left\| x - x^k \right\| \to 0$$

при любых x_0, если:

$$\|S\| < 1$$

(достаточное условие сходимости)

Доказательство:

Рассмотрим разность точного решения и k-ого к нему приближения. Для эквивалентной системы, по построению:

$$x - x^k = Sx + c - (Sx^{k-1} + c) = S(x - x^{k-1}) =$$

$$= S\left(Sx + c - (Sx^{k-2} + c)\right) = S^2(x - x^{k-2}) = S^k(x - x_0)$$

Для норм левой и правой частей также справедливо равенство:

$$\|x - x^k\| = \|S^k(x - x_0)\|$$

Учтем согласованность канонических матричных и векторных норм, а также субмультипликативность матричной нормы, тогда:

$$\|x - x^k\| = \|S^k(x - x_0)\| \leq \|S^k\|\|x - x_0\| \leq \|S\|^k\|x - x_0\|$$

Обозначим:

$$\|S\| \leq q < 1$$

таким образом:

$$\|x - x_k\| \leq q^k\|x - x_0\|$$

расстояние до точного решения ограничено сверху и убывает со скоростью геометрической прогрессии ($q < 1$ по условию теоремы), таким образом, в пределе:

$$\lim_{k\to\infty}\|x - x^k\| \to 0 \blacksquare$$

Получим оценку ошибки приближенного решения.

Th.: имеет место оценка сверху [3]:

$$\|x - x^k\| \leq \frac{\|S\|}{1 - \|S\|}\|x^k - x^{k-1}\| \leq \frac{q}{1 - q}\|x^k - x^{k-1}\| \qquad (2.20)$$

Доказательство:

Рассмотрим ошибку:

$$x - x^k = Sx + c - (Sx^{k-1} + c) = S(x - x^{k-1}) = S(x - x^k + x^k - x^{k-1})$$

В нормах:

$$\|x - x^k\| = \|S(x - x^k + x^k - x^{k-1})\| \leq \|S(x - x^k)\| + \|S(x^k - x^{k-1})\|$$

$$\|x - x^k\| \leq \|S\|\|x - x^k\| + \|S\|\|x^k - x^{k-1}\|$$

$$\|x - x^k\| \leq \frac{\|S\|}{1 - \|S\|}\|x^k - x^{k-1}\| \leq \frac{q}{1 - q}\|x^k - x^{k-1}\|$$

■

Th: необходимом и достаточным условием сходимости итерационного процесса является [1]

$$|\lambda(S)| < 1 \tag{2.21}$$

Докажем достаточность

Согласно теореме Кронекера, всякая квадратная матрица может быть приведена к жордановой форме:

$$J = U^{-1}SU$$

где U – ортогональная матрица, и обратно:

$$S = UJU^{-1}$$

J – жорданова форма:

$$J = \begin{bmatrix} J_{\lambda,1} & & \\ & \ddots & \\ & & J_{\lambda,m} \end{bmatrix}$$

где J_λ – клетки Жордана:

$$J_\lambda = \begin{bmatrix} \lambda & 1 & \\ & \ddots & 1 \\ & & \lambda \end{bmatrix}$$

матрица U ортогональна, и в результате умножений норма S не изменяется, умножение на μ не изменяет ортогональности U, таким образом:

$$S = \left(\sqrt{\mu}U\right)J\left(\sqrt{\mu}U\right)^{-1} = UJ_\mu U^{-1}$$

$$\mu J = J_\mu = \begin{bmatrix} \boxed{\begin{matrix} \lambda_1 & \mu & 0 \\ 0 & \ddots & \mu \\ 0 & 0 & \lambda_1 \end{matrix}} & & \\ & \ddots & \\ & & \boxed{\begin{matrix} \lambda_m & \mu & 0 \\ 0 & \ddots & \mu \\ 0 & 0 & \lambda_m \end{matrix}} \end{bmatrix}$$

причем:

$$\|S\| = \left\|UJ_\mu U^{-1}\right\| = \left\|J_\mu\right\|$$

по условию:

$$|\lambda(S)| < 1$$

подберем μ таким образом, чтобы выполнялось неравенство:

$$\left|\lambda_j(S)\right| + \mu < 1$$

тогда норма-бесконечность матрицы:

$$\|J_\mu\|_\infty = \max_i \sum_{j=1}^{m} \left|J_{\mu_{i,j}}\right| = \max_i\left(\left|\lambda_j(S)\right| + \mu\right) < 1$$

Рассмотрим:

$$\left\|x - x^k\right\|_\infty \le \|S\|_\infty^k \|x - x^0\|_\infty \le \|U\|_\infty \left\|J_\mu\right\|_\infty^k \|U^{-1}\|_\infty \|x - x^0\|_\infty \to 0$$

и достаточность доказана.

Докажем необходимость

Предположим, что:

$$\left|\lambda_j(S)\right| \ge 1$$

Предположим, что начальное приближение подобрано так, что ошибка:

$$x - x^0 = u^{(j)}$$

Пусть x^0 – собственный вектор S, $x^0 = u^{(j)}$, тогда:

$$x - x^k = S^k u^{(j)} = S^{k-1} S u^{(j)} = S^{k-1} \lambda_j u^{(j)} = \lambda_j^k u^{(j)} \nrightarrow 0$$

Необходимость доказана. ■

Тема 2.4. Способы построения эквивалентных СЛАУ

Метод Ричардсона

Умножим левую и правую части СЛАУ на $\tau > 0$, а затем вычтем из обеих частей точное решение:

$$Ax = b \Leftrightarrow \tau Ax = \tau b \Leftrightarrow \tau Ax - x = \tau b - x \Leftrightarrow x = (E - \tau A)x + \tau b$$

Получили эквивалентную систему вида $x = Sx + c$, где:

$$S = E - \tau A, c = \tau b$$

Итерационный процесс [1]:

Th: $$x^{k+1} = (E - \tau A)x^k + \tau b \qquad (2.22)$$

сходится к точному решению СЛАУ, если

$$A = A^T \succ 0$$

и параметр τ:

$$\tau \in \left(0; \frac{2}{\mathrm{M}}\right)$$

где M – максимальное собственное значение A:

$$\mathrm{M} = \max_j \lambda_j(A)$$

Доказательство:

Запишем критерий сходимости:

$$\left|\lambda_j(S)\right| = \left|\lambda_j(E - \tau A)\right| < 1$$

Собственные значения S и A связаны равенством:

$$\lambda_j(E - \tau A) = 1 - \tau\lambda_j(A)$$

подставим его в запись критерия сходимости, тогда:

$$\left|1 - \tau\lambda_j(A)\right| < 1 \Rightarrow \begin{cases} 1 - \tau\lambda_j(A) < 1 \\ 1 - \tau\lambda_j(A) > -1 \end{cases} \Rightarrow \begin{cases} 1 - \tau\mu < 1 \\ 1 - \tau\mathrm{M} > -1 \end{cases} \Rightarrow \tau \in \left(0; \frac{2}{\mathrm{M}}\right)$$

где μ – минимальное собственное значение A:

$$\mu = \min_j \lambda_j(A)$$

Найдем оптимальное значение τ, минимизировав норму S:

$$\tau^* = \arg\min_{\tau>0} \|S\|_2 = \arg\min_{\tau>0} \|E - \tau A\|_2 = \arg\min_{\tau>0} \max_j \left|1 - \tau\lambda_j(A)\right|$$

Таким образом, решается задача оптимизации:

$$\tau^* = \arg\min_{\tau>0} \max\{|1 - \tau\mu|; |1 - \tau\mathrm{M}|\}$$

Решением оптимизационной задачи является:

$$\tau^* = \frac{2}{\mathrm{M} + \mu} \tag{2.23}$$

Метод Якоби

Представим A в виде суммы:

$$A = L + D + U$$

где L – строго нижнетреугольная матрица, D – диагональная матрица, U – строго верхнетреугольная матрица, тогда:

$$Ax = b \Leftrightarrow (L + D + U)x = b \Leftrightarrow Dx = -(L + U)x + b \Leftrightarrow$$

$$x = -D^{-1}(L + U)x + D^{-1}b$$

Получили эквивалентную систему вида $x = Sx + c$ где:

$$S = -D^{-1}(L + U), c = D^{-1}b$$

Th: Метод Якоби сходится к точному решению [1]:

$$x^{k+1} = -D^{-1}(L + U)x^k + D^{-1}b \tag{2.24}$$

если матрица A отличается диагональным преобладанием, то есть:

$$|a_{i,i}| > \sum_{\substack{j=1 \\ j \neq i}}^{m} |a_{i,j}|$$

Доказательство:

Рассмотрим норму-бесконечность матрицы эквивалентной системы в методе Якоби:

$$\|S\|_\infty = \max_i \sum_{j=1}^{m} |s_{i,j}| = \max_i \sum_{\substack{j=1 \\ j \neq i}}^{m} \frac{|a_{i,j}|}{|a_{i,i}|} = \max_i \frac{1}{|a_{i,i}|} \sum_{\substack{j=1 \\ j \neq i}}^{m} |a_{i,j}| < 1$$

по построению.

Тогда достаточное условие сходимости для метода Якоби доказано.■

Метод Гаусса-Зейделя

Представим A как сумму (аналогично с методом Якоби):

$$Ax = b \Leftrightarrow (L + D + U)x = b \Leftrightarrow (L + D)x = -Ux + b \Leftrightarrow$$

$$x = -(L + D)^{-1}Ux + (L + D)^{-1}b$$

Получили эквивалентную систему $x = Sx + c$, где:

$$S = -(L + D)^{-1}U, c = (L + D)^{-1}b$$

Th: Итерационный процесс [1, 4]:

$$x^{k+1} = -(L + D)^{-1}Ux^k + (L + D)^{-1}b \tag{2.25}$$

сходится для любых x^0 если матрица исходной системы симметрична и положительно определена:

$$A = A^T \succ 0$$

Доказательство:

Поскольку матрица A симметрична, $U = L^T$, тогда:

$$A = L + D + U = L + D + L^T$$

Запишем:

$$x^{k+1} = -(L+D)^{-1}L^T x^k + (L+D)^{-1} =$$
$$= -(L+D)^{-1}(A - L - D)x^k + (L+D)^{-1}b =$$
$$= (E - (L+D)^{-1}A)x^k + (L+D)^{-1}b$$

Рассмотрим ошибку приближенного решения:

$$r^k = x - x^{k+1} =$$
$$= (E - (L+D)^{-1}A)x + (L+D)^{-1}b - (E - (L+D)^{-1}A)x^k - (L+D)^{-1}b =$$
$$= (E - (L+D)^{-1}A)(x - x^k) = (E - (L+D)^{-1}A)r^k$$

Матрица A симметрична и положительно определена, тогда можем ввести A-норму вектора, отвечающую всем аксиомам векторных норм:

$$\|x\|_A = \sqrt{(Ax, x)}$$

Рассмотрим A-норму ошибки:

$$\left\|r^{k+1}\right\|_A^2 = (A(E - (L+D)^{-1}A)r^k, (E - (L+D)^{-1}A)r^k) =$$
$$(Ar^k - A(L+D)^{-1}Ar^k, r^k - (L+D)^{-1}Ar^k)$$

Введем обозначения:

$$v = (L+D)^{-1}Ar^k$$
$$Ar^k = (L+D)v$$

и запишем:

$$\left\|r^{k+1}\right\|_A^2 = (Ar^k - Av, r^k - v) = (Ar^k, r^k) - (Ar^k, v) - (Av, r^k) + (Av, v) =$$
$$= \left\|r^k\right\|_A^2 - \Big(2(Ar^k, v) - (Av, v)\Big) =$$
$$= \left\|r^k\right\|_A^2 - \Big(2\big((L+D)v, v\big) - \big((L+D+L^T)v, v\big)\Big) =$$
$$= \left\|r^k\right\|_A^2 - \big((L+D-L^T)v, v\big) = \left\|r^k\right\|_A^2 - (Dv, v) \le \left\|r^k\right\|_A^2 - d\|v\|_2^2$$

Для A-нормы ошибки запишем:

$$\left\|r^k\right\|_A^2 = (Ar^k, r^k) = \big((L+D)v, A^{-1}(L+D)v\big) \le \|A^{-1}(L+D)v\|\|(L+D)v\|$$

$$\leq \|A^{-1}\|_2 \|L+D\|_2^2 \|v\|_2^2 = \frac{1}{\lambda_{\min}} \|L+D\|_2^2 \|v\|_2^2$$

Из полученной оценки следует, что:

$$-\|v\|_2^2 \leq -\frac{\lambda_{\min} \left\|r^k\right\|_A^2}{\|L+D\|_2^2}$$

Подставим полученный результат в оценку ошибки, тогда:

$$\left\|r^{k+1}\right\|_A^2 \leq \left\|r^k\right\|_A^2 - d\|v\|_2^2 \leq \left\|r^k\right\|_A^2 - d\frac{\lambda_{\min}\left\|r^k\right\|_A^2}{\|L+D\|_2^2} = \left(1 - d\frac{\lambda_{\min}}{\|L+D\|_2^2}\right)\left\|r^k\right\|_A^2$$

$$\left(1 - d\frac{\lambda_{\min}}{\|L+D\|_2^2}\right) < 1$$

Таким образом, A-норма ошибки монотонно убывает от итерации к итерации и метод сходится к точному решению. ■

Тема 2.5. Частичная проблема собственных значений

Степенной метод

Условимся, что собственные числа матрицы A действительны и упорядочены по убыванию модуля:

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_r| > 0$$

где r – ранг матрицы A,

и рассмотрим итерационный процесс:

$$x^{k+1} = \frac{Ax^k}{\|Ax^k\|}, x^0 \neq 0 \qquad (2.26)$$

Утверждается, что итерационный процесс сходится:

$$\lim_{k\to\infty} \left\|u^{(1)} - x^k\right\| \to 0$$

где k – номер итерации.

Доказательство утверждения [7]:

Разложим x_0 по собственным векторам матрицы A:

$$x_0 = c_1 u^{(1)} + c_2 u^{(2)} + \cdots + c_m u^{(r)} = \sum_{j=1}^{r} c_j u^{(j)}$$

где c_j – коэффициенты разложения

Подставим результат в рабочую формулу итерационного процесса и обратимся к равенству:

$$Au^{(j)} = \lambda_j u^{(j)},$$

тогда:

$$x_1 = \frac{Ax^0}{\|Ax^0\|} = \frac{A\left(c_1 u^{(1)} + c_2 u^{(2)} + \cdots + c_r u^{(r)}\right)}{\|A(c_1 u^{(1)} + c_2 u^{(2)} + \cdots + c_r u^{(r)})\|} = \frac{\sum_{j=1}^{r} c_j \lambda_j u^{(j)}}{\left\|\sum_{j=1}^{r} c_j \lambda_j u^{(j)}\right\|}$$

Следующая подстановка дает:

$$x^2 = \frac{Ax^1}{\|Ax^1\|} = \frac{c_1 \lambda_1^2 u^{(1)} + c_2 \lambda_2^2 u^{(2)} + \cdots + c_r \lambda_r^2 u^{(r)}}{\left\|\sum_{j=1}^{r} c_j \lambda_j u^{(j)}\right\| \|c_1 \lambda_1^2 u^{(1)} + c_2 \lambda_2^2 u^{(2)} + \cdots + c_r \lambda_r^2 u^{(r)}\|} =$$

$$= \frac{\sum_{j=1}^{r} c_j \lambda_j^2 u^{(j)}}{\left\|\sum_{j=1}^{r} c_j \lambda_j u^{(j)}\right\| \left\|\sum_{j=1}^{r} c_j \lambda_j^2 u^{(j)}\right\|},$$

и далее для k-ой итерации запишем:

$$x^k = \frac{\sum_{j=1}^{r} c_j \lambda_j^k u^{(j)}}{\prod_{n=1}^{k} \left\|\sum_{j=1}^{r} c_j \lambda_j^n u^{(j)}\right\|} = \sum_{j=1}^{r} \gamma_j \lambda_j^k u^{(j)}$$

Угол между векторами:

$$\cos\varphi = \frac{\left|\left(x^k, u^{(1)}\right)\right|}{\|x^k\| \|u^{(1)}\|} = \frac{\left|\left(\gamma_1 \lambda_1^k u^{(1)} + \gamma_2 \lambda_2^k u^{(2)} + \cdots + \gamma_r \lambda_r^k u^{(r)}, u^{(1)}\right)\right|}{\left\|\sum_{j=1}^{r} \gamma_j \lambda_j^k u^{(j)}\right\| \|u^{(1)}\|} =$$

$$= \frac{\left|\gamma_1 \lambda_1^k \left(u^{(1)}, u^{(1)}\right)\right|}{\left\|\sum_{j=1}^{r} \gamma_j \lambda_j^k u^{(j)}\right\| \|u^{(1)}\|} = \frac{\left|\gamma_1 \lambda_1^k\right| \left\|u^{(1)}\right\|^2}{\left\|\lambda_1^k \sum_{j=1}^{r} \frac{\gamma_j \lambda_j^k u^{(j)}}{\lambda_1^k}\right\| \|u^{(1)}\|}$$

Тогда в пределе:

$$\lim_{k\to\infty} \cos\varphi \to \frac{\left|\gamma_1 \lambda_1^k\right| \left\|u^{(1)}\right\|^2}{\left\|\lambda_1^k \gamma_1 u^{(1)}\right\| \|u^{(1)}\|} = \frac{\left|\gamma_1 \lambda_1^k\right| \left\|u^{(1)}\right\|^2}{\left|\gamma_1 \lambda_1^k\right| \|u^{(1)}\|^2} = 1$$

Таким образом, итерационный процесс сходится к собственному вектору, соответствующему собственному числу, максимальному по модулю.

■

Приближение к собственному числу найдем из соотношения Релея:

$$\rho = \frac{(Ax^k, x^k)}{(x^k, x^k)} \approx \frac{\left(Au^{(1)}, u^{(1)}\right)}{(u^{(1)}, u^{(1)})} = \frac{\left(\lambda_1 u^{(1)}, u^{(1)}\right)}{(u^{(1)}, u^{(1)})} = \lambda_1 \qquad (2.27)$$

Следующие собственные числа и соответствующие им собственные векторы также можно получить при организации итерационного процесса со структурой (23), при этом решается частичная проблема для матрицы [3]:

$$A_2 = A - \lambda_1 u^{(1)} u^{(1)T} \qquad (2.28)$$

для которой максимальное по модулю собственное значение соответствует $\lambda_2(A)$.

Для приближений последующих собственных значений A подход аналогичен. В литературе метод называется методом исчерпывания [3].

Оценка скорости сходимости и ошибки приближения приводится в [6].

Тема 2.6. Полная проблема собственных значений

Рассмотрим сферическую норму матрицы [2]:

$$\|A\|_{\text{сф}} = \sqrt{\sum_{j=1}^{m}\sum_{i=1}^{n} a_{i,j}^2}, \|A\|_{\text{сф}}^2 = \sum_{j=1}^{m}\sum_{i=1}^{n} a_{i,j}^2$$

Квадрат сферической нормы равен следу матрицы $A^T A$:

$$\|A\|_{\text{сф}}^2 = \text{Trace}(A^T A)$$

Для дальнейшего покажем, что:

$$\|S^T AS\|_{\text{сф}}^2 = \|A\|_{\text{сф}}^2$$

где S – некоторая ортогональная матрица

Доказательство:

$$\|S^T AS\|_{\text{сф}}^2 = \text{Trace}((S^T AS)^T S^T AS) = \text{Trace}(S^T A^T SS^T AS) =$$

$$= \text{Trace}((AS)^T AS) = \|AS\|_{\text{сф}}^2 = \|(AS)^T\|_{\text{сф}}^2 = \text{Trace}(AS(AS)^T)$$

$$= \text{Trace}(AS(AS)^T) = \text{Trace}(AA^T) = \|A^T\|_{\text{сф}}^2 = \|A\|_{\text{сф}}^2$$

Итак, в результате умножения матрицы A слева и справа на S и S^T соответственно, сумма квадратов элементов не изменяется.

Далее, заметим, что если в результате умножений получена диагональная матрица [2]:

$$D = S^T AS, D = \mathrm{diag}(d)$$

то элементы этой матрицы d_j – собственные числа A.

Доказательство:

Рассмотрим векторы:

$$e^{(j)} = \begin{cases} e_i^{(j)} = 1, i = j \\ e_i^{(j)} = 0, i \neq j \end{cases}$$

При умножении вектора $e^{(j)}$ на D получим:

$$De^{(j)} = d_j e^{(j)}$$

Умножение слева на S приводит к результату:

$$S^T ASe^{(j)} = d_j e^{(j)}, ASe^{(j)} = d_j Se^{(j)}$$

заметим, что $Se^{(j)}$ – вектор, d_j – скаляр, таким образом, полученная запись повторяет тождество для собственных чисел и векторов матрицы, таким образом:

$$Au^{(j)} = \lambda_j u^{(j)}, \lambda_j = d_j, u^{(j)} = Se^{(j)}$$

$$\Lambda = U^T AU$$

Изложим метод плоских вращений Якоби для решения полной проблемы собственных значений симметричной матрицы A с действительными элементами.

NB: метод обобщается и на комплексный случай

Рассмотрим итерационный процесс [2]:

$$A_{k+1} = S_k^T A_k S_k, k = 0, \dots, \infty, A_0 = A \qquad (2.29)$$

в качестве S_k используется ортогональная матрица:

$$S_k = \begin{array}{c}
\begin{bmatrix}
1 & & & & & & & & & & \\
 & \ddots & & & & & & & 0 & & \\
 & & 1 & & & & & & & & \\
 & & & \cos\varphi & & & & -\sin\varphi & & & \\
 & & & & 1 & & & & & & \\
 & & & & & \ddots & & & & & \\
 & & & & & & 1 & & & & \\
 & & & \sin\varphi & & & & \cos\varphi & & & \\
 & & & & & & & & 1 & & \\
 & 0 & & & & & & & & \ddots & \\
 & & & & & & & & & & 1
\end{bmatrix} \\
\begin{array}{ccccccccccc}
 & & & p & & & & q & & &
\end{array}
\end{array}$$

$$\begin{array}{l} p \\ \\ \\ p \\ \\ \\ \\ q \\ \\ \\ \\ \end{array}$$

индексы p, q назначаются на каждой итерации из следующих соображений.

При перемножении матриц по (26) элементы A_{k+1} вне строк и столбцов p, q сохранят свои прежние значения:

$$a_{i,j}^{(k+1)} = a_{i,j}^{(k)}, \left(a_{i,j}^{(k+1)}\right)^2 = \left(a_{i,j}^{(k)}\right)^2, i,j \neq p, i,j \neq q$$

Сумма квадратов соответствующих элементов в строках p, q, но вне столбцов p, q, не изменится:

$$\left(a_{p,j}^{(k+1)}\right)^2 + \left(a_{q,j}^{(k+1)}\right)^2 = \left(a_{p,j}^{(k)}\right)^2 + \left(a_{q,j}^{(k)}\right)^2, j \neq p, q$$

также не изменится и сумма квадратов соответствующих элементов в столбцах, но вне строк p, q:

$$\left(a_{i,p}^{(k+1)}\right)^2 + \left(a_{i,q}^{(k+1)}\right)^2 = \left(a_{i,p}^{(k)}\right)^2 + \left(a_{i,q}^{(k)}\right)^2, i \neq p, q$$

При этом симметричность матрицы не нарушится, т.е.:

$$a_{p,q}^{(k+1)} = a_{q,p}^{(k+1)}, \left(a_{p,q}^{(k+1)}\right)^2 = \left(a_{q,p}^{(k+1)}\right)^2$$

Идея метода состоит в том, чтобы подобрать угол φ так, чтобы получить нулевые элементы с индексами (p, q), (q, p) после умножения по (26):

$$\left(a_{p,q}^{(k+1)}\right)^2 = \left(a_{q,p}^{(k+1)}\right)^2 = \left(a_{p,q}^{(k)} \cos 2\varphi + 0{,}5\left(a_{q,q}^{(k)} - a_{p,p}^{(k)}\right) \sin 2\varphi\right)^2 = 0$$

Поскольку сферическая норма матрицы не изменится, также как и сумма квадратов всех прочих элементов вне главной диагонали за исключением двух их них, с выбранными индексами p, q, сумма квадратов внедиагональных элементов будет последовательно убывать от итерации к итерации, то есть в пределе придем к диагональной матрице A_k. Для этого следует принять [2]:

$$\cos\varphi = \sqrt{\frac{1}{2}\left(1 + \frac{1}{\sqrt{1+t^2}}\right)}$$

$$\sin\varphi = \mathrm{signum}(t)\sqrt{\frac{1}{2}\left(1 - \frac{1}{\sqrt{1+t^2}}\right)}$$

где:

$$t = \frac{2a_{p,q}^{(k)}}{a_{p,p}^{(k)} - a_{q,q}^{(k)}}$$

В итерационном процессе приближение к матрице собственных векторов:

$$U_{k+1} = U_k S_k, S_0 = E$$

Литература

1. Бахвалов Н.С., Жидков Н.П., Кобельков Г.М. Численные методы. Изд. 3-е, доп. и перераб. М.:БИНОМ, 2003.
2. Ильин В.А., Позняк Э.Г. Линейная алгебра. М.: ФИЗМАТЛИТ, 2010.
3. Пак В.Г., Черкасова Т.Х. Вычислительная математика: учебное пособие. СПб.: Изд-во Политехн. ун-та, 2013.
4. Стренг Г. Линейная алгебра и ее применения. М.: Мир, 1980.
5. Тыртышников Е.Е. Матричный анализ и основы алгебры. М.: МЦНМО, 2025.
6. Уилкинсон Дж. Х. Алгебраическая проблема собственных значений. М.: Наука, 1970.
7. Устинов С.М., Зимницкий В.А. Вычислительная математика: учебное пособие для вузов по направлениям подготовки «Системный анализ и управление» и «Информатика и вычислительная техника». СПб.: БХВ-Петербург, 2009.