

Лабораторная работа №1 — Конспект для защиты

Исследование влияния предобработки данных на качество линейной регрессии

1. Цель работы

Предложить среднеквадратическую аппроксимацию табличной функции многих переменных, проанализировать чувствительность точного решения к ошибкам округления, проверить сходимость расчётных и исходных данных.

2. Теоретические сведения

2.1 Линейная регрессия

Модель линейной регрессии задаёт зависимость целевой переменной y от признаков X :

$$y = Xw + \varepsilon$$

где:

- $X \in \mathbb{R}^{n \times d}$ — матрица признаков (n объектов, d признаков),
- $w \in \mathbb{R}^d$ — вектор весов (коэффициентов),
- $y \in \mathbb{R}^n$ — вектор целевых значений,
- ε — вектор случайных ошибок.

Задача обучения — найти веса w^* , минимизирующие сумму квадратов остатков (МНК):

$$w^* = \arg \min_w \|Xw - y\|^2$$

2.2 Метод наименьших квадратов и нормальное уравнение

Функция потерь МНК:

$$L(w) = \|Xw - y\|^2 = (Xw - y)^T (Xw - y)$$

Берём градиент и приравниваем к нулю:

$$\frac{\partial L}{\partial w} = 2X^T(Xw - y) = 0$$

$$X^T X w = X^T y$$

Это **нормальное уравнение**. При невырожденной матрице $X^T X$:

$$w^* = (X^T X)^{-1} X^T y$$

На практике вместо явного обращения матрицы решают СЛАУ:

$$X^T X w = X^T y$$

методом `np.linalg.solve`, что численно устойчивее.

Важно для защиты: свободный член (intercept) вводится добавлением столбца единиц к матрице X перед решением. В коде: `X = np.c_[np.ones(len(X)), X]`. Это расширяет задачу до $(d + 1)$ параметра.

2.3 Связь с СЛАУ

Нормальное уравнение $X^T X w = X^T y$ — это СЛАУ размера $(d + 1) \times (d + 1)$. Качество её решения определяется **числом обусловленности** матрицы $A = X^T X$.

3. Методы предобработки

3.1 StandardScaler (центрирование и нормировка)

Центрирование (`with_mean=True`):

$$X' = X - \bar{X}, \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

Нормировка (`with_std=True`):

$$X'' = \frac{X'}{\sigma_X}, \quad \sigma_X = \text{std}(X_{\text{train}})$$

Полная стандартизация (`with_mean=True, with_std=True`):

$$X_{\text{scaled}} = \frac{X - \bar{X}}{\sigma_X}$$

Ключевой факт: параметры масштабирования $\bar{X}$ и σ_X вычисляются **только по обучающей выборке** и применяются к тестовой. Это предотвращает утечку информации (data leakage).

Почему масштабирование не меняет MAE при degree=1?

Линейная регрессия со свободным членом **инвариантна** к линейному преобразованию признаков. Если $X' = aX + b$, то существуют такие w' , что $X'w' = Xw$. Предсказания и MAE остаются теми же.

Почему масштабирование снижает число обусловленности?

Без нормировки признаки имеют разные масштабы (например, криминальность от 0 до 90, доля жилых зон от 0 до 100 — а расстояние от 1 до 12). Матрица $X^T X$ при этом плохо обусловлена из-за

разброса собственных значений. Деление на σ выравнивает масштабы $\rightarrow$ диапазон собственных значений сужается $\rightarrow \kappa$ уменьшается.

3.2 PolynomialFeatures

Генерирует новые признаки — степени и попарные произведения исходных.

При d исходных признаках и степени p число новых признаков:

$$D = \binom{d+p}{p}$$

Для $d = 13$ (Boston Housing):

- $p = 1$: $D = 13$
- $p = 2$: $D = \binom{15}{2} = 105$ (без исходных: 91 новый, итого с исходными 104)
- $p = 3$: $D = \binom{16}{3} = 560 \rightarrow$ с intercept: **560 признаков vs ~395 строк обучающей выборки**

Важно: при $p = 3$ число признаков (≈ 559) превышает число объектов (≈ 395). Система **недоопределена**: матрица $X^T X$ вырождена или почти вырождена, МНК-решение точно воспроизводит обучение, но не обобщается.

4. Метрики качества

4.1 MAE (средняя абсолютная ошибка)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Интерпретация: средняя ошибка предсказания в единицах целевой переменной (тыс. долларов для Boston Housing).

4.2 Число обусловленности

$$\kappa(A) = \|A\| \cdot \|A^{-1}\| = \frac{\sigma_{\max}}{\sigma_{\min}}$$

где $\sigma_{\max}$, $\sigma_{\min}$ — максимальное и минимальное сингулярные числа матрицы $A = X^T X$.

Смысл: если $\kappa(A) \sim 10^k$, то решение СЛАУ теряет порядка k значащих цифр из-за ошибок округления в данных.

В коде число обусловленности считается от **расширенной матрицы** (с добавленным столбцом единиц), так как именно она решается в `fit`:

```
Xm = np.c_[np.ones(len(X_train_poly)), X_train_poly]
cond = np.linalg.cond(Xm.T @ Xm)
```

5. Постановка задачи (Вариант 3)

- **Датасет:** Boston Housing (housing.csv)
- **Целевая переменная:** MEDV — медианная стоимость жилья (тыс. \$)
- **Признаки:** 13 столбцов (CRIM, ZN, INDUS, CHAS, NOX, RM, AGE, DIS, RAD, TAX, PTRATIO, B, LSTAT)
- **Параметры разбиения:** test_size=0.22 , random_state=46
- **Число экспериментов:** 6

№	with_mean	with_std	degree
1	False	False	1
2	True	False	1
3	False	True	1
4	True	True	1
5	True	True	2
6	True	True	3

6. Реализация (ключевые фрагменты)

Разбиение данных

```
np.random.seed(46)
indices = np.random.permutation(len(X))
test_size = int(0.22 * len(X))
train_indices = indices[test_size:]
test_indices = indices[:test_size]
```

Сначала берутся test_size индексов для теста, остальные — для обучения.

fit и predict (с intercept)

```
def fit(X, y):
    X = np.c_[np.ones(len(X)), X]      # добавляем столбец единиц
    return np.linalg.solve(X.T @ X, X.T @ y)

def predict(X, w):
    X = np.c_[np.ones(len(X)), X]
    return X @ w
```

Ключевой момент: `np.c_[np.ones(len(X)), X]` добавляется **внутри** `fit` и `predict`, поэтому передаются признаки **без** столбца единиц.

Масштабирование

```
def scale(X_train, X_test, with_mean=False, with_std=False):
    if with_mean:
        mean = X_train.mean()
        X_train, X_test = X_train - mean, X_test - mean
    if with_std:
        std = X_train.std()
        X_train, X_test = X_train / std, X_test / std
    return X_train, X_test
```

Полиномиальные признаки

```
def poly_features(X, degree=2):
    X_poly = X.copy()
    cols = X.columns.tolist()
    new_cols = {}
    for d in range(2, degree + 1):
        for combo in combinations_with_replacement(cols, d):
            name = "*".join(combo)
            new_cols[name] = X[list(combo)].prod(axis=1)
    return pd.concat([X_poly, pd.DataFrame(new_cols, index=X.index)], axis=1)
```

7. Результаты экспериментов

№	with_mean	with_std	degree	MAE_train	MAE_test	Cond
1	False	False	1	3.4245	2.9344	2.24×10^8
2	True	False	1	3.4245	2.9344	9.95×10^6
3	False	True	1	3.4245	2.9344	1.16×10^5
4	True	True	1	3.4245	2.9344	9.73×10^1
5	True	True	2	1.7389	2.5606	1.10×10^{17}
6	True	True	3	1.64×10^{-8}	663.77	1.20×10^{20}

8. Анализ результатов (ответы на вопросы защиты)

8.1 Как масштабирование признаков влияет на качество модели?

При $\text{degree} = 1$ масштабирование **не влияет на MAE**: все четыре эксперимента (1–4) дают одинаковые значения $\text{MAE}_{\text{train}} \approx 3.42$ и $\text{MAE}_{\text{test}} \approx 2.93$.

Причина: линейная регрессия со свободным членом инвариантна к линейным преобразованиям признаков. Любое линейное отображение признаков компенсируется изменением весов, предсказания не меняются.

На **число обусловленности** масштабирование влияет существенно:

Предобработка	κ
Без предобработки	2.24×10^8
Только центрирование	9.95×10^6
Только нормировка	1.16×10^5
Полная стандартизация	9.73×10^1

Основной вклад в снижение κ вносит **деление на стандартное отклонение**.

8.2 Как изменяется качество при увеличении степени полинома?

- $p = 1 \rightarrow p = 2$: $\text{MAE}_{\text{train}}$ снижается с 3.42 до 1.74, MAE_{test} — с 2.93 до 2.56. Полиномиальные признаки позволяют модели улавливать нелинейные зависимости.
- $p = 2 \rightarrow p = 3$: $\text{MAE}_{\text{train}}$ падает до $\approx 10^{-8}$ (фактически 0), но MAE_{test} взрывается до 663.77. Это переобучение.

Причина при $p = 3$: число признаков (≈ 559) превышает число объектов обучающей выборки (≈ 395). Система СЛАУ недоопределена. МНК находит решение, точно интерполирующее обучающие данные, но не обобщающееся на тест.

8.3 Есть ли признаки переобучения?

Переобучение наблюдается при $p = 2$ и резко усиливается при $p = 3$.

Признаки переобучения:

- Разрыв между $\text{MAE}_{\text{train}}$ и MAE_{test} :**
 - $p = 1$: train 3.42, test 2.93 — разрыв мал;
 - $p = 2$: train 1.74, test 2.56 — разрыв растёт;
 - $p = 3$: train ≈ 0 , test 663.77 — катастрофический разрыв.
- Рост числа обусловленности:** $\kappa \sim 10^{17}$ при $p = 2$, $\kappa \sim 10^{20}$ при $p = 3$ — решение численно нестабильно.
- Потеря численной устойчивости при $p = 3$:** предсказания принимают значения порядка 10^4 , что видно на scatter-plot.

8.4 Как число обусловленности связано с качеством модели?

Число обусловленности $\kappa(X^T X)$ характеризует **чувствительность решения СЛАУ к возмущениям данных**. Если $\kappa \sim 10^k$, то относительная ошибка решения может быть в 10^k раз больше относительной ошибки входных данных.

Связь с качеством:

- При умеренном κ (эксперименты 1–4, $\kappa \leq 10^8$) модель устойчива, $\text{MAE}_{\text{train}} \approx \text{MAE}_{\text{test}}$.
- При $\kappa \sim 10^{17}$ (эксп. 5) модель улучшает MAE_{test} по сравнению с линейной ($2.56 < 2.93$), но уже нестабильна.
- При $\kappa \sim 10^{20}$ (эксп. 6) решение теряет смысл: веса вычислены с огромными ошибками округления.

Вывод: большой κ сам по себе не означает плохого MAE — при $p = 2$ MAE_{test} лучше, несмотря на $\kappa \sim 10^{17}$. Однако κ является **индикатором риска**: чем он выше, тем менее надёжен результат.

8.5 Какая комбинация даёт наилучший результат?

Эксперимент 5 (`with_mean=True, with_std=True, degree=2`): $\text{MAE}_{\text{test}} \approx 2.56$.

- Полиномиальные признаки 2-й степени учитывают нелинейные зависимости;
- Полная стандартизация ограничивает рост κ по сравнению с нестандартизованными признаками при $p = 2$.
- При этом $\kappa \approx 10^{17}$ — результат получен в условиях пониженной численной устойчивости, что следует учитывать при интерпретации.

9. Выводы

1. **Масштабирование при `degree=1` не влияет на MAE**, но существенно снижает число обусловленности — с $\sim 10^8$ до $\sim 10^1$ при полной стандартизации. Определяющий вклад вносит деление на стандартное отклонение.
2. **Число обусловленности и масштабирование** характеризуют численную устойчивость решения СЛАУ $X^T X w = X^T y$, а не точность аппроксимации напрямую.
3. **Увеличение степени до 2** снижает MAE на обеих выборках за счёт нелинейных зависимостей. При **`degree=3`** число признаков превышает число объектов — система недоопределена, что приводит к переобучению: $\text{MAE}_{\text{train}} \approx 0$, $\text{MAE}_{\text{test}} \approx 664$.
4. **Признаки переобучения:** разрыв $\text{MAE}_{\text{train}}/\text{MAE}_{\text{test}}$ и рост числа обусловленности при увеличении степени полинома.
5. **Наилучший результат** — `with_mean=True, with_std=True, degree=2` ($\text{MAE}_{\text{test}} \approx 2.56$). Комбинация обеспечивает учёт нелинейностей при сохранении приемлемой точности, хотя $\kappa \approx 10^{17}$ остаётся высоким.

10. Частые вопросы на защите

Q: Почему `np.linalg.solve`, а не `np.linalg.inv` ?

A: `solve` использует LU-разложение и численно устойчивее явного обращения матрицы. Вычисление A^{-1} накапливает дополнительные ошибки округления.

Q: Почему `MAE_train = MAE_test` при `degree=1` для всех вариантов масштабирования?

A: MAE одинаков не только между экспериментами 1–4, но и `train ≈ test` (3.42 vs 2.93). Инвариантность — почему все 4 эксперимента дают одно и то же значение, а не почему `train = test`.

Q: Что значит «инвариантность к линейному преобразованию»?

A: Если $X' = aX + b$, то для любых весов w существуют w' такие, что $X'w' = Xw$ при всех x . Следовательно, решение нормального уравнения для X' и X даёт одинаковые предсказания.

Q: Почему `test_indices = indices[:test_size]`, а не `indices[test_size:]` ?

A: Это авторская реализация разбиения. Первые `test_size` перемешанных индексов — тест, остальные — обучение.

Q: Почему `std = X_train.std()`, а не `X_train.std(ddof=1)` ?

A: Использована популяционная дисперсия (делитель n , по умолчанию в pandas). Важно применять одни и те же параметры к `train` и `test` — и здесь они берутся именно от `train`.

Q: Как число признаков меняется с `degree`?

A: При 13 исходных признаках: `degree=1` → 13; `degree=2` → 104; `degree=3` → 559 (без `intercept`).
Формула: $\binom{d+p}{p} - 1$ новых признаков (кроме константы), или $\binom{d+p}{p}$ включая константу.

Q: Почему в `poly_features` только `range(2, degree+1)` ?

A: Исходные признаки (степень 1) уже включены через `X_poly = X.copy()`. Цикл добавляет только степени ≥ 2 .

Q: Что такое число обусловленности геометрически?

A: $\kappa(A) = \sigma_{\max} / \sigma_{\min}$ — отношение наибольшего к наименьшему сингулярному числу. Характеризует «вытянутость» эллипсоида, задаваемого матрицей. Чем сильнее вытянут — тем хуже обусловлена система.

11. Датасет Boston Housing

Признак	Описание
CRIM	Уровень преступности на душу населения
ZN	Доля жилых зон с участками > 25 000 кв.фут
INDUS	Доля акров несельскохозяйственного бизнеса
CHAS	Бинарный: 1, если граничит с рекой Чарльз
NOX	Концентрация оксидов азота

Признак	Описание
RM	Среднее число комнат в доме
AGE	Доля домов, построенных до 1940 г.
DIS	Взвешенное расстояние до центров занятости
RAD	Индекс доступности радиальных шоссе
TAX	Налоговая ставка на имущество (\$/10 000)
PTRATIO	Отношение учеников к учителям
B	$1000(B_k - 0.63)^2$, B_k — доля афроамериканцев
LSTAT	Доля населения с низким статусом (%)
MEDV	Медианная стоимость домов (тыс. \$) — целевая переменная

Всего: 506 объектов. При `test_size=0.22` : тест $\approx$ 111 объектов, обучение $\approx$ 395 объектов.