

L7 Визуализация данных и введение в статистический анализ

Ксения Балабаева
20/10/2025

Меры центральной тенденции: где находится "центр" данных?

Меры центральной тенденции описывают типичное или центральное значение в наборе данных. Две основные меры — среднее и медиана — по-разному определяют "центр" и имеют различные свойства.

Среднее (Mean, μ)

Сумма всех значений, деленная на их количество.

Формула: $\mu = (\Sigma x_i) / n$

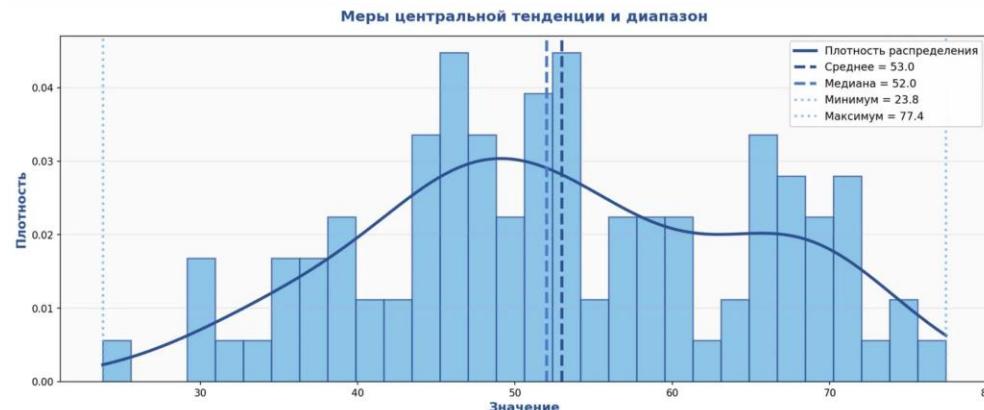
Свойство: Чувствительно к выбросам — экстремальные значения сильно влияют на среднее.

Медиана (Median)

Значение, делящее упорядоченный набор данных пополам.

50% наблюдений меньше медианы, 50% больше

Свойство: Устойчива к выбросам — экстремальные значения не влияют на медиану.



Минимум и максимум: границы диапазона данных

Минимум и максимум определяют границы, в которых находятся все значения данных. Разность между ними называется диапазоном и оказывает общий разброс данных.

min

Минимум (min)

Наименьшее значение в наборе данных. Определяет нижнюю границу распределения.

max

Максимум (max)

Наибольшее значение в наборе данных. Определяет верхнюю границу распределения.

R

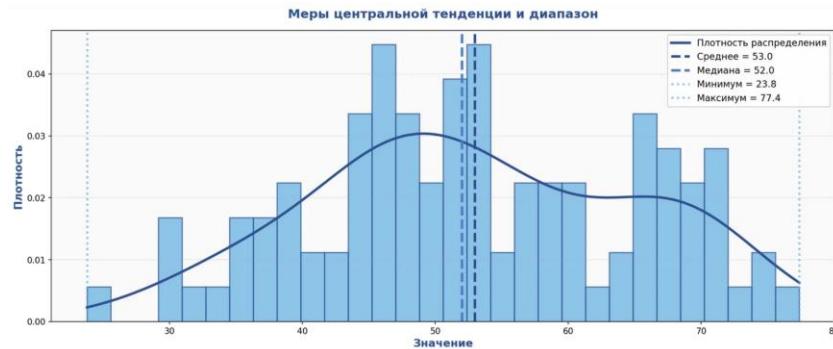
Диапазон (Range)

Разность между максимумом и минимумом.

Формула: $\text{Range} = \text{max} - \text{min}$

Применение

Быстрая оценка разброса данных, выявление экстремальных значений, проверка диапазона допустимых значений.



Мода: наиболее частое значение в данных

Мода (mode) — значение, которое встречается в наборе данных наиболее часто. В отличие от среднего и медианы, мода применима как к числовым, так и к категориальным данным.

Типы распределений по количеству мод:

Унимодальное распределение

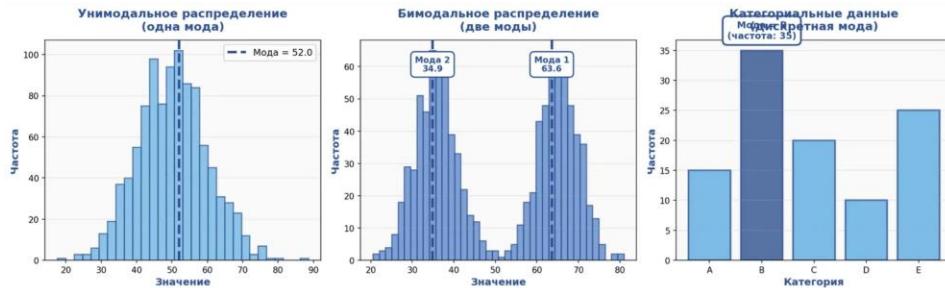
Имеет одну моду — один явный пик частоты. Характерно для нормального распределения.

Бимодальное распределение

Имеет две моды — два пика частоты. Может указывать на наличие двух различных групп в данных.

Мультимодальное распределение

Имеет более двух мод — несколько пиков частоты. Указывает на сложную структуру данных.



Особенности и применение

Для категориальных данных: Мода — единственная мера центральной тенденции, применимая к номинальным данным (например, цвет, пол, категория товара).

Устойчивость: Мода не зависит от выбросов, так как учитывает только частоту появления значений.

Квантили: деление распределения на равные части

Квантиль — значение, ниже которого находится определенная доля наблюдений в упорядоченном наборе данных.

Квартили делят данные на 4 части:

Q1 (25%) — Первый квартиль

25% данных меньше этого значения

Q2 (50%) — Второй квартиль = Медиана

50% данных меньше этого значения

Q3 (75%) — Третий квартиль

75% данных меньше этого значения

Межквартильный размах (IQR)

Содержит центральные 50% данных.

Формула: $IQR = Q3 - Q1$



Процентили делят данные на 100 частей (например, 95-й процентиль означает, что 95% данных меньше этого значения).

Стандартное отклонение: мера разброса данных

Стандартное отклонение показывает, насколько в среднем значения отклоняются от среднего. Это одна из важнейших мер разброса данных, широко используемая в статистике и машинном обучении.

Дисперсия (Variance, σ^2)

Среднее квадратов отклонений от среднего значения. Измеряется в квадратах единиц исходных данных.

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n}$$

где x — значения данных, μ — среднее, n — количество наблюдений

Стандартное отклонение: мера разброса данных

Стандартное отклонение показывает, насколько в среднем значения отклоняются от среднего. Это одна из важнейших мер разброса данных, широко используемая в статистике и машинном обучении.

Дисперсия (Variance, σ^2)

Среднее квадратов отклонений от среднего значения. Измеряется в квадратах единиц исходных данных.

$$\sigma^2 = \sum (x_i - \mu)^2 / n$$

где x — значения данных, μ — среднее, n — количество наблюдений

Стандартное отклонение (σ)

Квадратный корень из дисперсии. Измеряется в тех же единицах, что и исходные данные, что делает его более интерпретируемым.

$$\sigma = \sqrt(\sigma^2)$$

или эквивалентно:

$$\sigma = \sqrt[\sum (x_i - \mu)^2 / n]$$

Интерпретация

Чем больше σ , тем больше разброс данных. Малое стандартное отклонение означает, что значения сконцентрированы близко к среднему. Большое стандартное отклонение указывает на широкий разброс значений. Преимущество σ перед σ^2 в том, что оно измеряется в тех же единицах, что и исходные данные (например, если данные в сантиметрах, то σ также в сантиметрах).

Правило трех сигм: распределение данных вокруг среднего

Для нормального распределения правило трех сигм описывает, какая доля данных находится в пределах одного, двух и трех стандартных отклонений от среднего значения.

Интервалы стандартных отклонений

$\pm 1\sigma$ (одна сигма)

Содержит ~68.27% всех данных

$\pm 2\sigma$ (две сигмы)

Содержит ~95.45% всех данных

$\pm 3\sigma$ (три сигмы)

Содержит ~99.73% всех данных



Применение и Z-score

Выявление аномалий: Значения за пределами $\pm 3\sigma$ считаются редкими и потенциально аномальными.

Стандартизация (z-score):

$$z = (x - \mu) / \sigma$$

Показывает, на сколько стандартных отклонений значение отличается от среднего.

Box Plot: визуализация всех ключевых статистик

Box Plot (ящик с усами) объединяет медиану, квартили, межквартильный размах, минимум, максимум и выбросы в одной компактной визуализации, позволяя быстро оценить распределение данных.

Элементы Box Plot

- **Центральная линия:** медиана (Q2, 50-й процентиль)
- **Границы коробки:** Q1 (25%) и Q3 (75%)
- **Высота коробки:** IQR (межквартильный размах)
- **Усы (whiskers):** минимум и максимум без выбросов
- **Точки за усами:** выбросы (outliers)

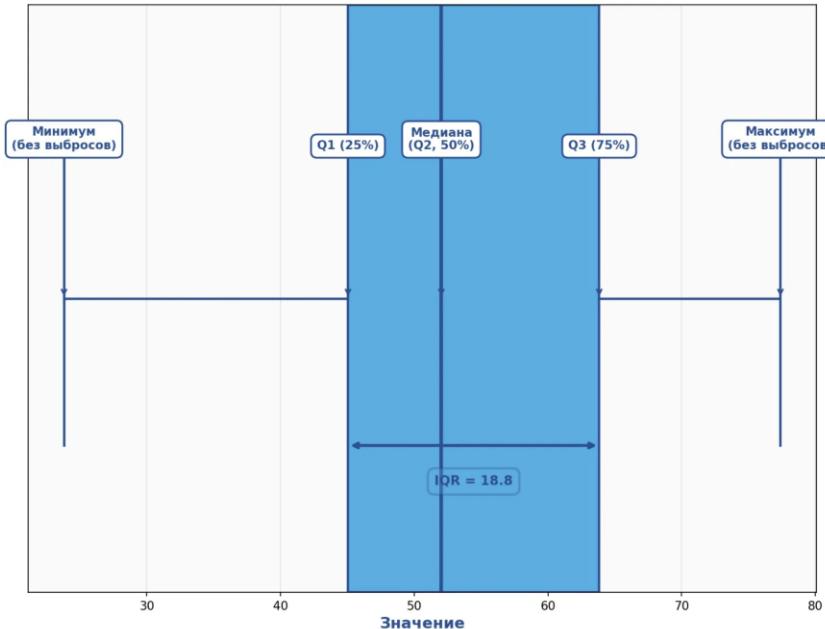
Правило выбросов

Значения за пределами интервала $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ считаются выбросами и отображаются отдельными точками.

Преимущество

Компактное представление распределения, легко сравнивать несколько групп данных, устойчивость к выбросам.

Box Plot: Визуализация всех ключевых статистик



Гистограмма и Kernel Density Estimation (KDE)

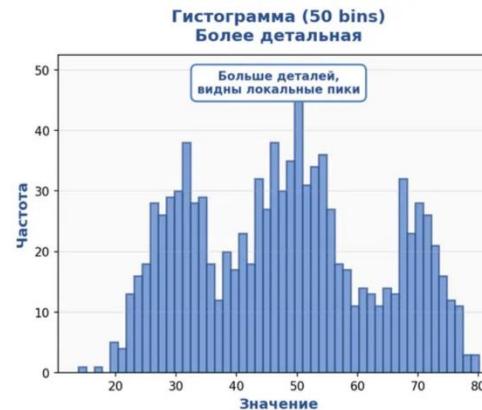
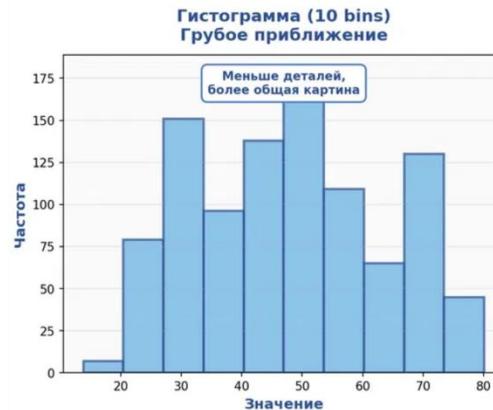
Гистограмма (Histogram)

Визуализация распределения данных путем разбиения диапазона на интервалы (bins) и подсчета частоты попадания значений в каждый интервал.

Ключевой параметр: количество bins. Малое количество дает грубое приближение, большое — более детальную картину, но может показывать шум.

Преимущества гистограммы:

- Простота интерпретации
- Показывает фактические частоты
- Быстрое построение



Гистограмма и Kernel Density Estimation (KDE)

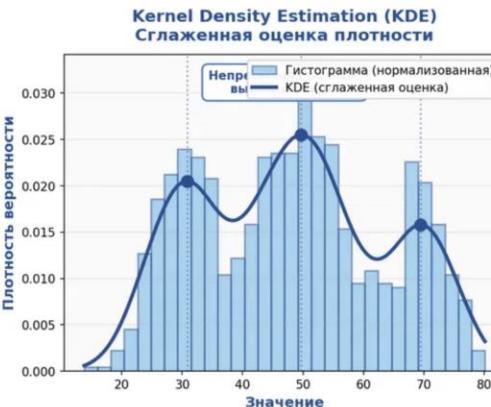
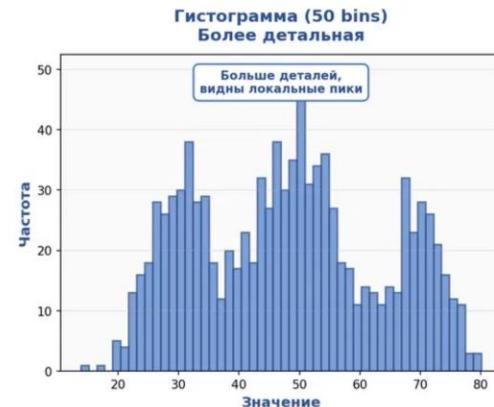
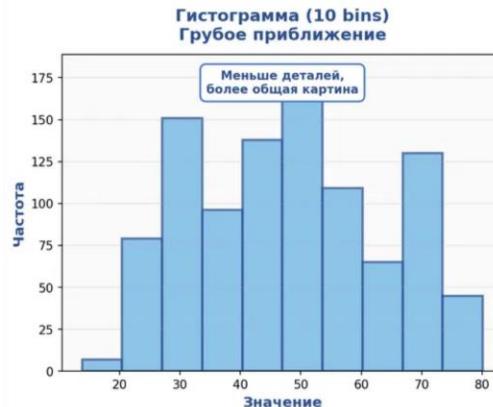
Гистограмма (Histogram)

Визуализация распределения данных путем разбиения диапазона на интервалы (bins) и подсчета частоты попадания значений в каждый интервал.

Ключевой параметр: количество bins. Малое количество дает грубое приближение, большое — более детальную картину, но может показывать шум.

Преимущества гистограммы:

- Простота интерпретации
- Показывает фактические частоты
- Быстрое построение



Kernel Density Estimation (KDE)

Непрерывная сглаженная оценка плотности вероятности. Вместо дискретных столбцов создает плавную кривую, используя ядерную функцию (kernel) вокруг каждой точки данных.

Ключевой параметр: bandwidth (ширина полосы). Контролирует степень сглаживания: малый bandwidth → детально, большой → сглажено.

Корреляция

Коэффициент корреляции Пирсона (r) — мера линейной зависимости между двумя переменными. Показывает, насколько сильно и в каком направлении связаны переменные.

Формула корреляции:

$$r = \frac{\sum [(x_i - \mu_x)(y_i - \mu_y)]}{\sqrt{[\sum (x_i - \mu_x)^2] \times [\sum (y_i - \mu_y)^2]}}$$

Диапазон значений: $-1 \leq r \leq 1$

$r = 1$

Идеальная положительная корреляция

$r = 0$

Нет линейной корреляции

$r = -1$

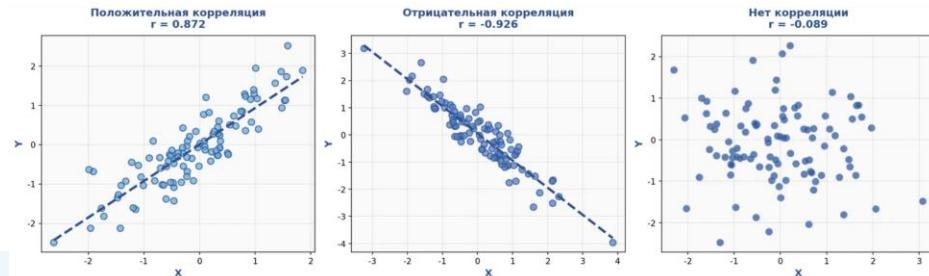
Идеальная отрицательная корреляция

Интерпретация силы связи:

$|r| > 0.7$ — сильная связь

$0.3 < |r| < 0.7$ — умеренная связь

$|r| < 0.3$ — слабая связь



Корреляция как косинус угла между векторами

Векторное представление: Переменные X и Y можно представить как векторы в n-мерном пространстве, где n — количество наблюдений. Корреляция имеет элегантную геометрическую интерпретацию через угол между этими векторами.

Формула через скалярное произведение:

$$r = \cos(\theta) = (\mathbf{X} \cdot \mathbf{Y}) / (\|\mathbf{X}\| \times \|\mathbf{Y}\|)$$

где θ — угол между центрированными векторами X и Y

Геометрический смысл:

$\theta \approx 0^\circ$ (малый угол)

$r \approx 1$ — положительная корреляция

Векторы направлены в одну сторону

$\theta \approx 90^\circ$

$r \approx 0$ — нет корреляции

Векторы перпендикулярны

$\theta \approx 180^\circ$ (большой угол)

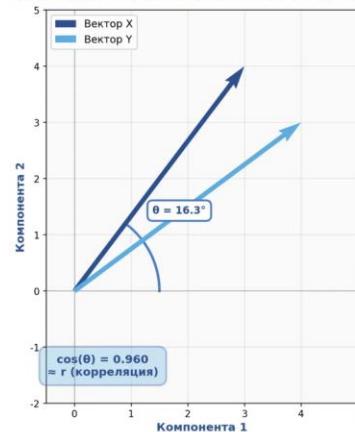
$r \approx -1$ — отрицательная корреляция

Векторы направлены в противоположные стороны

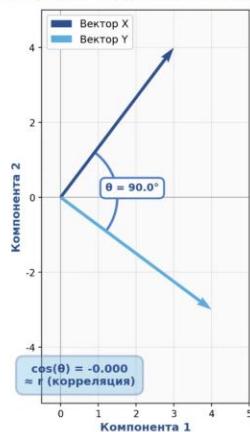
Интуиция

Корреляция показывает, насколько векторы "смотрят в одном направлении". Чем меньше угол между ними, тем сильнее положительная корреляция.

Малый угол → Высокая положительная корреляция



Большой угол → Отрицательная корреляция



Ключевые выводы

- 1** Меры центральной тенденции (среднее, мода, медиана) показывают типичное значение в данных
- 2** Меры разброса (\min , \max , IQR , σ) характеризуют вариативность и разброс данных
- 3** Квантили делят распределение на части и помогают понять структуру данных
- 4** Правило трех сигм позволяет выявлять аномалии в нормально распределенных данных
- 5** Корреляция измеряет линейную взаимосвязь между переменными ($-1 \leq r \leq 1$)
- 6** Геометрическая интерпретация: корреляция = косинус угла между векторами

Практическое применение

Эти статистики составляют фундамент анализа данных, машинного обучения и научных исследований. Они позволяют описывать данные, выявлять закономерности, обнаруживать аномалии и принимать обоснованные решения на основе количественных показателей.