

Типы задач в машинном обучении и виды разметки данных

Классификация, регрессия, кластеризация
и современные подходы к разметке

Три основных парадигмы машинного обучения

Машинное обучение классифицируется по способу обучения модели на данных. Выбор типа обучения определяется наличием размеченных данных и характером решаемой задачи.

01

Обучение с учителем

Модель обучается на размеченных данных, где для каждого объекта известна правильная метка или значение целевой переменной. Применяется для задач классификации и регрессии.

02

Обучение без учителя


Модель самостоятельно находит закономерности в неразмеченных данных без явных целевых переменных. Используется для кластеризации, снижения размерности и выявления аномалий.

03

Обучение с подкреплением

Агент обучается принимать решения через взаимодействие со средой, получая награды или штрафы за свои действия. Применяется в робототехнике, играх и системах управления.

Классификация: предсказание категориальной переменной



Постановка задачи

По выборке $\{(x_1, y_1), \dots, (x_n, y_n)\}$, где $y_i \in \{1, 2, \dots, K\}$, построить модель $f: X \rightarrow Y$ для предсказания класса.

Метрики классификации

1. Accuracy

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

Доля правильных предсказаний среди всех объектов.

Матрица ошибок и метрика F1-Score

Матрица ошибок (Confusion Matrix)

		Предсказанный класс	
		Положительный	Отрицательный
Положительный	TP	FN	
	True Positive Правильно предсказан положительный класс	False Negative Пропущен положительный класс	
Отрицательный	FP	TN	
	False Positive Ложная тревога (Type I Error)	True Negative Правильно предсказан отрицательный класс	

Метрики на основе матрицы ошибок

Precision (Точность)

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Доля правильных положительных предсказаний среди всех положительных предсказаний. Отвечает на вопрос: "Какая доля объектов, которые мы предсказали как положительные, действительно положительные?"

Recall (Полнота)

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$


Доля найденных положительных объектов среди всех истинно положительных. Отвечает на вопрос: "Какую долю положительных объектов мы смогли найти?"

F1-Score (Гармоническое среднее)

$$\text{F1} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Баланс между точностью и полнотой. Особенно полезна при несбалансированных классах, когда важны оба типа ошибок (FP и FN).

Регрессия: предсказание непрерывной переменной



Постановка задачи

По выборке $\{(x_1, y_1), \dots, (x_n, y_n)\}$, где $y_i \in \mathbb{R}$, построить модель $f: X \rightarrow \mathbb{R}$ для предсказания непрерывного значения.

Две популярные метрики

1. MSE (Mean Squared Error)

$$MSE = (1/n) \times \sum (y_i - \hat{y}_i)^2$$


Среднее значение квадратов разностей. Сильно штрафует большие ошибки.

2. MAE (Mean Absolute Error)

$$MAE = (1/n) \times \sum |y_i - \hat{y}_i|$$

Среднее значение абсолютных разностей. Более устойчива к выбросам.

Кластеризация: поиск групп схожих объектов



Постановка задачи

По набору объектов $\{x_1, \dots, x_n\}$ без меток разбить их на K кластеров так, чтобы объекты внутри кластера были схожи, а между кластерами — различны.

Две популярные метрики

1. Silhouette Score

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

$a(i)$ — среднее расстояние до своего кластера

$b(i)$ — расстояние до ближайшего чужого кластера

Значения от -1 до 1. Высокие значения означают хорошее разделение.

2. Davies-Bouldin Index

$$DB = (1/K) \times \sum_{i \neq j} \left[\frac{(s_i + s_j)}{d(c_i, c_j)} \right]$$

Разметка данных — фундамент обучения с учителем

Что такое разметка данных?

Процесс добавления меток (labels) или тэгов к сырым данным, которые показывают модели машинного обучения, что она должна предсказывать.

-  **Занимает ~80% времени** ML-проекта на подготовку и обработку данных
-  **Критична для supervised learning** — без разметки модель не может обучаться
-  **Определяет качество модели** — garbage in = garbage out
-  **Требует человеческой экспертизы** — для точной и согласованной разметки

Сырые данные

Разметка (аннотация)

Размеченные данные

Обучение модели

Готовая ML-модель

Пример

Разметка изображений кошек и собак для классификатора: каждому изображению присваивается метка "кошка" или "собака", чтобы модель научилась различать эти два класса.

"Garbage In, Garbage Out" — качество данных определяет качество модели

Принцип GIGO является фундаментальным в машинном обучении: качество выходных предсказаний модели напрямую зависит от качества входных обучающих данных.

Последствия некачественной разметки

Низкая точность предсказаний

Модель обучается на неправильных примерах и воспроизводит ошибки разметки, что приводит к систематическим ошибкам в предсказаниях на новых данных.

"Garbage In, Garbage Out" — качество данных определяет качество модели

Принцип GIGO является фундаментальным в машинном обучении: качество выходных предсказаний модели напрямую зависит от качества входных обучающих данных.

Последствия некачественной разметки

Низкая точность предсказаний

Модель обучается на неправильных примерах и воспроизводит ошибки разметки, что приводит к систематическим ошибкам в предсказаниях на новых данных.

Смещения и предвзятость (Bias)

Несогласованная или предвзятая разметка приводит к тому, что модель усваивает человеческие предрассудки и систематически ошибается на определенных группах объектов.

"Garbage In, Garbage Out" — качество данных определяет качество модели

Принцип GIGO является фундаментальным в машинном обучении: качество выходных предсказаний модели напрямую зависит от качества входных обучающих данных.

Последствия некачественной разметки

Низкая точность предсказаний

Модель обучается на неправильных примерах и воспроизводит ошибки разметки, что приводит к систематическим ошибкам в предсказаниях на новых данных.

Смещения и предвзятость (Bias)

Несогласованная или предвзятая разметка приводит к тому, что модель усваивает человеческие предрассудки и систематически ошибается на определенных группах объектов.

Неспособность обобщать

Модель переобучается на шумных или противоречивых метках и не может корректно работать на реальных данных, теряя способность к общению.

"Garbage In, Garbage Out" — качество данных определяет качество модели

Принцип GIGO является фундаментальным в машинном обучении: качество выходных предсказаний модели напрямую зависит от качества входных обучающих данных.

Последствия некачественной разметки

Низкая точность предсказаний

Модель обучается на неправильных примерах и воспроизводит ошибки разметки, что приводит к систематическим ошибкам в предсказаниях на новых данных.

Смещения и предвзятость (Bias)

Несогласованная или предвзятая разметка приводит к тому, что модель усваивает человеческие предрассудки и систематически ошибается на определенных группах объектов.

Неспособность обобщать

Модель переобучается на шумных или противоречивых метках и не может корректно работать на реальных данных, теряя способность к обобщению.

Потеря ресурсов

Некачественная разметка приводит к необходимости повторного сбора и разметки данных, что означает потерю времени, денег и вычислительных ресурсов.

Типы разметки по модальности данных



Изображения

Типы разметки:

- Классификация изображений
- Object Detection (bounding boxes)
- Semantic Segmentation
- Instance Segmentation
- Keypoint Detection

Примеры: распознавание объектов, медицинская диагностика, автономное вождение

Текст

Типы разметки:

- Классификация текста
- Named Entity Recognition (NER)
- Part-of-Speech Tagging
- Relation Extraction
- Question Answering

Примеры: анализ тональности, извлечение сущностей, чат-боты



Аудио

Типы разметки:

- Классификация звуков
- Speech-to-Text транскрипция
- Speaker Identification
- Emotion Recognition
- Sound Event Detection

Примеры: голосовые ассистенты, распознавание эмоций, транскрибация

Видео

Типы разметки:

- Action Recognition
- Object Tracking
- Video Segmentation
- Event Detection

Примеры: видеонаблюдение, спортивная аналитика, контент- moderation



Специализированные

Типы данных:

- LIDAR (облака точек)
- DICOM/NIfTI (медицинские изображения)
- Временные ряды
- 3D модели

Примеры: автономные автомобили, медицинская визуализация, IoT

Методы разметки данных



Ручная разметка

Человек вручную размечает каждый элемент данных

- Внутренняя (in-house)
- Краудсорсинг
- Экспертная разметка



Полуавтоматическая

Комбинация автоматической предразметки и ручной проверки

- Pre-labeling + проверка
- Active Learning
- Transfer Learning



Автоматическая

Модель автоматически генерирует метки без участия человека

- Weak Supervision
- Self-Supervised Learning
- Synthetic Data Generation

Метод	Стоимость	Скорость	Качество	Масштабируемость
Ручная разметка	Высокая	Медленно	Отличное	Низкая
Полуавтоматическая	Средняя	Средне	Хорошее	Средняя
Автоматическая	Низкая	Быстро	Среднее	Высокая

Сложности разметки данных



Высокие затраты времени и труда

Проблема:

80% времени ML-проекта на подготовку данных. Масштаб: 150,000+ изображений с 10 объектами каждое.

Решение:

Автоматизация, краудсорсинг, активное обучение



Необходимость экспертных знаний

Проблема:

Медицинская диагностика требует врачей, юридические документы — юристов. Высокая стоимость экспертов.

Решение:

Обучение аннотаторов, гибридный подход, transfer learning



Риск несогласованности

Проблема:

Разные аннотаторы применяют разные критерии. Субъективность оценок (например: положительный vs саркастический отзыв).

Решение:

Четкие guidelines, перекрестная разметка, метрики IAA



Риск ошибок

Проблема:

Человеческий фактор при работе с большими объемами. Усталость и невнимательность при монотонной работе.

Решение:

Контроль качества, золотой стандарт, регулярные перерывы

Большие языковые модели для разметки данных

Большие языковые модели (LLM) — это модели глубокого обучения с миллиардами параметров, способные решать широкий класс задач обработки естественного языка без специального обучения.

Преимущества использования LLM

Скорость и масштабируемость

LLM могут автоматически размечать тысячи примеров за минуты, что в десятки раз быстрее ручной разметки. Легко масштабируются на большие датасеты.

Согласованность и экономия

Обеспечивают единообразный подход к разметке, исключая человеческие ошибки. Значительно снижают затраты на разметку для простых и средних задач.

Ограничения

Требуют валидации для специализированных задач (медицина, юриспруденция). Могут ошибаться в узкоспециализированных областях. Использование коммерческих API может быть дорогим.

Применение LLM

- Классификация текстов и анализ тональности
- Выделение именованных сущностей (NER)
- Генерация синтетических данных
- Автоматическая проверка и валидация

Рекомендуемый подход

Гибридная стратегия: использование LLM для первичной автоматической разметки с последующей человеческой валидацией критически важных меток.

Качественная разметка — основа успешного машинного обучения

Выбор типа задачи определяется характером целевой переменной: классификация для категориальных меток, регрессия для непрерывных значений, кластеризация для поиска структуры в данных.

Метрики качества должны соответствовать специфике задачи: Accuracy и F1-Score для классификации, MSE и MAE для регрессии, Silhouette Score для кластеризации.

Принцип "Garbage In, Garbage Out" подчеркивает критическую важность качественной разметки данных. Некачественные данные приводят к некачественным моделям независимо от сложности алгоритма.

Современные подходы к разметке эволюционируют от полностью ручной к гибридным методам с использованием LLM. Большие языковые модели значительно ускоряют и удешевляют процесс разметки.

Оптимальная стратегия — комбинация автоматической разметки с помощью LLM и человеческой экспертизы для обеспечения высокого качества данных при разумных затратах ресурсов.