

Теория SVD: полный конспект для защиты лабораторной работы №2

1. Постановка задачи и мотивация

1.1 Проблема собственных значений — почему её недостаточно

Классическая задача собственных значений: для квадратной матрицы $A \in \mathbb{R}^{n \times n}$ найти $\lambda \in \mathbb{C}$ и $v \neq 0$ такие что:

$$Av = \lambda v$$

Ограничения:

- Работает только для **квадратных** матриц
- Далеко не каждая матрица **диагонализируема** (может не хватить собственных векторов)
- Собственные числа могут быть **комплексными** даже у вещественных матриц
- Не даёт геометрически удобного разложения для **прямоугольных** матриц

1.2 Откуда берутся прямоугольные матрицы?

В практических задачах матрицы почти всегда прямоугольные:

- Изображение 640×640 — квадратная матрица, но в общем случае $n \times m$
- Система уравнений с n уравнениями и m неизвестными при $n \neq m$
- Датасет из n объектов с m признаками

Нужно **обобщение** разложения на прямоугольный случай.

1.3 Ключевая идея: матрица — это линейное отображение

Матрица $A \in \mathbb{R}^{n \times m}$ — линейное отображение из $\mathbb{R}^m$ в $\mathbb{R}^n$. Вопрос: можно ли найти такие ортонормированные базисы в пространстве-источнике ($\mathbb{R}^m$) и пространстве-образе ($\mathbb{R}^n$), что в этих базисах A действует **максимально просто** — растягивает вдоль осей?

Ответ: **да**. Это и есть SVD.

2. Теорема о сингулярном разложении (SVD)

2.1 Формулировка

Теорема (SVD). Для любой матрицы $A \in \mathbb{R}^{n \times m}$ существует разложение:

$$A = U\Sigma V^T$$

где:

- $U \in \mathbb{R}^{n \times n}$ — ортогональная матрица ($U^T U = U U^T = I$), столбцы $u_1, \dots, u_n$ — **левые сингулярные векторы**
- $V \in \mathbb{R}^{m \times m}$ — ортогональная матрица ($V^T V = V V^T = I$), столбцы $v_1, \dots, v_m$ — **правые сингулярные векторы**
- $\Sigma \in \mathbb{R}^{n \times m}$ — **псевдодиагональная матрица** вида:

$$\Sigma = \begin{pmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \end{pmatrix}$$

с $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0 = \sigma_{r+1} = \dots$, где $r = \text{rank}(A)$.

Числа σ_i называются **сингулярными числами** матрицы A .

2.2 Доказательство существования

Шаг 1. Рассмотрим симметричную матрицу $A^T A \in \mathbb{R}^{m \times m}$.

Она **симметрична**: $(A^T A)^T = A^T A$ ✓

Она **положительно полуопределена**: $x^T (A^T A) x = \|Ax\|^2 \geq 0$ для любого x ✓

Шаг 2. По спектральной теореме для симметричных матриц существует ортонормированный базис из собственных векторов:

$$A^T A v_i = \lambda_i v_i, \quad i = 1, \dots, m$$

где $\lambda_i \geq 0$ (так как матрица п.п.о.) и $V = (v_1 | \dots | v_m)$ — ортогональная матрица.

Шаг 3. Определим сингулярные числа: $\sigma_i = \sqrt{\lambda_i}$.

Шаг 4. Для $i \leq r$ (где $\lambda_i > 0$) определим **левые сингулярные векторы**:

$$u_i = \frac{A v_i}{\sigma_i}$$

Проверим, что $\{u_i\}$ ортонормированы:

$$u_i, u_j = \frac{1}{\sigma_i \sigma_j} (A v_i)^T (A v_j) = \frac{v_i^T A^T A v_j}{\sigma_i \sigma_j} = \frac{\lambda_j v_i^T v_j}{\sigma_i \sigma_j} = \frac{\lambda_j \delta_{ij}}{\sigma_i \sigma_j} = \delta_{ij}$$

Шаг 5. Векторы $u_{r+1}, \dots, u_n$ выбираются как **произвольное** ортонормированное дополнение до базиса $\mathbb{R}^n$ (например, методом Грама–Шмидта).

Шаг 6. Проверяем разложение: для каждого $i \leq r$:

$$Av_i = \sigma_i u_i$$

В матричном виде это равносильно $AV = U\Sigma$, откуда:

$$A = U\Sigma V^T \quad \square$$

3. Геометрический смысл SVD

3.1 Действие матрицы в три шага

Разложение $A = U\Sigma V^T$ означает, что произвольное линейное преобразование — это **три простых действия**:

1. V^T : **поворот/отражение** в пространстве-источнике (переход к базису из правых сингулярных векторов)
2. Σ : **масштабирование** вдоль осей (растяжение на σ_i по i -й оси, нулевое в направлениях ядра)
3. U : **поворот/отражение** в пространстве-образа (переход из «диагонального» базиса к стандартному)

3.2 Единичный шар $\rightarrow$ эллипсоид

Матрица A переводит **единичный шар** $\{x : \|x\| = 1\}$ в **эллипсоид** с полуосями $\sigma_1 \geq \sigma_2 \geq \dots$ вдоль направлений $u_1, u_2, \dots$

Это важнейшая геометрическая интерпретация: **сингулярные числа — это длины полуосей эллипсоида-образа**.

4. Свойства сингулярных чисел

4.1 Связь с собственными числами

$$\sigma_i(A) = \sqrt{\lambda_i(A^T A)} = \sqrt{\lambda_i(A A^T)}$$

Для **квадратной** матрицы A в общем случае $\sigma_i \neq |\lambda_i(A)|$. Но:

- Для **симметричной** п.п.о. матрицы: $\sigma_i = \lambda_i$
- Для **ортогональной** матрицы: все $\sigma_i = 1$

4.2 Норма и число обусловленности

- **Спектральная норма**: $\|A\|_2 = \sigma_1$ (наибольшее сингулярное число)
- **Норма Фробениуса**: $\|A\|_F = \sqrt{\sum_i \sigma_i^2}$

- **Ранг:** $r = \mathrm{rank}(A) =$ число ненулевых сингулярных чисел
- **Число обусловленности:** $\kappa(A) = \frac{\sigma_1}{\sigma_r}$ (для невырожденной квадратной матрицы)

4.3 Сингулярные числа — всегда неотрицательны

По определению $\sigma_i = \sqrt{\lambda_i(A^T A)} \geq 0$. Это **не** собственные числа матрицы A — это геометрические коэффициенты растяжения.

Важно для лабораторной: если степенной метод выдаёт **отрицательные оценки** сингулярных чисел — это ошибка метода, не свойство матрицы. Причина: степенной метод находит собственный вектор $A^T A$, соответствующий λ_1 ; при вычислении $u_1 = Av_1/\sigma_1$ знак определяется знаком скалярного произведения. Если u_1 направлен «не туда», проекция Av_1 на «неправильный» u_1 может дать отрицательное число. Исправление: брать $|\sigma_i|$ или следить за согласованием знаков u_i и v_i .

5. Усечённое SVD (truncated SVD)

5.1 Основная идея

Полное SVD: $A = U \Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T$

Каждое слагаемое $\sigma_i u_i v_i^T$ — это **матрица ранга 1**. Сумма по всем r слагаемым даёт исходную матрицу точно.

Усечённое SVD — берём только $k < r$ первых слагаемых:

$$A_k = U_k \Sigma_k V_k^T = \sum_{i=1}^k \sigma_i u_i v_i^T$$

5.2 Теорема Экарта–Янга (оптимальность усечённого SVD)

Теорема. Среди всех матриц ранга $\leq k$ матрица A_k является **наилучшим приближением** к A как в спектральной, так и во фробениусовой норме:

$$\|A - A_k\|_2 = \sigma_{k+1}, \quad \|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}$$

Смысл: отброшенные слагаемые с малыми σ_i несут мало информации. Оставляя k главных сингулярных компонент, мы получаем **оптимальное** сжатие данных.

5.3 Коэффициент сжатия изображений

Для матрицы одного канала $n \times m$:

- Исходный объём: $n \cdot m$ чисел
- Объём усечённого SVD (k компонент): $k \cdot (n + m + 1)$ чисел (U_k : $n \cdot k$, Σ_k : k , V_k^T : $k \cdot m$)

- **Степень сжатия:** $\frac{n \cdot m}{k(n + m + 1)}$

При $n = m = 640$, $k = 50$: сжатие в $\frac{640^2}{50 \cdot 1281} \approx 6.4$ раза.

6. Степенной метод для SVD

6.1 Степенной метод для симметричной задачи

Базовый степенной метод находит **наибольшее по модулю собственное значение** матрицы B и соответствующий собственный вектор:

```
b_0 = случайный вектор
for k = 1, 2, ..., N:
    z_k = B * b_{k-1}          # умножение на матрицу
    b_k = z_k / ||z_k||        # нормировка
    λ_k = b_k^T * B * b_k      # payleigh-quotient
```

После N итераций: $b_N \approx v_1$, $\lambda_N \approx \lambda_1 = \sigma_1^2$.

Сходимость: скорость определяется отношением $\left(\frac{\sigma_2}{\sigma_1}\right)^{2N}$. Если $\sigma_1 \gg \sigma_2$ — быстро. Если $\sigma_1 \approx \sigma_2$ — медленно.

6.2 Адаптация для SVD

Цель: найти пару (u_1, v_1, σ_1) .

Вместо $A^T A$ можно работать непосредственно с A :

```
v = случайный вектор единичной нормы
for k = 1, 2, ..., N:
    u = A @ v;    u = u / ||u||    # левый сингулярный вектор
    v = A.T @ u;  v = v / ||v||    # правый сингулярный вектор
    σ = u.T @ A @ v
```

Это **билатеральный степенной метод** — он аппроксимирует σ_1 .

6.3 Нахождение последующих сингулярных чисел (дефляция)

После нахождения (u_1, v_1, σ_1) исключаем первую компоненту:

$$A^{(2)} = A - \sigma_1 u_1 v_1^T$$

Применяем метод к $A^{(2)}$ — получаем (σ_2, u_2, v_2) .

Повторяем k раз для получения k пар.

Внимание: ошибки накапливаются при дефляции — каждое последующее σ_i вычисляется менее точно.

6.4 Влияние числа итераций N

N	Погрешность (типично)	Комментарий
10	Большая (~5-20%)	Может не сойтись при $\sigma_1 \approx \sigma_2$
50	Малая (~0.1-1%)	Обычно достаточно для изображений
100	Минимальная	Избыточно при хорошем разделении

Норма $\|A - U\Sigma V^T\|$ падает с ростом N .

6.5 Почему могут появиться отрицательные сингулярные числа?

Метод вычисляет $\sigma \approx u^T A v$. Произведение $u^T A v$ — скаляр, и его знак зависит от ориентации u и v . Если на очередной итерации вектор «перевернулся» (что случается при $\sigma_i \approx 0$ или при плохой случайной инициализации), результат может оказаться отрицательным.

Это ошибка численного метода, а не свойство матрицы. Исправление: $\sigma_i := |\sigma_i|$, при необходимости корректируем знак u_i или v_i .

7. Метод вращений Якоби

7.1 Идея: диагонализация через ортогональные вращения

Метод Якоби применяется к **симметричным** матрицам. Для SVD он применяется к $B = A^T A$ (или к расширенной матрице).

Идея: последовательно уничтожать внедиагональные элементы матрицы с помощью **матриц вращений Гивенса** $G_{pq}()$:

$$B^{(k+1)} = G_{pq}^T B^{(k)} G_{pq}$$

Каждое преобразование уничтожает элемент b_{pq} (и симметричный ему b_{qp}).

7.2 Матрица вращения Гивенса

$$G_{pq}() = \begin{pmatrix} 1 & \dots & 0 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & & \vdots & & \vdots \\ 0 & \dots & \cos & \dots & \sin & \dots & 0 \\ \vdots & & \vdots & \ddots & \vdots & & \vdots \\ 0 & \dots & -\sin & \dots & \cos & \dots & 0 \\ \vdots & & \vdots & & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \dots & 0 & \dots & 1 \end{pmatrix}$$

Единицы повсюду, кроме позиций (p, p) , (q, q) : $\cos$; (p, q) : $\sin$; (q, p) : $-\sin$.

7.3 Выбор угла

Требуем, чтобы $(B')_{pq} = 0$ после применения $G_{pq}()$:

$$\tan(2) = \frac{2b_{pq}}{b_{pp} - b_{qq}}$$

Из этого уравнения:

$$= \frac{1}{2} \arctan\left(\frac{2b_{pq}}{b_{pp} - b_{qq}}\right)$$

(при $b_{pp} = b_{qq}$: $= \pi/4$).

7.4 Сходимость

Мера внедиагональности:

$$\text{off}(B) = \sqrt{\sum_{i \neq j} b_{ij}^2}$$

После каждого шага: $\text{off}(B^{(k+1)})^2 = \text{off}(B^{(k)})^2 - 2b_{pq}^2$

Метод сходится: при циклическом переборе всех (p, q) (одна «развёртка» = $\binom{n}{2}$ шагов):

$$\text{off}(B^{(k+1)}) \leq \left(1 - \frac{2}{n(n-1)}\right)^{1/2} \text{off}(B^{(k)}) \rightarrow 0$$

Критерий останова: $\text{off}(B) < \varepsilon \cdot \|B\|_F$ (или $\max_{i \neq j} |b_{ij}| < \varepsilon$).

7.5 Получение SVD из собственного разложения $A^T A$

После диагонализации: $B = V \Lambda V^T$, где $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$.

Тогда $\sigma_i = \sqrt{\lambda_i}$, V — правые сингулярные векторы.

Левые сингулярные векторы: $u_i = Av_i / \sigma_i$.

7.6 Сложность операций: сравнение методов

Метод	Сложность одного шага	Всего шагов	Итого
Степенной (для k компонент)	$O(nm)$	kN	$O(knmN)$
Якоби (для $m \times m$)	$O(m)$	$\sim m^2/\varepsilon^2$	$O(m^3/\varepsilon^2)$

Для изображений: матрица A — размер $n \times m$ (скажем 640×640).

- Степенной метод для $k = 50$ компонент, $N = 100$ итераций: $\sim 50 \times 100 \times 640^2 \approx 2 \times 10^9$ опер.
- Якоби для 640×640 : $\sim 640^3 \approx 2.6 \times 10^8$ опер., но **выдаёт все** сингулярные числа.

Практически для изображений **степенной метод быстрее**, если нужно лишь несколько первых компонент. Якоби выгоден при небольших матрицах и когда нужен полный спектр.

8. Применение к обработке изображений

8.1 Цветное изображение $\rightarrow$ три матрицы

Изображение $n \times m$ пикселей в формате RGB = три матрицы $R, G, B \in \mathbb{R}^{n \times m}$.

Обработка: SVD применяется к каждому каналу независимо:

$$R = U_R \Sigma_R V_R^T, \quad G = U_G \Sigma_G V_G^T, \quad B = U_B \Sigma_B V_B^T$$

8.2 Сжатие и восстановление

Усечённое разложение канала R при k компонентах:

$$R_k = \sum_{i=1}^k \sigma_i^{(R)} u_i^{(R)} (v_i^{(R)})^T$$

После обратной сборки k -компонентных R_k, G_k, B_k в тензор — восстановленное изображение.

Нормализация: значения пикселей обычно в $[0, 1]$ или $[0, 255]$. После восстановления нужен `np.clip(Ak, 0, 255)`.

8.3 График сингулярных чисел

Типичная картина для натурального изображения: сингулярные числа убывают быстро — первые несколько несут основную информацию («низкочастотное содержание»), остальные — детали и шум.

- **Крутое убывание** $\rightarrow$ хорошее сжатие при малом k
- **Медленное убывание** $\rightarrow$ изображение «сложное», требует большего k для качества

Различия между каналами R, G, B: распределение сингулярных чисел может отличаться (зависит от цветового состава сцены), но обычно схоже.

9. Типичные вопросы на защите и ответы

Q: Что такое сингулярное разложение?

A: Разложение $A = U\Sigma V^T$ для любой матрицы $\mathbb{R}^{n \times m}$, где U, V — ортогональные, Σ — псевдодиагональная с неотрицательными числами по диагонали. Геометрически: любое линейное отображение = поворот $\rightarrow$ масштабирование $\rightarrow$ поворот.

Q: Почему сингулярные числа всегда неотрицательны?

A: $\sigma_i = \sqrt{\lambda_i(A^T A)}$. Матрица $A^T A$ положительно полуопределена, поэтому $\lambda_i \geq 0$, и $\sigma_i \geq 0$.

Q: Почему степенной метод может дать отрицательные «сингулярные числа»?

A: Метод вычисляет скаляр $u^T A v$. Этот скаляр может быть отрицательным из-за произвольного выбора знаков u и v на каждой итерации. Истинные сингулярные числа — это модули. В отчёте нужно отметить это наблюдение и объяснить: знак зависит от ориентации сингулярных векторов, а не от матрицы.

Q: В чём смысл усечённого SVD?

A: По теореме Экарта–Янга, A_k — наилучшее приближение к A ранга k в любой унитарно-инвариантной норме. Первые k компонент несут максимум «энергии» (в смысле $\|A_k\|_F^2 = \sum_{i=1}^k \sigma_i^2$).

Q: Как связаны собственные числа $A^T A$ и сингулярные числа A ?

A: $\sigma_i(A) = \sqrt{\lambda_i(A^T A)}$. Собственные числа $A^T A$ неотрицательны, сингулярные числа — их квадратные корни.

Q: Зачем нужна нормировка пикселей при восстановлении?

A: Операции SVD не гарантируют, что значения A_k останутся в $[0, 255]$ (или $[0, 1]$). Из-за численных ошибок и усечения могут появиться значения вне диапазона. Нужен `np.clip`.

Q: Какой метод эффективнее — степенной или Якоби?

A: Зависит от задачи. Если нужны только первые $k \ll \min(n, m)$ компонент — степенной быстрее ($O(knmN)$). Если нужен **полный спектр** или матрица небольшая — Якоби целесообразен. Для изображения 640×640 с $k = 50$ степенной метод значительно быстрее.

Q: Как выбрать k для приемлемого качества изображения?

A: Смотрят на график сингулярных чисел и ищут «колесо» (knee point) — место, где убывание резко замедляется. Также можно задаться долей сохранённой «энергии»: $\frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2} \geq 0.9$ (90% энергии).

Q: Почему для разных цветовых каналов сингулярные числа разные?

A: Каждый канал R, G, B — отдельная матрица интенсивностей с собственной структурой. Для сцен с доминирующим цветом соответствующий канал может иметь более «сжатый» спектр.

Q: Что означает $\|A - U\Sigma V^T\|$?

A: Это **норма ошибки разложения**. Если разложение точное — она нулевая. При N итерациях степенного метода она убывает с ростом N , оставаясь ненулевой из-за конечного числа итераций.

10. Краткая схема: SVD в трёх словах

$$A = U \cdot \Sigma \cdot V^T$$

↑ ↑ ↑ ↑

матрица поворот масш- поворот

($n \times m$) ($n \times n$) -таб. ($m \times m$)

($n \times m$)

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ – сингулярные числа

$u_1, \dots, u_n$ – левые сингулярные векторы (столбцы U)

$v_1, \dots, v_m$ – правые сингулярные векторы (столбцы V)

$$A v_i = \sigma_i u_i \quad \leftrightarrow \quad A^T u_i = \sigma_i v_i$$

Конспект охватывает теорию, необходимую для полной защиты лабораторной работы №2 по ЧМА.